



Mühendislik ve Mimarlık Fakültesi

Bilgisayar Mühendisliği Bölümü

Bilgisayar Mühendisliği Uygulama Tasarımı Dersi Proje Formu

Proje Başlığı	
Makine Öğrenmesi Kullanarak Kredi Kartı Dolandırıcılığı Tespiti	

Öğrenci Bilgileri	
Öğrenci No	23100011032
Öğrenci Ad Soyad	Sultan YUVALI
Öğrenci No	23100011054
Öğrenci Ad Soyad	Zeynep Sude BÖREKÇİ

Dr.Öğr.Üyesi Özlem ERDAŞ ÇİÇEK

Proje Raporu Hazırlama Kuralları

Her öğrenci bitirme projesini aşağıda belirlenen kurallara göre hazırlayacaktır.

1. Rapor Bölümleri

- Kapak
- İçindekiler
- Projenin Önemi
- Projenin Amacı
- Projenin Hedefi
- Projenin iş-zaman çizelgesi
- Projede kullanılan donanımlar ve yazılımlar ile ilgili bilgileri.
- Projenin yapım aşamaları.
- Kaynaklar

2. Konu Anlatımı

- Etik kurallara uygun olarak, öğrenci konuyu kendi cümleleri ile sade bir şekilde anlatmalıdır. Yararlanılan kaynaklar belirtilmelidir.

3. Sayfa Düzeni

- Kenar Boşlukları: 2.5 cm
- Sayfa Numarası: Sağ Alt Köşede Projenin Önemi sayfasından itibaren başlamalıdır.

4. Metin Özellikleri

- Paragraf Girintisi Yok
- Metin iki yana yaslı
- Tek satır aralıklı
- 12 Punto ve Normal
- Paragraflar arasında 1 boşluk
- Ana Başlıklar ve alt Başlıklar: 12 Punto ve Kalın
- Tüm Metin Fontu: Times New Roman

5. Şekiller ve Tablolar

- Şekiller sayfa içerisinde ortalı olmalıdır.
- Şekil açıklama metni şekil altında tek satıra sığıyorsa ortalı, sığmıyorsa iki yana yaslı sol kenara yaslı olmalıdır.
- Tablolar sayfa içerisinde sola yaslı olmalıdır
- Tablo açıklama metni tablo üstünde ve sola yaslı olmalıdır.

6. Kaynaklar

- Bitirme projesinde hazırlanmasında yararlanılan kaynaklar, metin içerisinde kullanım sırasına göre rapor sonunda ve “Kaynaklar” başlığı altında sıra numaraları verilerek listelenecektir.

Proje çalışmalarınızda başarılar...

İçindekiler

1.Projenin Konusu ve Özgün Değeri.....	4
2.Projenin Amacı ve Hedefi.....	5
3.Projenin İş-Zaman Çizelgesi.....	6
4.Projede Kullanılan Donanımlar ve Yazılımlar ile İlgili Bilgiler	9
4.1. Donanımlar.....	9
4.2. Yazılımlar.....	9
5.Projenin Yapım Aşamaları.....	9
Kaynaklar.....	10

1. Proje Konusunun Önemi ve Özgün Değeri

Günümüzde bilgi teknolojilerindeki hızlı gelişim ve dijitalleşmenin yaygınlaşması, finansal işlemlerin büyük ölçüde elektronik ortamlara taşınmasına neden olmuştur. Bu dönüşümün en önemli unsurlarından biri kredi kartlarıdır. Kredi kartları, sundukları kullanım kolaylığı ve hızlı işlem imkânı sayesinde hem çevrim içi alışverişlerde hem de fiziksel mağazalarda en yaygın kullanılan ödeme araçları arasında yer almaktadır. Ancak kredi kartı kullanımının bu denli artması, beraberinde ciddi güvenlik risklerini de getirmiştir. Kredi kartı dolandırıcılığı, kart bilgilerinin kullanıcıdan habersiz şekilde ele geçirilmesi ve bu bilgilerin yetkisiz kişiler tarafından kullanılması sonucu ortaya çıkan bir siber suç türüdür. Bu tür dolandırıcılık faaliyetleri, bireysel kullanıcılar için maddi kayıplara yol açmakla kalmamakta, aynı zamanda bankalar, ödeme kuruluşları ve finansal sistemler için de büyük ekonomik zararlara neden olmaktadır. Finans sektöründe yaşanan bu kayıplar, müşteri güveninin azalmasına ve kurumların itibar kaybına yol açabilmektedir. Bu nedenle kredi kartı dolandırıcılığının önlenmesi, günümüz finansal sistemleri açısından kritik bir öneme sahiptir. Geleneksel dolandırıcılık tespit yöntemleri genellikle önceden tanımlanmış kurallar ve eşik değerler üzerinden çalışmaktadır. Bu yöntemler belirli dolandırıcılık senaryolarında etkili olabilse de, saldırganların sürekli olarak yöntem değiştirmesi ve daha karmaşık dolandırıcılık teknikleri geliştirmesi karşısında yetersiz kalmaktadır. Sabit kurallara dayalı sistemler, yeni ve daha önce karşılaşılmamış dolandırıcılık türlerini tespit etmekte zorlanmakta ve yüksek oranda yanlış alarm üretme riski taşımaktadır. Bu noktada makine öğrenmesi tabanlı yaklaşımlar önemli bir çözüm alternatifi sunmaktadır. Makine öğrenmesi, büyük hacimli veriler içerisindeki karmaşık ilişkileri ve örüntüleri otomatik olarak öğrenebilme yeteneğine sahiptir. Kredi kartı işlemlerine ait geçmiş veriler kullanılarak eğitilen makine öğrenmesi modelleri, normal işlem davranışlarını öğrenebilmekte ve bu davranışlardan sapma gösteren şüpheli işlemleri yüksek doğrulukla tespit edebilmektedir. Ayrıca bu yöntemler, zaman içerisinde yeni verilerle güncellenerek değişen dolandırıcılık yöntemlerine uyum sağlayabilmektedir. 6 Bu proje kapsamında, makine öğrenmesi teknikleri kullanılarak kredi kartı işlemlerinde dolandırıcılığın tespit edilmesi amaçlanmaktadır. Gerçek dünya verilerini içeren bir veri seti üzerinde gerçekleştirilecek analizler sayesinde, dolandırıcılık tespitinde karşılaşılan sınıf dengesizliği gibi önemli problemler ele alınacak ve farklı makine öğrenmesi algoritmalarının performansları karşılaştırılacaktır. Böylece, finansal sistemlerde güvenliğin artırılmasına katkı sağlayabilecek, etkin ve güvenilir bir dolandırıcılık tespit yaklaşımı ortaya konulması hedeflenmektedir.

Özgün Değer

Kredi kartı dolandırıcılığı tespitinde makine öğrenmesi yöntemleri son yıllarda akademik çalışmalarda ve gerçek dünya uygulamalarında yaygın olarak kullanılmaktadır. Bununla birlikte, bu alandaki en temel ve zorlayıcı problemlerden biri kullanılan veri setlerinin aşırı derecede dengesiz olmasıdır. Gerçek hayatta gerçekleştirilen kredi kartı işlemlerinin büyük bir çoğunluğu normal işlemlerden oluşmakta, dolandırıcılık işlemleri ise toplam işlemlerin çok küçük bir yüzdesini temsil etmektedir. Bu durum, geliştirilen makine öğrenmesi modellerinin dolandırıcılık sınıfını yeterince öğrenmesini zorlaştırmakta ve yanlış sonuçlar üretmesine neden olabilmektedir. Dengesiz veri problemi, özellikle yalnızca doğruluk (accuracy) metriğine dayalı değerlendirmelerde yanıltıcı sonuçlar ortaya çıkarabilmektedir. Örneğin, bir model tüm

işlemleri “normal” olarak sınıflandırsa bile yüksek doğruluk elde edebilmekte, ancak dolandırıcılık işlemlerini tespit etme konusunda başarısız olabilmektedir. Bu nedenle kredi kartı dolandırıcılığı gibi kritik güvenlik problemlerinde, model performansının daha anlamlı ve detaylı metrikler ile değerlendirilmesi gerekmektedir. Bu proje kapsamında, Kaggle platformunda yer alan ve gerçek dünya kredi kartı işlemlerini içeren “Credit Card Fraud Detection” veri seti kullanılacaktır. Veri setinin dengesiz yapısı göz önünde bulundurularak, veri ön işleme sürecinde uygun teknikler uygulanacak ve bu problemin model performansı üzerindeki etkileri incelenecektir. Ayrıca, farklı makine öğrenmesi algoritmaları kullanılarak modeller eğitilecek ve bu modellerin dolandırıcılık tespiti konusundaki başarıları karşılaştırmalı olarak değerlendirilecektir. Projenin özgün değeri; yalnızca bir makine öğrenmesi modeli geliştirmekle sınırlı kalmayıp, dengesiz veri problemi çerçevesinde farklı yaklaşımların etkilerini analiz etmesi, performans değerlendirmesinde doğruluk metriği yerine precision, recall ve F1-score gibi daha anlamlı ölçütlere odaklanmasıdır. Bu yaklaşım sayesinde, kredi kartı dolandırıcılığı tespitinde gerçek hayata daha yakın, güvenilir ve uygulanabilir sonuçlar elde edilmesi hedeflenmektedir.

2.Projenin Amacı ve Hedefi

Bu proje kapsamında, kredi kartı işlemlerine ait veriler kullanılarak makine öğrenmesi tabanlı bir kredi kartı dolandırıcılığı tespit sistemi geliştirilmesi amaçlanmaktadır. Araştırma sürecinde, literatürde yer alan kredi kartı dolandırıcılığı tespiti çalışmalarında kullanılan yöntemler incelenecek, gerçek dünya verilerini içeren ve dengesiz sınıf dağılımına sahip bir veri kümesi üzerinde uygun veri ön işleme teknikleri uygulanacaktır. Elde edilen veriler kullanılarak farklı makine öğrenmesi algoritmaları ile modeller oluşturulacak ve bu modellerin dolandırıcılık işlemlerini tespit etme başarıları karşılaştırmalı olarak değerlendirilecektir. Geliştirilecek olan makine öğrenmesi tabanlı dolandırıcılık tespit sisteminin, literatürde önerilen benzer yaklaşımlara kıyasla dolandırıcılık işlemlerini daha doğru ve güvenilir bir şekilde tespit edebilmesi, özellikle erken aşamada şüpheli işlemleri belirleyerek finansal kayıpların azaltılmasına katkı sağlaması hedeflenmektedir. Proje sonunda elde edilecek sistemin, bankacılık ve finans sektöründe kullanılabilecek nitelikte, ölçeklenebilir ve gerçek hayattaki dolandırıcılık senaryolarına uyum sağlayabilen bir yapı sunması amaçlanmaktadır.

3.Projenin iş-zaman çizelgesi

Projede yer alacak başlıca iş paketleri (İP) ve hedefleri, her bir iş paketinin hangi sürede gerçekleştirileceği, başarı ölçütü ve projenin başarısına katkısı “İş-Zaman Çizelgesi” doldurularak verilir.

İP. No.	İş Paketlerinin Adı ve Hedefleri	Zaman Aralığı (Haftalık)	Başarı Ölçütü
1	Veri Setinin Hazırlanması ve Keşifsel Analiz: Literatürde sıklıkla kullanılan (örneğin Kaggle - Credit Card Fraud Detection) veri seti temin edilecektir. Bu iş paketinde, ham verinin yapısı incelenecek, dolandırıcılık (fraud) ve normal işlemler arasındaki sınıf dağılımı analiz edilecektir. Veri setinin modellemeye giriş olarak alınabilmesi için eksik veri kontrolü yapılacak ve tüm verilerin tek bir standart formatta (dataframe) hazırlanması hedeflenmektedir.	1. hafta	Veri seti için ortak bir yapı belirlenmesi ve araştırma aşamasında kullanılacak olan verilerin modellemeye hazır hale getirilmesi gerekmektedir. Dolandırıcılık ve normal işlem etiketlerinin doğru ayrıştırılması, veri ön işleme aşaması için önem arz etmektedir. Veri setinin hazırlanması iş paketinin araştırmanın başarısına katkısı %10 oranındadır.
2	Veri Normalizasyonu ve Ölçeklendirme: Kullanılacak olan kredi kartı veri kümelerinde "Tutar" (Amount) ve "Zaman" (Time) gibi nitelikler çok farklı sayısal aralıklarda bulunmaktadır. Makine öğrenmesi aşamasına geçmeden önce bu değerlerin ortak bir aralığa (örneğin 0-1 arası veya standart sapma bazlı) dönüştürülmesi gerekmektedir. Bu iş paketinde, modelin sapma yapmasını engellemek için gerekli normalizasyon yöntemleri (Min-Max Scaling, Robust Scaler vb.) ile veriler belirli aralıklarda normalize edilecektir.	2. ve 3. Haftalar	Kredi kartı veri kümelerinde nitelikler farklı tiplerde ve çok geniş değer aralıklarında bulunmaktadır. Sağlam ve başarılı bir dolandırıcılık tespit sistemi geliştirebilmek için eğitim ve test aşamasında kullanılacak verilerin makine öğrenmesi algoritmalarına uygun formatta gelmesi büyük önem arz etmektedir. Bu sebeplerden dolayı veri normalizasyonu iş paketinin araştırmanın başarısına katkısı %10 oranındadır.
3	Dengesiz Veri (Imbalance) Çözümü ve Örneklem: Kredi kartı dolandırıcılığı verilerinde, dolandırıcılık işlemleri normal işlemlere göre çok az sayıdadır (dengesiz dağılım). Bu durum makine öğrenmesi algoritmalarının sınıflandırma başarısını düşürür. Bu iş paketinde, SMOTE (Synthetic Minority Over-sampling Technique) gibi yöntemlerle azınlık sınıfı artırılacak veya "Undersampling" ile çoğunluk sınıfı azaltılarak veri seti daha dengeli ve anlamlı hale getirilecektir.	4., 5. ve 6. Haftalar	Dengesiz veri setleri, algoritmaların sürekli "normal" işlem tahmini yapmasına ve dolandırıcılığı kaçırmasına sebep olmaktadır. Bu iş paketinde sınıf dengesizliğinin giderilmesi, modelin dolandırıcılık sınıfını öğrenebilmesi için kritiktir. Bundan dolayı veri dengeleme ve örneklem iş paketinin araştırmanın başarısına katkısı %10 oranındadır.
4	**Özellik Seçimi (Feature Selection):** Kullanılacak olan veri kümelerinde dolandırıcılık tespitine katkısı	7., 8. ve 9.	Araştırma esnasında geliştirilecek olan sistemin başarısı, doğru öz niteliklerin seçimi ile doğru orantılıdır. Özellik

İP. No.	İş Paketlerinin Adı ve Hedefleri	Zaman Aralığı (Haftalık)	Başarı Ölçütü
	olmayan veya gürültü yaratan öznitelikler bulunabilmektedir. Her işlem özniteliğinin sınıflandırmada etkisi birbirinden farklı olabilmektedir. Bu öznitelikler hem makine öğrenmesi algoritmasının çalışma zamanını yükseltmekte hem de başarısının düşmesine sebep olabilmektedir. Bu sebeple literatürde kullanılan özellik seçme algoritmalarının (PCA, Korelasyon Matrisi vb.) kullanılarak dolandırıcılık tespiti için en kritik öznitelik vektörlerinin oluşturulması hedeflenmektedir.	Haftalar	seçimi işlemi hem veri setlerini basitleştirirken hem de makine öğrenmesi algoritmasının hızlı ve başarılı çalışmasını sağlamaktadır. Gereksiz verilerin elenmesi ile daha modüler bir tespit sistemi geliştirilmesi, araştırmanın başarısını artıracaktır. Bu sebeplerden dolayı özellik seçimi iş paketinin araştırmanın başarısına katkısı %20 oranındadır.
5	Makine Öğrenmesi Modellerinin Eğitimi: Veri işleme aşamasından sonra elde edilen öznitelik vektörleri makine öğrenmesi algoritmalarını (Lojistik Regresyon, Random Forest, XGBoost) eğitmek için kullanılacak ve çapraz doğrulama yöntemi ile öğrenme ve doğrulama başarımlarının maksimize edildiği yöntem ve parametrelerin tayin edilmesi hedeflenmektedir.	10., 11. ve 12. Haftalar	Belirli bir dolandırıcılık probleminin makine öğrenmesi algoritmaları ile çözümü için uygun algoritmanın belirlenmesi kadar algoritmanın eğitim kümesinin hazırlanması ve algoritma parametrelerinin optimize edilmesi büyük önem arz etmektedir. Makine öğrenmesi iş paketinde dolandırıcılık tespit modelinin oluşturulmasında benchmark testlerinin yapılması araştırmanın başarıya ulaşması için gereklidir. Bu sebeplerden dolayı makine öğrenmesi iş paketinin araştırmanın başarısına katkısı %35 oranındadır.
6	Doğrulama ve Test: Eğitim sürecinde dışarıda tutulan ve eğitim sürecine dâhil edilmeyen veriler sistemin doğrulanması için kullanılmalı ve doğruluk başarımı (özellikle F1-Score, Recall ve Precision metrikleri ile) gün mertebesine yaklaşılabilecek şekilde artırılması hedeflenmektedir. Ayrıca test verileri üzerinde modelin gerçek zamanlı senaryolara vereceği tepkiler simüle edilerek nihai sonuçlar raporlanacaktır.	13. ve 14. Haftalar	Geliştirilecek olan dolandırıcılık tespit sisteminin bu iş paketinde eğitim aşamasında kullanılmamış olan veriler ile testi yapılacaktır. Test işlemi sonucunda elde edilen doğruluk oranları ve yakalama başarıları (Recall) araştırma projesinin başarısını belirleyecektir. Bu sebeplerden dolayı doğrulama ve test iş paketinin araştırmanın başarısına katkısı %15 oranındadır.

4.Projede kullanılacak yöntem, donanımlar ve yazılımlar ile ilgili bilgiler

Yöntem: Bu proje, gözetimli öğrenme (Supervised Learning) yaklaşımı kullanılarak geliştirilecektir. Kredi kartı dolandırıcılığı veri setlerindeki sınıf dengesizliği problemini gidermek amacıyla SMOTE gibi yeniden örnekleme teknikleri uygulanacaktır. Model performansı, dengesiz veri yapısı göz önünde bulundurularak F1-Score başta olmak üzere precision ve recall metrikleri ile değerlendirilecektir.

Kullanılacak Algoritmalar: Model eğitiminde sınıflandırma başarısını karşılaştırmak için şu algoritmalar kullanılacaktır:

- Lojistik Regresyon (Logistic Regression)
- Rastgele Orman (Random Forest)
- XGBoost

4.1. Donanımlar: Proje geliştirme süreci için kişisel bilgisayar kullanılacaktır.

4.2. Yazılımlar: Projenin geliştirilmesinde Python programlama dili Scikit-learn ve XGBoost kütüphaneleri kullanılacaktır.

5.Projenin yapım aşamaları

1. Hafta yapılanlar:

KREDİ KARTI DOLANDIRICILIĞI TESPİTİ

1.Literatür Taraması

Kredi kartı dolandırıcılığının tespiti, finansal kayıpların önlenmesi açısından büyük önem taşımakta olup, bu alanda yapılan çalışmalar özellikle makine öğrenmesi ve yapay zekâ yöntemlerinin gelişmesiyle birlikte hız kazanmıştır. Geleneksel kural tabanlı yöntemlerin yetersiz kalması, veri odaklı ve öğrenebilen sistemlerin geliştirilmesini gerekli kılmıştır. Bu doğrultuda, literatürde kredi kartı dolandırıcılığı tespitinde çeşitli makine öğrenmesi algoritmalarının kullanıldığı çok sayıda çalışma bulunmaktadır.

Makine öğrenmesi tabanlı yaklaşımlar incelendiğinde, sınıflandırma algoritmalarının dolandırıcılık tespitinde yaygın olarak kullanıldığı görülmektedir. Lojistik Regresyon, Karar Ağaçları, Rastgele Orman, Destek Vektör Makineleri (SVM), Naive Bayes ve K-En Yakın Komşu (KNN) gibi algoritmalar, işlemleri “normal” ve “dolandırıcılık” olarak sınıflandırmada başarılı sonuçlar vermektedir. Özellikle Rastgele Orman ve Karar Ağaçları gibi topluluk öğrenme yöntemleri yüksek doğruluk ve genelleme yetenekleri ile öne çıkarken, Naive Bayes algoritması hızlı çalışmasına rağmen bağımsızlık varsayımı nedeniyle bazı durumlarda daha düşük performans gösterebilmektedir. Ayrıca, dolandırıcılık verilerinin dengesiz yapısı literatürde önemli bir problem olarak ele alınmakta ve bu sorunu gidermek için SMOTE gibi veri dengeleme yöntemleri kullanılmaktadır.

Selimoğlu ve Yılmaz tarafından yapılan çalışmada, kredi kartı dolandırıcılığının tespiti için Çok Katmanlı Yapay Sinir Ağı (MLP) ve Naive Bayes algoritmaları karşılaştırılmıştır. Kaggle veri seti kullanılarak gerçekleştirilen çalışmada, veri setinin %70'i eğitim ve %30'u test için ayrılmıştır. Elde edilen sonuçlara göre, Çok Katmanlı Yapay Sinir Ağı modeli %99,943 doğruluk oranı ile en yüksek performansı gösterirken, Naive Bayes algoritması %98,207 doğruluk oranı elde etmiştir. Bu durum, yapay sinir ağı tabanlı yöntemlerin karmaşık veri yapılarında daha başarılı sonuçlar verebildiğini ortaya koymaktadır [1].

Sarker ve arkadaşları tarafından yapılan daha güncel bir çalışmada ise kredi kartı dolandırıcılığının tespiti için Destek Vektör Makinesi (SVM), Karar Ağaçları, Naive Bayes ve Rastgele Orman algoritmaları karşılaştırılmıştır. Yapılan deneyler sonucunda, özellikle Rastgele Orman algoritmasının %99,96 doğruluk oranı ile en başarılı model olduğu belirlenmiştir. Ayrıca çalışmada doğruluk metriğinin yanı sıra hassasiyet, geri çağırma, F1 skoru ve Matthews korelasyon katsayısı gibi performans ölçütleri de değerlendirilmiştir. Elde edilen bulgular, topluluk öğrenme yöntemlerinin dolandırıcılık tespitinde oldukça etkili olduğunu göstermektedir [2].

Genel olarak literatür incelendiğinde, kredi kartı dolandırıcılığı tespitinde tek bir algoritmanın her durumda en iyi sonucu vermediği görülmektedir. Model performansı; veri setinin yapısı, veri dengesizliği, özellik seçimi ve kullanılan algoritmaya bağlı olarak değişmektedir. Bununla birlikte, yapay sinir ağları ve rastgele orman gibi gelişmiş yöntemlerin yüksek doğruluk oranları ile öne çıktığı dikkat çekmektedir. Bu nedenle, farklı algoritmaların karşılaştırılması ve problem özelinde en uygun modelin belirlenmesi büyük önem taşımaktadır.

Sonuç olarak, makine öğrenmesi ve yapay zekâ teknikleri kredi kartı dolandırıcılığının tespitinde güçlü ve etkili çözümler sunmaktadır. Literatürdeki çalışmalar, bu alanda özellikle derin öğrenme ve hibrit modellerin gelecekte daha fazla önem kazanacağını göstermektedir.

VERİ ÖN İŞLEME VE İSTATİSTİKSEL ANALİZ RAPORU

1. Giriş

Finansal sistemlerde kredi kartı dolandırıcılığı, hem bireysel kullanıcılar hem de finans kuruluşları açısından ciddi ekonomik kayıplara yol açmaktadır. Bu nedenle dolandırıcılık işlemlerinin erken ve doğru tespiti kritik öneme sahiptir.

Makine öğrenmesi tabanlı dolandırıcılık tespit sistemlerinin başarısı büyük ölçüde veri kalitesine ve uygulanan ön işleme (data preprocessing) adımlarına bağlıdır. Ham verinin doğrudan modele verilmesi; yanlış örüntü öğrenimi, değişken baskınlığı ve düşük genelleme performansı gibi problemlere yol açabilmektedir.

Bu çalışmada kredi kartı işlemlerine ait veri seti üzerinde kapsamlı bir veri ön işleme ve istatistiksel analiz süreci gerçekleştirilmiş; veri temizleme, ölçekleme, gürültü giderme ve sınıf dengesizliği probleminin çözümüne yönelik yöntemler uygulanmıştır.

2. Veri Setinin Genel Özellikleri

Çalışmada kullanılan veri seti aşağıdaki özelliklere sahiptir:

- **Toplam işlem sayısı:** 284.807
- **Bağımsız değişken sayısı:** 30
- **Hedef değişken:** 1 (Class)

2.1 Hedef Değişken (Class)

Değer	Anlam
0	Normal işlem
1	Dolandırıcılık (Fraud) işlemi

Veri seti ciddi şekilde dengesizdir:

İşlem Türü Kayıt Sayısı

Normal	284.315
Fraud	492

Dolandırıcılık işlemleri toplam verinin yaklaşık %0.17'sini oluşturmaktadır. Bu durum makine öğrenmesi açısından Imbalanced Dataset problemi yaratmaktadır.

Imbalanced Dataset (Dengesiz Veri Seti), bir veri setinde bulunan sınıfların (class'ların) sayıca birbirine eşit olmaması durumudur.

Makine öğrenmesinde sınıflandırma problemlerinde veriler genellikle farklı kategorilere ayrılır. Eğer bu kategorilerden biri diğerine göre çok daha fazla sayıda örnek içeriyorsa, bu veri seti:

Imbalanced (dengesiz) veri seti olarak adlandırılır.

Bu dengesizlik:

- Modelin sürekli "normal" tahmini yapmasına
- Fraud sınıfını öğrenememesine
- Accuracy metriğinin yanıltıcı olmasına

Accuracy, bir makine öğrenmesi modelinin yaptığı tahminlerin ne kadarının doğru olduğunu gösteren en temel performans ölçütüdür. $Accuracy = \text{Doğru tahmin sayısı} / \text{toplam tahmin sayısı}$

Yani modelin doğru bildiği işlemlerin tüm işlemlere oranıdır.

İkili sınıflandırmada (Normal / Fraud) tahminler 4 gruba ayrılır:

Gerçek Durum	Model Tahmini	Adı
Fraud	Fraud	True Positive (TP)
Normal	Normal	True Negative (TN)
Normal	Fraud	False Positive (FP)
Fraud	Normal	False Negative (FN)

Accuracy bu değerlerle şöyle hesaplanır:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

neden olabilir.

Neden Problem Oluşturur?

Makine öğrenmesi algoritmaları veriden örüntü öğrenir. Ama veri dengesiz olunca model şu hataya düşer: Çoğunluk sınıfını ezberlemek daha “kolay” olduğu için azınlık sınıfını öğrenmez

imbalanced Dataset'in Etkileri

Dengesiz veri şu sorunlara yol açar:

- Model Azınlık Sınıfını Öğrenemez Fraud işlemler çok az olduğu için model onları “önemsiz” sanır.
- Accuracy Yanıltıcı Olur

Accuracy yüksek çıkar ama model işe yaramaz.


- Overfitting Majority Class’a Oluşur

Model sadece normal işlemleri öğrenir.

Overfitting, modelin eğitim verisine aşırı uyum sağlayarak genelleme yeteneğini kaybetmesidir. Bu çalışmada gürültü değişkenlerinin kaldırılması, PCA dönüşümü ve normalizasyon işlemleri uygulanarak overfitting riski azaltılmıştır.

Fraud Detection Sistemleri Çalışmaz

Gerçek hayatta en kritik olan fraud yakalama başarısı düşer. Bu nedenle veri dengeleme teknikleri uygulanması gereklidir.



Makine Öğrenmesi Modeli Sınıflandırma Performansı ve Karmaşıklık Matrisi Analizi

Görselin Tanımı ve Amacı: Sunulan **Karmaşıklık Matrisi (Confusion Matrix)**, geliştirilen ikili sınıflandırma modelinin test veri seti üzerindeki tahmin başarısını detaylı olarak analiz etmek amacıyla oluşturulmuştur. Matris, modelin yaptığı tahminleri gerçek durumlar ile karşılaştırarak dört farklı senaryo üzerinden performans değerlendirmesi yapılmasına olanak tanır.

Özellikle dolandırıcılık tespiti gibi **dengesiz veri setlerinde (imbalanced datasets)**, tek başına "Doğruluk" (Accuracy) metriği modelin başarısını ölçmekte yetersiz kalmaktadır. Bu nedenle, modelin hangi tür hataları yaptığı (yanlış alarm mı, kaçırılan dolandırıcılık mı?) bu matris üzerinden incelenmiştir.

Matris Bileşenlerinin Proje Bağlamındaki Analizi:

1. **True Positive (TP - Doğru Pozitif):**
 - **Tanım:** Gerçekte **Dolandırıcılık (Fraud)** olan bir işlemin, model tarafından da başarılı bir şekilde **Fraud** olarak tespit edilmesidir.
 - **Proje Önemi:** Sistemin temel başarı kriteridir. Bu değerin yüksek olması, modelin dolandırıcılık girişimlerini yakalama yeteneğinin (Recall/Duyarlılık) yüksek olduğunu gösterir.
2. **True Negative (TN - Doğru Negatif):**

- **Tanım:** Gerçekte **Normal** olan bir işlemin, model tarafından doğru bir şekilde **Normal** olarak sınıflandırılmasıdır.
 - **Proje Önemi:** Müşteri deneyimi açısından kritiktir. Normal işlemlerin sorunsuz devam etmesini sağlar. Görseldeki sarı/açık renkli yoğun alanın (genellikle sol üst köşe) bu sınıfı temsil etmesi, sistemin normal işlemleri ayırt etmede yüksek başarı gösterdiğini kanıtlar.
3. **False Positive (FP - Yanlış Pozitif / Tip 1 Hata):**
- **Tanım:** Gerçekte **Normal** olan bir işlemin, model tarafından hatalı bir şekilde **Dolandırıcılık** olarak işaretlenmesidir.
 - **Risk:** "Yanlış Alarm" durumudur. Banka müşterisinin kartının gereksiz yere bloke edilmesine ve müşteri memnuniyetsizliğine yol açar, ancak doğrudan finansal kayıp yaratmaz.
4. **False Negative (FN - Yanlış Negatif / Tip 2 Hata):**
- **Tanım:** Gerçekte **Dolandırıcılık (Fraud)** olan bir işlemin, model tarafından kaçırılarak hatalı bir şekilde **Normal** olarak sınıflandırılmasıdır.
 - **Risk:** Finansal sistemler için **en kritik ve maliyetli hatadır**. Modelin tehdidi algılayamaması sonucunda banka ve müşteri doğrudan maddi zarara uğrar. Bu projede amaç, Accuracy değerini maksimize etmekten ziyade, bu karedeki (FN) hata oranını minimize etmektir.



Veri Setindeki Sınıf Dağılımının Histogram Analizi (Normal İşlem vs. Dolandırıcılık)

Görsel Analizi ve Problem Tanımı:

Grafik, projede kullanılan veri setindeki hedef değişkenin (Class) sınıflar arasındaki dağılımını görselleştirmektedir. x-ekseni işlem sınıflarını (0: Normal, 1: Fraud), y-ekseni ise ilgili sınıfa ait örneklem sayısını (frekans) ifade etmektedir.

Grafik incelendiğinde, sınıflar arasında şiddetli bir asimetri olduğu görülmektedir:

- **Sınıf 0 (Normal İşlemler):** Toplam 284.315 adet kayıt ile veri setinin %99.83'ünü oluşturmaktadır.
- **Sınıf 1 (Dolandırıcılık İşlemleri):** Yalnızca 492 adet kayıt ile veri setinin %0.17'sini oluşturmaktadır.


İstatistiksel Değerlendirme:

Bu tablo, literatürde "**Aşırı Dengesiz Veri Seti**" (**Highly Imbalanced Dataset**) olarak tanımlanan yapısal probleme işaret etmektedir. Dolandırıcılık (Fraud) sınıfının görselde neredeyse hiç görünmemesi, normal işlemlerin sayısal baskınlığını (dominance) kanıtlar niteliktedir.

Makine Öğrenmesi Üzerindeki Olası Etkileri:

Bu yapısal dengesizlik, veri ön işleme adımlarında müdahale edilmediği takdirde, geliştirilecek makine öğrenmesi modellerinde aşağıdaki problemlere yol açma riski taşımaktadır:

1. **Çoğunluk Sınıfı Yanlılığı (Majority Class Bias):** Standart makine öğrenmesi algoritmaları, genel hata oranını minimize etmeye odaklanır. Veri setinin %99'undan fazlası "Normal" olduğu için, model istatistiksel olarak en güvenli yol olan "tüm işlemleri normal olarak tahmin etme" eğilimine girecek ve dolandırıcılık örüntülerini öğrenmeyi ihmal edecektir.
2. **Doğruluk Paradoksu (Accuracy Paradox):** Model, tek bir dolandırıcılık işlemini dahi yakalayamasa (yani Recall = 0 olsa) bile, matematiksel olarak %99.83 gibi yanıltıcı derecede yüksek bir doğruluk (Accuracy) skoru üretecektir. Bu durum, model performansının yanlış yorumlanmasına neden olabilir.




1. Normal İşlemlerde Tutar Dağılımı (Amount Distribution - Normal Transactions)

Grafik Analizi ve Gözlemler:

Normal işlemlere ait ölçeklendirilmiş tutar dağılımını gösteren histogram incelendiğinde, verinin **aşırı sağa çarpık (highly right-skewed)** bir asimetri sergilediği açıkça görülmektedir.

- **Merkezi Yoğunlaşma:** Frekansın en yüksek olduğu bölge, ölçeklendirilmiş değerlerin 0.00 ile 0.10 arasında olduğu aralıktır. Bu durum, veri setindeki meşru işlemlerin çok büyük bir çoğunluğunun düşük ve standart günlük harcama tutarlarından oluştuğunu kanıtlamaktadır.
- **Kuyruk Yapısı (Tail):** Sağ eksene doğru uzanan ince uzun kuyruk, frekansı çok düşük olmasına rağmen parasal değeri çok yüksek olan işlemlerin (outlier/uç değerler) varlığını göstermektedir. Ölçeklendirilmiş değerlerin 1.0 noktasına kadar uzanması, global maksimum değer bu sınıf içerisinde yer aldığını belirtmektedir.



2. Dolandırıcılık İşlemlerinde Tutar Dağılımı (Amount Distribution - Fraud Transactions)

Grafik Analizi ve Gözlemler:

Dolandırıcılık (Fraud) sınıfına ait tutar dağılımı histogramı incelendiğinde, normal işlemlere benzer şekilde **sağa çarpık (right-skewed)** bir karakteristiğin korunduğu tespit edilmiştir.

- **Dağılım Farklılığı:** Dolandırıcılık işlemleri de ağırlıklı olarak düşük tutarlı bölgelerde (0.00 - 0.05 arası) yoğunlaşmaktadır. Ancak, normal işlemlere kıyasla x-eksenindeki maksimum yayılım yaklaşık 0.35 - 0.40 bandında kesilmektedir. Bu durum, tespit edilen dolandırıcılık işlemlerinin, veri setindeki en yüksek normal işlem tutarlarına erişmediğini göstermektedir.
- **Frekans Oranı:** y-eksenindeki maksimum frekans değerinin yaklaşık 300 civarında olması, veri setindeki şiddetli sınıf dengesizliğinin (imbalance) doğal bir yansımasıdır.

3. PCA Uygulanan Değişkenler (V1–V28)

Veri setindeki V1–V28 değişkenleri orijinal finansal özellikler değildir. Bu değişkenler veri sağlayıcı tarafından **Principal Component Analysis (PCA)** yöntemi ile dönüştürülmüştür.

3.1 PCA'nın Tanımı

PCA, çok boyutlu veriyi daha az boyutlu, birbirinden bağımsız ve maksimum varyans taşıyan yeni bileşenlere dönüştüren istatistiksel bir yöntemdir.

Matematiksel olarak PCA:

- En yüksek varyansı taşıyan doğrultuları belirler,
- Yeni eksenler (principal components) oluşturur,
- Orijinal değişkenleri bu eksenlere projekte eder.

3.2 PCA'nın Kullanım Amaçları

- Kullanıcı gizliliğini korumak
- Değişkenler arası korelasyonu ortadan kaldırmak
- Boyut indirgeme sağlamak
- Gürültüyü azaltmak
- Model performansını artırmak

3.3 PCA Sonrası Özellikler

PCA uygulanmış değişkenlerde teorik olarak:

- Ortalama ≈ 0
- Standart sapma ≈ 1
- Bileşenler birbirinden bağımsızdır

Yapılan istatistiksel analizler sonucunda V1–V28 değişkenlerinin bu özellikleri sağladığı gözlemlenmiştir. Bu nedenle bu değişkenler için ek bir standardizasyon işlemine ihtiyaç duyulmamıştır.

4. GitHub Proje Paylaşımı

Proje kapsamında geliştirilen tüm kodlar, veri ön işleme çalışmaları, model eğitim dosyaları, deney sonuçları ve rapor içerikleri GitHub platformuna yüklenmiştir. Böylece proje geliştirme süreci düzenli şekilde takip edilmiş ve proje çıktılarının erişilebilirliği sağlanmıştır.

GitHub deposunda aşağıdaki içerikler yer almaktadır:

- Veri ön işleme (data preprocessing) kodları
- SMOTE veri dengeleme uygulamaları

- Logistic Regression, Random Forest ve XGBoost model kodları
- Eğitim ve test performans analizleri
- Deney sonuç tabloları
- Rapor ve proje dokümantasyon dosyaları

Proje GitHub bağlantısı:

<https://github.com/sultan-yuvali/Makine-Ogrenmesi-Kullanilarak-Kredi-Karti-Dolandiriciligi-Tespiti.git>

GitHub kullanımı sayesinde proje sürüm kontrolü sağlanmış, yapılan geliştirmeler düzenli şekilde yönetilmiş ve proje çıktılarının paylaşılabiliirliği artırılmıştır.

2. Ve 3. Haftalarda yapılanlar :

1. Time Değişkeninin Veri Setinden Çıkarılması

Time değişkeni, işlemin veri setindeki ilk işlemten itibaren geçen süreyi saniye cinsinden göstermektedir.

Ancak bu değişken:

- Finansal davranışı temsil etmez
- Dolandırıcılık mantığı ile doğrudan ilişkili değildir
- Tahmin gücü düşüktür
- Modele gürültü ekleyebilir

1.1 Gürültü (Noise) Kavramı

Makine öğrenmesinde gürültü; anlamlı bilgi taşımayan ve modelin yanlış örüntüler öğrenmesine sebep olan değişkenleri ifade eder.

Time değişkeni modele bırakıldığında:

- Sahte zaman temelli örüntüler öğrenilebilir
- Overfitting riski artabilir
- Model genelleme yeteneği azalabilir

Bu nedenlerle Time değişkeni veri setinden tamamen çıkarılmıştır.

2. Amount Değişkeninin Normalizasyonu

V1–V28 değişkenleri PCA sonrası ölçeklenmiş yapıdadır. Ancak **Amount** değişkeni gerçek parasal değeri temsil etmekte ve geniş aralıkta değişmektedir.

Örnek değerler:

- 5 TL
- 500 TL
- 25.000 TL

Bu durum modelde değişken baskınlığına neden olabilir.

2.1 Uygulanan Yöntem: Min-Max Normalizasyonu

Kullanılan formül:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Formüldeki Terimler:

- X → Orijinal değer
- X_{min} → İlgili değişkenin minimum değeri
- X_{max} → İlgili değişkenin maksimum değeri
- X_{norm} → Normalize edilmiş değer

Sonuç olarak:

Normalizasyon sonrası değişkenin aralığı

$$0 \leq Amount_{norm} \leq 1$$

2.2 Normalizasyonun Avantajları

- Tüm değişkenler eşit ölçeğe gelir
- Öğrenme dengelenir
- Algoritmalar daha stabil çalışır
- Eğitim süresi azalır

- Model performansı artar

3. Veri Dengesizliği Problemi

Fraud işlemlerin oranı oldukça düşüktür (%0.17).

Bu durumda model tüm işlemleri “normal” olarak öğrenebilir ve yüksek doğruluk oranı elde etmesine rağmen fraud tespitinde başarısız olabilir.

4. Kullanılan Yöntem: Undersampling

Bu çalışmada yalnızca **Undersampling** yöntemi uygulanmıştır.

4.1 Undersampling Tanımı

Çoğunluk sınıfından rastgele örnek seçilerek veri dengelenir.

Bu çalışmada:

- Fraud verilerinin tamamı korunmuştur
- Normal işlemler rastgele azaltılmıştır

4.2 Amaç

- Yapay veri üretmemek
 - Gerçek dağılımı korumak
 - Fraud işlemlerin öğrenilmesini sağlamak
 - Hesaplama maliyetini azaltmak
-

5. İstatistiksel Veri Analizi

Veri dağılımı ortalama, standart sapma ve Z-skoru analizleri ile incelenmiştir.

5.1 Ortalama (Mean)

Doğru Formül:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

Açıklama:

- $\mu \rightarrow$ Aritmetik ortalama
- $n \rightarrow$ Gözlem sayısı
- $x_i \rightarrow$ i'inci gözlem değeri

Ortalama, veri setinin merkezi eğilimini gösterir.

Bu Çalışmada:

PCA uygulanmış V1–V28 değişkenlerinde ortalama değerlerin 0'a çok yakın olduğu gözlemlenmiştir.

Bu durum, PCA dönüşümü sırasında verinin **merkezlendiğini (mean-centered)** göstermektedir.

5.2 Standart Sapma (Standard Deviation)

Önce varyans tanımlanır:

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2$$

Standart sapma ise varyansın kareköküdür:

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

Açıklama:

- $\sigma \rightarrow$ Standart sapma
- $\mu \rightarrow$ Ortalama
- $(x_i - \mu)^2 \rightarrow$ Ortalama etrafındaki sapmanın karesi

Standart sapma, verinin ortalama etrafında ne kadar yayıldığını ölçer.

Bu Çalışmada:

PCA bileşenlerinde standart sapmanın yaklaşık 1 olduğu gözlemlenmiştir.

Bu durum PCA dönüşümünün yalnızca merkezleme değil aynı zamanda ölçekleme (variance normalization) işlemini de içerdiğini göstermektedir

5.3 Z-Skoru (Standard Score)

Doğru Formül:

$$Z = \frac{x - \mu}{\sigma}$$

Açıklama:

- $x \rightarrow$ İlgili gözlem değeri
- $\mu \rightarrow$ Ortalama
- $\sigma \rightarrow$ Standart sapma
- $Z \rightarrow$ Standartlaştırılmış değer

Z-skoru, bir gözlemin ortalamadan kaç standart sapma uzaklıkta olduğunu gösterir.

6. İstatistiksel Özet Tablosu

Değişken Grubu	Ortalama	Standart Sapma	Z-Skoru Analizi	Teknik Yorum
V1 – V28	≈ 0	≈ 1	Büyük çoğunluk ± 3 aralığındadır.	PCA (Temel Bileşenler Analizi) ile standardize edilmiştir.
Amount (Tutar)	Değişken	Yüksek (Önce)	Normalizasyon sonrası ± 3 aralığındadır.	Min-Max normalizasyonu uygulanarak ölçeklendirilmiştir.
Class (Hedef)	0'a yakın	Dengesiz Dağılım	Kategorik olduğu için Z-skoru anlamlı değildir.	Bağımlı (hedef) değişkendir; Fraud/Normal ayrımını içerir.

Açıklama

- **V1–V28 değişkenleri** PCA sonrası zaten ortalaması 0 ve standart sapması 1 olan standardize edilmiş bileşenlerdir. Bu nedenle Z-skoru dağılımı doğal olarak ± 3 aralığında yoğunlaşmaktadır.
- **Amount değişkeni** normalizasyon öncesi yüksek varyansa sahipken, Min-Max dönüşümü sonrası ölçek problemi ortadan kaldırılmıştır.
- **Class değişkeni** kategorik (binary) olduğu için klasik Z-skoru yorumu uygulanmaz; istatistiksel yayılım analizi yerine sınıf oranı değerlendirilir.

7. Ön İşleme Sonrası Veri Yapısı

Uygulanan işlemler sonucunda veri:

- Gürültüden arındırılmış
- Ölçek uyumu sağlanmış
- Dengelenmiş

- Yapay veri içermeyen
 - Gerçek dağılımı koruyan
 - Makine öğrenmesi için uygun hale getirilmiş
-

8. Sonuç

Bu çalışmada kredi kartı dolandırıcılığı veri seti üzerinde kapsamlı bir veri ön işleme süreci yürütülmüştür.

- PCA yapısı analiz edilmiştir.
- Gürültü oluşturan Time değişkeni çıkarılmıştır.
- Amount değişkeni Min-Max yöntemi ile normalize edilmiştir.
- Veri istatistiksel olarak incelenmiştir.
- Yapay veri üretmeden undersampling ile dengeleme yapılmıştır.

Sonuç olarak oluşturulan veri yapısı, gerçek dünya koşullarına uygun, güvenilir ve genellenebilir makine öğrenmesi modellerinin eğitimi için uygun hale getirilmiştir.

4, 5. ve 6. Haftalarda yapılanlar:

KREDİ KARTI DOLANDIRICILIĞI TESPİTİNDE SINIF DENGESİZLİĞİNİN MODEL PERFORMANSINA ETKİSİ: KONTROLLÜ HASSASİYET ANALİZİ

1. Çalışmanın Amacı ve Teorik Altyapı

Bu çalışmanın temel amacı, kredi kartı dolandırıcılığı (fraud detection) gibi anomali tespiti problemlerinde kronik bir sorun olan "Sınıf Dengesizliği" (Class Imbalance) probleminin, makine öğrenmesi modellerinin sınıflandırma performansı üzerindeki yıkıcı etkisini deneysel ve kontrollü bir ortamda ispatlamaktır.

Gerçek dünya finansal verilerinde dolandırıcılık işlemleri, meşru (normal) işlemlere kıyasla istatistiksel olarak nadir olaylardır (rare events). Bu durum, literatürde **Dengesizlik Oranı (Imbalance Ratio - IR)** olarak adlandırılan ve aşağıdaki formülle ifade edilen değerin çok yüksek olmasına yol açmaktadır:

Dengesizlik Oranı (Imbalance Ratio)

$$IR = \frac{N_{Normal}}{N_{Fraud}}$$

Bu analiz kapsamında, makine öğrenmesi algoritmalarının veri kalitesinden bağımsız olarak, sadece matematiksel IR değerinin artmasına bağlı olarak dolandırıcılık tespit performansında (Fraud Recall) yaşayacağı "kırılma noktasını" (breaking point) tespit etmek hedeflenmiştir.

2. Deneysel Veri Üretimi ve İstatistiksel Korumalı Örneklem

Modellerin başarısızlığının verinin rastgeleliğinden veya kalitesizliğinden değil, doğrudan sınıf dengesizliğinden kaynaklandığını bilimsel olarak kanıtlamak amacıyla son derece kontrollü bir veri hazırlık süreci yürütülmüştür.

2.1. Sınıf Ayırıştırması ve Referans Dağılımın Belirlenmesi:

Başlangıç aşamasında temizlenmiş veri seti "Fraud" (Class=1) ve "Normal" (Class=0) olarak iki bağımsız alt kümeye ayrılmıştır. Azınlık sınıfı olan Fraud işlemlerinde bilgi kaybı yaşanmaması adına 492 adet işlemin tamamı deney boyunca sabit tutulmuştur. Normal işlemlerin orijinal aritmetik ortalaması ve standart sapması hesaplanarak, oluşturulacak yeni senaryolar için "istatistiksel referans noktası" olarak kaydedilmiştir.

2.2. Dağılım Koruyarak Örneklem (Distribution-Preserving Sampling):

Literatürdeki standart rastgele alt örneklem (random undersampling) yöntemleri, verinin orijinal dağılımını bozma riski taşır. Bu çalışmada verinin istatistiksel genetiğini korumak amacıyla Z-Skoru (Z-score) tabanlı tabakalı bir örneklem algoritması geliştirilmiştir:

1. Normal sınıf verisindeki her bir öznitelik $Z = \frac{X - \mu}{\sigma}$ formülü ile standart normal dağılım uzayına taşınmıştır.
2. Elde edilen Z-skoru değerleri belirli aralıklara bölünmüş ve her iterasyonda çekilecek örneklem bu aralıklardan, orijinal yoğunluğa orantılı olacak şekilde seçilmiştir.
3. Hedeflenen örneklem sayısının ana kütle aştığı senaryolarda iadeli seçim (upsampling / replace=True) yapılarak veri eksikliğinin önüne geçilmiştir.

Bu algoritmik yaklaşım sayesinde, üretilen her bir alt veri setinde istatistiksel bütünlük korunmuş, ortalama ve standart sapmadaki sapmalar minimize edilerek mükemmel bir "kontrollü deney" ortamı yaratılmıştır.

2.3. Dengesizlik Senaryolarının (IR) Oluşturulması:

Fraud sayısı (492) sabit kalmak koşuluyla, Normal işlem sayısı kademeli ve geometrik olarak artırılarak 12 farklı deney veri seti üretilmiştir:

Seçilen Normal İşlem Sayıları: [500, 1000, 1500, 3000, 6000, 12000, 24000, 48000, 50000, 55000, 60000, 96000]

Bu sayede her senaryoda modelin karşısına giderek daha dengesizleşen (IR değeri artan) bir problem sunulmuştur.

Amaç: Modelin farklı IR (Imbalance Ratio) değerlerinde fraud tespit başarısını ölçmek.

Model Performansının Kırılma Noktasını Belirlemek

Modelin fraud recall (fraud tespit oranı) değeri izlendi. Normal veri miktarı arttıkça, modelin azınlık sınıfı öğrenme kapasitesi ne zaman zayıflıyor, hangi IR değerinde performans düşüyor gözlemlendi.

2.4. Dataset Hazırlığı ve IR Analizi

`</> Python`

```
df = pd.read_csv("creditcard_ready.csv")
fraud = df[df["Class"] == 1]
normal = df[df["Class"] == 0]
sizes = [500, 1000, 1500, 3000, 6000, 12000, 24000, 48000, 96000]
```

Dataset'in Okunması (pd.read_csv)

Projemizde kullandığımız veri seti, kredi kartı işlemlerini içeren ve fraud/normal sınıflarını gösteren bir CSV dosyasıdır.

Bu adımda veri seti Python ortamına aktarılır ve DataFrame olarak saklanır.

Fraud ve Normal Verilerin Ayrılması

```
fraud = df[df["Class"] == 1]
```

Fraud (dolandırıcılık) işlemleri filtrelenir.

Bu, azınlık sınıfın sabitlenmesi için önemlidir.

Bu projede fraud sayısı 492 kayıt olarak sabit tutulur.

Böylece modelin performansındaki değişiklikler sadece normal verinin artışından kaynaklanır, fraud sayısının artışı performansı yanıltmaz.

```
normal = df[df["Class"] == 0]
```

Normal (geçerli) işlemler filtrelenir.

Bu, çoğunluk sınıfı oluşturur ve farklı büyüklüklerde senaryolar için örneklenir.

Normal Veri İçin Senaryoların Oluşturulması

```
sizes = [500, 1000, 1500, 3000, 6000, 12000, 24000, 48000, 50000, 55000, 60000, 96000]
```

Normal veri farklı boyutlarda örneklenir; bu sayede IR (Imbalance Ratio = Normal / Fraud) kontrollü olarak artırılır.

Her bir hedef boyut (size), modelin farklı dengesizlik seviyelerinde performansını ölçmek için bir senaryo oluşturur.

Bu Adımın Amacı ve Mantığı

- **Class imbalance etkisini izole etmek:** Fraud sabit, normal veri artırılıyor → modelin azınlık sınıfı öğrenme kapasitesi tek başına test ediliyor.
- **Kontrollü deney tasarımı:** Veri boyutunu adım adım artırmak, modelin performansının hangi noktada düşmeye başladığını (kırılma noktası) görmemizi sağlar.

Bu yaklaşım, veri dengesizliği arttıkça modelin azınlık sınıfı öğrenemediği noktayı belirlemeye olanak tanır.

Bu adımda ortalama, standart sapma ve z-score korunmaz; çünkü bunlar sonraki aşamalarda orantılı örnekleme ve z-score ile dağılım korunarak yapılır.

Buradaki görev temel dataset'i hazırlamak ve senaryoları belirlemektir.

2.5. Dağılım Koruyarak Örnekleme ve Upsampling

</> Python

```
normal_z = normal.copy()
normal_z.iloc[:, :-1] = normal.iloc[:, :-1].apply(zscore)
bins = np.linspace(-4, 4, 60)
```

1. Z-score ile Veri Standartlaştırma

Normal veri z-score uzayına taşındı.

Her özellik için:

$$Z = \frac{x - \mu}{\sigma}$$

Bu işlem, her özelliğin ortalamasını 0, standart sapmasını 1 yapar.

Amaç: Özelliklerin farklı ölçekleri ve dağılımları nedeniyle örneklemenin dengesiz olmasını önlemek.

Örneğin, bir sütun 0–1 arasında, diğeri 0–1000 arasında olabilir.

Z-score ile tüm sütunlar standart hale gelir → tüm gruplar eşit ağırlıkla temsil edilebilir.

2. Binning ile Veriyi Alt Gruplara Ayırma

</> Python

```
bins = np.linspace(-4, 4, 60)
```

- Z-score değerleri -4 ile 4 arasındaki eşit aralıklara bölündü.
- Her bin, belirli bir z-score aralığını temsil eder.
- Böylece örnekleme sırasında veri dağılımı bozulmadan her z-aralığından orantılı sayıda veri alınabilir.

3. Orantılı Örnekleme (Sampling)

</> Python

```
for idx in grouped.groups.values():
    group = normal.loc[idx]
    sampled = group.sample(frac=frac, replace=True/False, random_state=42)
```

- Her bin için, gruptaki verilerden hedef boyuta uygun oranda örnek alındı.

- `frac` → hedef büyüklüğü orijinal grup büyüklüğüne göre ayarlayan oran.

Bu yöntem sayesinde:

- Orijinal verinin ortalaması (mean) ve standart sapması (std) korunur.
- Veri dağılımı bozulmaz, modelin öğrenmesi doğal dağılım üzerinden gerçekleşir.

4. Upsampling ve Downsampling

Upsampling

Hedef boyut, gruptaki veri sayısından büyükse:

- `replace=True` ile veri tekrar seçilerek çoğaltılır.
- Bu işlem, az sayıda veri ile daha büyük bir set oluşturmayı sağlar.

Örnek: 500 veri var, 1000 hedefleniyorsa bazı veriler tekrar seçilir.

Downsampling

Hedef boyut, gruptaki veri sayısından küçükse:

- `replace=False` ile rastgele alt küme seçilir.
- Bu işlem, fazla veriyi hedef boyuta indirir.

5. Sonuç

Bu strateji ile normal sınıfın büyüklüğü artırılırken veri istatistikleri korunur:

- Ortalama ve standart sapma değişmez
- Z-score dağılımı korunur

Böylece modelin performans değişiklikleri veri yapısının bozulmasından değil, class imbalance etkisinden kaynaklanır.

2.6. Fraud ile Birleştirme

`</> Python`

```
df_exp = pd.concat([sampled_normal, fraud])
```

- Fraud sabit tutuldu, yeni normal veriler ile birleştirildi.
- Veriler karıştırıldı, böylece modelin sıralamaya bağımlılığı kaldırıldı.

2.7. İstatistiksel Kontrol

</> Python

```
new_mean = sampled_normal.drop("Class", axis=1).mean()
new_std = sampled_normal.drop("Class", axis=1).std()
print("Mean farkı:", (orig_mean - new_mean).abs().mean())
print("Std farkı :", (orig_std - new_std).abs().mean())
```

- Her senaryoda örneklenen normal verinin ortalama ve standart sapması orijinaliyle karşılaştırıldı.
- Farklar çok küçük çıktı (ortalama farkı ≈ 0.004 , std farkı ≈ 0.009).
- Bu, veri dağılımının korunmuş olduğunu gösteriyor.

2.8. Model Eğitimi ve Performans Ölçümü

1. Kullanılan Modeller

Logistic Regression (LR)

- Lineer bir sınıflandırma modelidir.
- Azınlık sınıf (fraud) üzerinde probabilistik tahminler üretir.
- Basit, hızlı ve yorumlanabilir bir modeldir.

Random Forest (RF)

- Ensemble bir ağaç tabanlı sınıflandırıcıdır.
- Farklı ağaçların çoğunluk oyuna göre sınıf tahmini yapar.
- Karmaşık ilişkileri ve non-lineer örüntüleri öğrenme kapasitesi yüksektir.

İki modelin birden kullanılması, model bağımlılığını azaltır ve farklı algoritmaların class imbalance etkisine tepkisini karşılaştırmayı sağlar.

2. Train-Test Split

</> Python

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)
```

- Veriler eğitim ve test setlerine ayrıldı (%80 eğitim, %20 test).
- `stratify=y` parametresi, fraud ve normal sınıf oranının her iki sette de korunmasını sağlar.

Böylece class imbalance etkisi model performansını doğru şekilde yansıtır.

3. Model Eğitimi ve Tahmin

- Logistic Regression ve Random Forest modelleri eğitim verisi ile öğrenir.
 - Test seti üzerinde tahmin yaparak gerçek veri ile modelin performansı ölçülür.
-

4. Performans Değerlendirme Metrikleri

Sınıf dengesizliği problemlerinde modelin tüm işlemlere "Normal" diyerek %99 Doğruluk (Accuracy) elde etmesi "Doğruluk Paradoksu" olarak adlandırılır ve yanıltıcıdır. Bu nedenle modeller aşağıdaki kritik metriklerle değerlendirilmiştir:

- **Duyarlılık (Recall):**

$$Recall = \frac{TP}{TP + FN}$$

Gerçek dolandırıcılık işlemlerinin ne kadarının yakalandığını gösterir. Finansal sistemlerde kaçırılan bir dolandırıcılığın (False Negative - FN) maliyeti çok yüksek olduğu için projenin en temel başarı ölçütüdür.

- **Kesinlik (Precision):**

$$Precision = \frac{TP}{TP + FP}$$

Modelin "Fraud" olarak işaretlediği işlemlerin yüzde kaçının gerçekten dolandırıcılık olduğunu (yanlış alarm oranını) gösterir.

- **F1-Skoru:**

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Precision ve Recall arasındaki harmonik ortalamadır, dengesiz verilerde model stabilitesini gösterir.

ROC-AUC: ROC-AUC (Receiver Operating Characteristic - Area Under Curve), modelin pozitif (fraud) ve negatif (normal) sınıfları birbirinden ayırt edebilme yeteneğini ölçen bir

performans metriğidir. ROC eğrisi altında kalan alanın hesaplanmasıyla elde edilir. AUC değeri 1'e yaklaştıkça modelin ayırt ediciliği artar.

5. Fraud Recall İzlenmesi

Bu projede en kritik metrik fraud recall'dür, çünkü:

- Amaç azınlık sınıfı (fraud) kaçırmadan tespit etmektir.
- IR (Imbalance Ratio) arttıkça recall değerinde düşüş beklenir; bu modelin kırılma noktasını gösterir.

Diğer metrikler (precision, F1, ROC AUC) da ölçüldü; ancak grafik ve kırılma analizi için recall önceliklidir.

6. Neden Bu Adım Önemli?

- Bu aşama, kontrollü veri büyümesi ile model performansının doğrudan ölçüldüğü deneydir.
 - Fraud sınıfının sabit tutulması sayesinde recall düşüşü yalnızca class imbalance'dan kaynaklanır.
 - Böylece modelin hangi IR değerinde çökme eğilimi gösterdiği bilimsel olarak tespit edilir.
-

2.9. IR Hesaplama ve Analiz

```
<> Python   
df["Normal_Size"] = df["Dataset"].str.extract(r'exp_dist_(\d+)_').astype(int)  
fraud_count = 492  
df["IR"] = df["Normal_Size"] / fraud_count
```

- Imbalance Ratio (IR) = Normal / Fraud
- IR arttıkça fraud recall değerleri izlendi.
- Grafikte modelin hangi IR noktasında “patladığı” (ani performans düşüşü) görüldü.

```
<> Python   
plt.plot(df["IR"], df["LR Recall"], marker='o', label="Logistic Regression")  
plt.plot(df["IR"], df["RF Recall"], marker='s', label="Random Forest")
```

Bu analiz, dengesiz veri setlerinde model seçiminin kritik önem taşıdığını açık biçimde ortaya koymaktadır.

3. Bu Hafta Yapılan İşlemlerin Anlamı

Adım	Yapılan İşlem	Amacı
Dataset ayırma	Fraud ve normal veri ayrıldı	Fraud sabit, normal veri kademeli artacak
Z-score ve bins	Normal veriyi grupladık	Dağılımı koruyarak örnekleme yapmak
Orantılı sampling	Her gruptan hedef oran kadar örnek alındı	Ortalama ve standart sapmayı korumak
Upsampling / Downsampling	Hedef boyuta göre örnekleme	Senaryolara uygun veri büyüklüğü elde etmek
Fraud ile birleştirme	Sabit fraud ile normal veriyi birleştirdik	Dengesiz veri seti oluşturmak
İstatistik kontrol	Mean / std farkı ölçüldü	Veri dağılımının korunup korunmadığını kanıtlamak
Model eğitimi	LR ve RF modelleri	Fraud sınıfının öğrenilme başarısını ölçmek
IR hesaplama	Normal / Fraud oranı	Modelin hangi imbalance noktasında performans kaybettiğini görmek
Grafik	IR vs Fraud Recall 	Kırılma noktasını görsel olarak göstermek

3. Bulgular ve Deneysel Sonuçların Yorumlanması

Modellerin farklı IR senaryolarındaki test sonuçları analiz edildiğinde literatürü destekleyen şu ampirik bulgulara ulaşılmıştır:

- Çoğunluk Sınıfı Yanlılığı (Majority Class Bias):** Düşük Imbalance Ratio (IR) değerlerinde (örneğin 500 veya 1000 normal işlem) her iki model de stabil bir öğrenme sergilemiştir. Ancak IR değeri belirli bir eşiği aştığında (veri seti istatistiksel olarak kusursuz olmasına rağmen) modeller sırf matematiksel baskınlık nedeniyle normal sınıfı ezberlemeye başlamış ve Fraud Recall (Dolandırıcılık Yakalama) oranında keskin bir düşüş (kırılma noktası) yaşanmıştır.
- Algoritma Dayanıklılığı:** Lojistik Regresyon, doğrusal yapısı gereği sınıf dengesizliğine karşı çok daha hassas davranmış ve erken iterasyonlarda pes etmiştir. Rastgele Orman (Random Forest) ise doğrusal olmayan yapısı sayesinde dengesizliğe daha uzun süre direnç göstermiş, ancak aşırı uç senaryolarda (örn. 96.000 normal işlem) o da Doğruluk Paradoksuna yenik düşmüştür.

4. Sonuç ve Metodolojik Çıkarımlar


Bu hassasiyet analizi, kredi kartı dolandırıcılığı tespitinde makine öğrenmesi modellerinin ham ve dengesiz verilerle doğrudan eğitilmesinin algoritmik olarak başarısızlıkla sonuçlanacağını matematiksel verilerle ispatlamıştır.

Elde Edilen Sonuçlar

- Fraud sabit kaldı, normal veri artırıldı → IR arttı.
- Başlangıçta Fraud Recall ≈ 0.9 civarında stabil.
- IR $\approx 5-10$ civarında recall düşmeye başladı.
- IR ≈ 100 civarında recall ciddi şekilde düştü → model “patladı”.
- Veri dağılımı (mean/std/z-score) korundu; bu nedenle düşüş gerçek dengesizlikten kaynaklanıyor, veri bozulmasından değil.

Deney sonuçları, gerçek dünya anomali tespiti sistemlerinde yapay veri üretimi (SMOTE - Synthetic Minority Over-sampling Technique), Alt/Üst Örnekleme (Undersampling/Oversampling) veya Maliyete Duyarlı Öğrenme (Cost-Sensitive Learning) gibi veri dengeleme stratejilerinin sadece bir seçenek değil, modelin körleşmesini engelleyen bilimsel bir zorunluluk olduğunu net bir şekilde ortaya koymaktadır. Bu bulgu, projenin ilerleyen aşamalarında uygulanacak olan SMOTE metodolojisinin ana dayanağını oluşturmaktadır.

5.Grafik Yorumu ve Açıklaması



- Bu grafik kırılma noktasını görsel olarak ortaya koyuyor.
- Başlangıçta recall yüksek, IR arttıkça düşüyor → “patlama noktası” böyle bulunuyor.

Fraud Recall – Imbalance Ratio (IR) Analizi

Bu grafik, sınıf dengesizliği (class imbalance) arttıkça iki farklı makine öğrenmesi modelinin (Logistic Regression ve Random Forest) azınlık sınıf olan **fraud** üzerindeki duyarlılık (recall) performansının nasıl değiştiğini göstermektedir.

5.1. Grafiğin Amacı

Grafiğin temel amacı, **Imbalance Ratio (IR)** arttıkça (Normal / Fraud oranı büyüdükçe) modellerin fraud sınıfını tespit etme yeteneklerinin nasıl etkilendiğini incelemektir.

Bu deney tasarımı kapsamında:

- Fraud sınıfı sabit tutulmuştur (492 kayıt).
- Normal sınıf kademeli olarak artırılmıştır.
- Böylece IR kontrollü şekilde yükseltilmiştir.
- Performans metriği olarak özellikle **fraud recall** izlenmiştir.

Bu yaklaşım sayesinde model performansındaki değişimin doğrudan sınıf dengesizliğinden kaynaklanıp kaynaklanmadığı analiz edilmektedir.

5.2. Eksenlerin Tanımı

- **X Eksen (Imbalance Ratio – IR):**
IR = Normal / Fraud oranını temsil eder.
IR arttıkça veri setindeki dengesizlik seviyesi artmaktadır.
- **Y Eksen (Fraud Recall):**
Fraud sınıfı için recall değerini göstermektedir.

$$Recall = \frac{TP}{TP + FN}$$

Bu metrik, gerçek fraud işlemlerinin ne kadarının model tarafından doğru şekilde yakalandığını ifade eder. Fraud tespit problemlerinde kritik öneme sahiptir çünkü kaçırılan fraud işlemler (False Negative) finansal kayba yol açar.

5.3. Logistic Regression (Mavi Eğri) Analizi

Grafikte mavi çizgi Logistic Regression modelinin fraud recall performansını göstermektedir.

Gözlemler:

- Düşük IR seviyelerinde (yaklaşık 1–10 aralığında) recall değeri 0.87–0.94 arasında dalgalanmaktadır.
- IR arttıkça recall değerinde genel bir azalma eğilimi görülmektedir.
- IR ≈ 50 sonrasında düşüş daha belirgin hale gelmektedir.
- IR ≈ 100 ve özellikle IR ≈ 200 civarında recall değeri yaklaşık 0.81 seviyesine kadar gerilemektedir.

Bu durum şunu göstermektedir:

Veri setindeki normal örnekler arttıkça Logistic Regression modeli azınlık sınıfı ayırt etme kapasitesini kaybetmeye başlamaktadır.

Lineer bir model olması nedeniyle Logistic Regression, karar sınırını çoğunluk sınıf lehine kaydırmakta ve minority class (fraud) örneklerini daha fazla kaçırmaktadır. Bu da modelin sınıf dengesizliğine karşı daha hassas olduğunu göstermektedir.

5.4. Random Forest (Turuncu Eğri) Analizi

Turuncu çizgi Random Forest modelinin fraud recall performansını göstermektedir.

Gözlemler:

- Düşük IR seviyelerinde recall değeri oldukça yüksektir (≈ 0.97 – 0.99).
- IR arttıkça çok sınırlı bir düşüş gözlenmektedir.
- $IR \approx 50$ ve sonrasında recall ≈ 0.94 – 0.95 seviyesinde stabil kalmaktadır.
- $IR \approx 200$ seviyesinde dahi ciddi bir performans çöküşü gözlenmemektedir.

Bu sonuç, Random Forest modelinin sınıf dengesizliğine karşı daha dayanıklı olduğunu göstermektedir.

Bunun temel nedenleri:

- Ağaç tabanlı yapının non-linear karar sınırları oluşturabilmesi
- Ensemble (topluluk) yaklaşımının azınlık sınıfa ait örüntüleri daha iyi yakalayabilmesi
- Veri uzayındaki karmaşık ilişkileri modelleyebilme kapasitesi

5.5. Modeller Arası Karşılaştırmalı Değerlendirme

Grafik iki model arasında belirgin bir fark ortaya koymaktadır:

IR Seviyesi	Logistic Regression	Random Forest
Düşük IR	Yüksek recall	Çok yüksek recall
Orta IR	Düşüş başlıyor	Stabil
Yüksek IR	Belirgin düşüş	Küçük düşüş

Bu durum şu bilimsel çıkarımı desteklemektedir:

- Logistic Regression modeli yüksek dengesizlik altında azınlık sınıfı öğrenme kapasitesini kaybetmektedir.
- Random Forest modeli daha robust (dayanıklı) bir performans sergilemektedir.
- IR arttıkça modeller arasındaki performans farkı açılmaktadır.

5.6. Kırılma Noktası (Breaking Point) Analizi

Grafikte özellikle Logistic Regression için bir **kırılma eğilimi** gözlenmektedir:

- $IR \approx 5-10$ aralığında performans nispeten stabil.
- $IR \approx 50$ sonrasında sistematik düşüş başlıyor.
- $IR \approx 100-200$ aralığında model belirgin şekilde zayıflıyor.

Bu nokta, modelin sınıf dengesizliği nedeniyle minority class'ı yeterince temsil edemediği eşik değeri olarak yorumlanabilir.

Random Forest için ise belirgin bir “patlama” veya ani çöküş gözlenmemektedir; bu da modelin dengesiz veri ortamında daha güvenilir olduğunu göstermektedir.

Bu grafik şu temel bulguları ortaya koymaktadır:

1. Sınıf dengesizliği arttıkça azınlık sınıfın tespiti zorlaşmaktadır.
2. Model mimarisi, dengesizliğe karşı dayanıklılıkta kritik rol oynamaktadır.
3. Lineer modeller (Logistic Regression) yüksek IR değerlerinde minority class'ı ihmal etmeye daha yatkındır.
4. Ensemble tabanlı ağaç modelleri (Random Forest) daha stabil bir recall performansı sunmaktadır.
5. Veri dağılımı korunmuş olduğu için gözlenen performans düşüşü veri bozulmasından değil, doğrudan class imbalance etkisinden kaynaklanmaktadır.

5.7. Sonuç

Bu grafik, kontrollü sınıf dengesizliği artışı altında modellerin davranışını nicel olarak ortaya koymaktadır.

Özellikle fraud recall üzerinden yapılan analiz, modelin hangi IR seviyesinde azınlık sınıfı öğrenme kapasitesini kaybetmeye başladığını göstermekte ve böylece çalışmanın temel amacı olan **“modelin dengesizlik nedeniyle kırılma noktasının belirlenmesi”** hedefine doğrudan hizmet etmektedir.

6. MODEL DEĞERLENDİRME METODOLOJİSİ VE DENEYSEL BULGULAR

Makine öğrenmesi modellerinin performansını ölçerken, verinin tek bir kez eğitim ve test seti olarak ayrılması (örneğin %80 Train, %20 Test) modelin rastgele iyi veya kötü sonuçlar üretmesine yol açabilmektedir. Bu çalışmada, modelin genelleme yeteneğini kanıtlamak ve varyansı minimize etmek amacıyla **Tabakalı 5-Katlı Çapraz Doğrulama (Stratified 5-Fold Cross-Validation)** metodolojisi kullanılmıştır.

6.1. 5-Katlı Çapraz Doğrulama (5-Fold Cross-Validation) Nedir ve Neden Kullanıldı?

K-Katlı Çapraz Doğrulama, veri setinin rastgele olarak K adet eşit parçaya (fold/katman) bölünmesi işlemidir. Bu çalışmada K=5 olarak belirlenmiştir.

- **Çalışma Prensipleri:** Veri seti 5 eşit parçaya bölünür. Model, 4 parça üzerinde eğitilirken geriye kalan 1 parça üzerinde test edilir. Bu işlem, her bir parçanın tam olarak bir kez test verisi olarak kullanılması sağlanacak şekilde 5 kez tekrarlanır.
- **Projedeki Amacı:** Dolandırıcılık tespiti gibi kritik bir problemde, modelin performansının verinin nasıl bölündüğüne bağlı kalmamasını sağlar. 5 farklı iterasyonun sonucunda elde edilen metriklerin aritmetik ortalaması alınarak, modelin gerçek dünya verisi üzerindeki performansı çok daha güvenilir ve tarafsız bir şekilde elde edilmiştir.

6.2. Tabakalı Örneklem (Stratified Sampling) Nedir ve Neden Kullanıldı?

Stratified (Tabakalı) yaklaşım, çapraz doğrulama işlemi sırasında veri parçalara ayrılırken, her bir parçadaki hedef sınıf (Fraud ve Normal) oranlarının orijinal veri setindeki oranla birebir aynı olmasını sağlayan istatistiksel bir koruma mekanizmasıdır.

- **Projedeki Amacı:** Çalışmamızdaki kredi kartı veri setinde sınıf dengesizliği (Class Imbalance) oranları son derece yüksektir (örneğin 96.000 Normal işleme karşılık sadece 492 Fraud işlemi). Eğer tabakalı örneklem yapılmadan normal bir çapraz doğrulama uygulansaydı, bazı katmanlara (fold) rastgele olarak hiç Fraud işlemi düşmeyebilir veya çok fazla düşebilirdi. "Stratified" parametresi kullanılarak, her bir eğitim ve test katmanında Fraud ve Normal işlemlerin homojen bir şekilde dağılması garanti altına alınmış ve deneysel bütünlük korunmuştur.

6.3. Modellerin Performans Analizi ve Tabloların Yorumlanması

Uygulanan Stratified 5-Fold Cross Validation işlemi sonucunda, Lojistik Regresyon ve Rastgele Orman (Random Forest) algoritmalarının artan Dengesizlik Oranlarına (Imbalance Ratio - IR) karşı gösterdiği ortalama performans değişimleri elde edilmiştir.

Lojistik Regresyon Performans Analizi:

Tablo 1 (Lojistik Regresyon sonuçları) incelendiğinde, literatürdeki "**Doğruluk Paradoksu**" (**Accuracy Paradox**) matematiksel olarak net bir şekilde gözlemlenmektedir. Dengesizlik Oranı (IR) arttıkça, modelin Doğruluk (Accuracy) değeri artarak **%99.90** seviyelerine ulaşmaktadır. Ancak modelin asıl amacı olan dolandırıcılık işlemlerini yakalama yeteneğini gösteren Recall (Duyarlılık) değeri; 1.02 IR seviyesinde **0.9206** iken, deney setine eklenen 100-120 IR aralığında (50k-60k normal işlem) modelin çözülmeye başladığı ve 195.12 IR seviyesinde **0.7906**'ya gerilediği görülmüştür. Lojistik regresyonun çizdiği doğrusal karar sınırı, çoğunluk sınıfının (Normal işlemler) baskısı altında kalarak azınlık sınıfını (Fraud) modelleyemez hale gelmiş ve model "çoğunluk sınıfı yanlılığına" (majority class bias) düşmüştür.

1. Lojistik Regresyon (Logistic Regression) Performans Tablosu

Normal İşlem	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
500	1.02	0.9420	0.9698	0.9206	0.9446
1000	2.03	0.9600	0.9618	0.9124	0.9364
1500	3.05	0.9700	0.9830	0.9086	0.9438
3000	6.10	0.9840	0.9826	0.8942	0.9358
12000	24.39	0.9940	0.9910	0.8742	0.9290
48000	97.56	0.9990	0.9576	0.8228	0.8858
50000	101.63	0.9990	0.9506	0.8188	0.8798
55000	111.79	0.9990	0.9486	0.8192	0.8790
60000	121.95	0.9990	0.9400	0.8090	0.8690
96000	195.12	0.9990	0.9530	0.7906	0.8642

Rastgele Orman (Random Forest) Performans Analizi:

Tablo 2 (Random Forest sonuçları) incelendiğinde, karar ağaçlarından oluşan bu topluluk (ensemble) modelinin sınıf dengesizliğine karşı çok daha dirençli (robust) olduğu tespit edilmiştir. Özellikle IR oranının 100'ü geçtiği en zorlu senaryolarda bile **Kesinlik (Precision) değerinin 1.0000 seviyesinde kalması**, modelin sadece dolandırıcıları yakalamakla kalmayıp, normal işlemleri yanlışlıkla dolandırıcılık olarak işaretlemmediğini (yanlış alarm üretmediğini) ispatlamıştır. Modelin Fraud sınıfını yakalama başarısı olan Recall oranı, artan dengesizliğe rağmen yalnızca **0.9718'den 0.9434'e** minimal bir gerileme göstermiş ve istikrarlı yapısını korumuştur.

2. Random Forest Performans Tablosu

Normal İşlem	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
500	1.02	0.9820	0.9958	0.9718	0.9824
3000	6.10	0.9940	0.9918	0.9594	0.9742
12000	24.39	0.9990	0.9980	0.9510	0.9730
48000	97.56	1.0000	1.0000	0.9450	0.9716
50000	101.63	1.0000	1.0000	0.9472	0.9742
55000	111.79	1.0000	1.0000	0.9492	0.9738
60000	121.95	1.0000	1.0000	0.9472	0.9734
96000	195.12	1.0000	1.0000	0.9434	0.9718

Kritik Eşik Değeri: IR $\approx$ 100 ve Performans Degradasyonu

Yapılan deneysel çalışmalar sonucunda, Lojistik Regresyon modelinin performansında IR $\approx$ 100 seviyesinde istatistiksel olarak anlamlı bir kırılma noktası tespit edilmiştir. Bu eşik değeri,

1 sahte (fraud) işleme karşılık yaklaşık 100 normal işlemin bulunduğu veri dağılımını ifade etmektedir.

Performans Kaybı: $IR < 100$ düzeylerinde Duyarlılık (Recall) oranı 0.92 ile 0.82 bandında seyrederken, $IR \approx 100$ eşliğinin aşılmasıyla birlikte bu değer hızla 0.79 seviyelerine gerilemektedir.

Anlamı: Bu durum, modelin sahte işlemleri tespit etme kabiliyetinin %20'nin üzerinde bir hata payına ulaştığını ve operasyonel riskin arttığını göstermektedir.

Kırılma Noktasının Teorik Nedenleri

Lojistik Regresyon modelinin bu kritik eşikten sonra sergilediği performans kaybı, aşağıdaki üç temel akademik gerekçeye dayandırılmaktadır:

Karar Sınırı Kayması (Decision Boundary Shift): Lojistik Regresyon, toplam hata fonksiyonunu (Log-Loss) minimize etmeye odaklı doğrusal bir modeldir. IR arttıkça, çoğunluk sınıfının (normal işlemler) gradyan üzerindeki baskısı artmakta ve karar sınırı azınlık sınıfı (fraud) aleyhine kaymaktadır. Bu durum, azınlık sınıfı örneklerinin yanlışlıkla çoğunluk sınıfı bölgesine itilmesine (False Negative) neden olmaktadır.

Doğruluk Paradoksu (Accuracy Paradox): Modelin toplam doğruluğu (Accuracy) %99.9 gibi yanıltıcı bir yüksekliğe ulaşırken, asıl hedef metrik olan Recall değerinin düşmesi literatürde "Doğruluk Paradoksu" olarak tanımlanır. Model, tüm örnekleri "normal" olarak sınıflandırarak hatayı minimize etme eğilimi göstermekte, ancak bu durum azınlık sınıfının ayırt edilebilirliğini ortadan kaldırmaktadır.

Azınlık Sınıfı Seyrelmesi (Minority Class Dilution): $IR \approx 100$ eşğinde, azınlık sınıfı verileri istatistiksel olarak "gürültü" (noise) gibi algılanmaya başlar. Doğrusal modeller, verideki bu düşük frekanslı sinyali, baskın olan çoğunluk sınıfı sinyalinden ayıramaz hale gelmektedir.

Model Robustness: Lojistik Regresyon ve Random Forest Karşılaştırması

Çalışmada, topluluk öğrenme (ensemble learning) temelli Random Forest algoritmasının bu kırılma noktasına karşı daha dirençli olduğu gözlemlenmiştir.


Metrik (IR $\approx$ 100)	Lojistik Regresyon	Random Forest
Recall (Duyarlılık)	0.79 (Kritik Düşüş)	0.94 (Stabil)
Model Yapısı	Doğrusal / Linear	Doğrusal Olmayan / Non-linear
Veri Duyarlılığı	Yüksek (Hızlı Kırılma)	Düşük (Dirençli)

Random Forest'ın Direnç Gerekçeleri:

Non-Linear Karar Sınırları: Karmaşık ve iç içe geçmiş veri dağılımlarında daha esnek sınırlar çizebilmesi.

Torbalama (Bagging) Etkisi: Her karar ağacının veri setinden farklı alt örneklerle (bootstrap) eğitilmesi, azınlık sınıfı örneklerinin modelin bütününde temsil edilme olasılığını artırmaktadır.

7. Model kodundaki çıktı grafiği



Bu çalışma, kredi kartı işlemlerinde dolandırıcılık tespiti (Fraud Detection) senaryosunda, veri setindeki **Dengesizlik Oranı (Imbalance Ratio - IR)** arttıkça modellerin başarısının nasıl değiştiğini ölçmek amacıyla tasarlanmıştır.

- **Veri Hazırlama (Dağılım Koruma):** Sentetik senaryolar oluşturulurken sadece veri sayısı artırılmamış; Z-Score normalizasyonu ve Binning (gruplandırma) yöntemleri kullanılarak normal işlemlerin orijinal istatistiksel dağılımı (ortalama ve standart sapma) korunmuştur. Bu, performans düşüşünün verinin karakterinden değil, tamamen sayısal azınlık durumundan kaynaklandığını ispatlar.
- **Doğrulama (Validation):** Modeller 5-Fold Stratified Cross-Validation ile test edilmiştir. Bu yöntem, her katlamada (fold) azınlık sınıfı oranını sabit tutarak sonuçların tesadüfi olmasını engeller.

7.1. Grafik Yorumu ve Model Karşılaştırması

Grafikte, X eksenini arttıkça (yani dolandırıcılık vakaları toplam veri içinde seyredikçe) iki farklı algoritmanın sergilediği tutum şu şekildedir:

A. Random Forest (Turuncu Çizgi): Yüksek Direnç ve Kararlılık

- **Analiz:** Random Forest (RF), IR değeri 1'den yaklaşık 200'e (195.12) çıkmasına rağmen **%95'in üzerinde** (0.950+) bir Recall değeriyle neredeyse yatay bir seyir izlemiştir.
- **Teknik Neden:** RF bir "Ensemble" (Topluluk) modelidir. Karar ağaçları yapısı gereği veriyi küçük parçalara (leaf nodes) böler. Azınlık sınıfı (Fraud) ne kadar az olursa olsun, ağaçlar bu vakaların ayırt edici özelliklerini diğerlerinden izole edip öğrenebilir.

B. Logistic Regression (Mavi Çizgi): Doğrusal Çöküş ve Hassasiyet

- **Analiz:** Lojistik Regresyon (LR), dengesizliğe karşı son derece hassastır. Başlangıçta %92 olan Recall değeri, IR arttıkça **%79 seviyelerine** kadar sert bir düşüş yaşamıştır.
- **Kırılma Noktaları:**
 - * **IR 0-50 Arası:** En keskin düşüş bu aralıkta gerçekleşir. Model, çoğunluk sınıfının (Normal) baskısı altında kalmaya başlar.
 - **IR 100+ Sonrası:** Modelin "Karar Sınırı" (Decision Boundary) tamamen normal işlemlere doğru kayar. Bu noktadan sonra model, şüpheli işlemleri ayırt etmekte zorlanarak "güvenli oynama" (her şeye normal deme) eğilimine girer.

7.2. Kritik Bulgular ve Sonuç

1. **Model Seçimi:** Finansal suç tespiti gibi IR değerinin çok yüksek olduğu (nadir olaylar) projelerde, Lojistik Regresyon gibi doğrusal modeller tek başına yetersiz kalmaktadır.
2. **Kırılma Noktası:** Lojistik Regresyon için kritik eşik **IR = 25** civarındır; bu noktadan sonra modelin yakalama gücü %90'ın altına inmektedir.
3. **Algoritma Üstünlüğü:** Deney, Random Forest'ın hiçbir ek örnekleme yöntemi (SMOTE vb.) gerektirmeden, sadece kendi mimarisi sayesinde aşırı dengesiz veride bile dolandırıcıları %95 başarıyla yakaladığını kanıtlamıştır.

8. Tekil Train-Test Ayrımı ile 5-Katlı Çapraz Doğrulamanın (5-Fold CV) Varyans Üzerindeki Etkisi

Projeye ait deneysel süreçlerde, model performansının veri bölünmesinden (data splitting) ne ölçüde etkilendiğini kanıtlamak amacıyla iki farklı değerlendirme yöntemi görselleştirilmiştir.

8.1. Dalgalı Grafik (Tekil Train-Test Ayrımı / Holdout Method): Bir önceki görselde (dalgalı yapıya sahip olan grafik), modeller veri setinin tek bir kez %80 Eğitim ve %20 Test olarak ayrılmasıyla (Holdout yöntemi) test edilmiştir. Bu grafikte, özellikle düşük ve orta Imbalance Ratio (IR) değerlerinde (IR=0 ile IR=50 aralığında) **yüksek bir varyans (dalgalanma/fluctuation)** görülmektedir.

- *Neden Dalgalı?* Lojistik Regresyon (mavi çizgi) ve Random Forest (turuncu çizgi) eğrilerindeki bu ani iniş ve çıkışlar, modelin davranışından ziyade **test setine düşen verilerin rastgeleliğinden** kaynaklanmaktadır. Aşırı dengesiz veri setlerinde, test setine düşen tek bir dolandırıcılık (Fraud) işleminin eksik veya fazla olması, yüzdelik Recall skorunda suni (gerçekçi olmayan) sıçramalara veya çakılmalara yol açmaktadır. Bu durum, modelin genelleme yeteneğini (generalization) ölçmek için tekil ayırım yönteminin ne kadar güvenilir olmadığını göstermektedir.

8.2. Pürüzsüz Grafik (5-Katlı Çapraz Doğrulama / 5-Fold CV): Çalışmanın asıl metodolojisini yansıtan diğer görselde (Şekil X: 5-Fold CV) ise eğrilerin son derece istikrarlı ve pürüzsüz (smooth) bir düşüş veya yatay seyir izlediği görülmektedir.

- *Neden Pürüzsüz?* Bu grafikteki her bir nokta, verinin 5 farklı alt kümeye bölünüp, her defasında farklı bir test setiyle 5 kez eğitilmesinin **matematiksel ortalamasını (mean)** yansıtmaktadır. Çapraz doğrulama işlemi, tekil ayırımdan kaynaklanan o rastgele istatistiksel gürültüyü (noise) ve yüksek varyansı filtrelemiştir.

Sonuç ve Çıkarım: İki grafik karşılaştırıldığında, tekil ayırım yönteminin yanıltıcı sıçramalar üretebildiği kanıtlanmıştır. 5-Fold CV grafiği ise istatistiksel gürültüden arındırılarak, sınıf dengesizliğinin (IR) modeller üzerindeki **gerçek ve sistematik etkisini** ortaya çıkarmıştır. Bu karşılaştırma, projedeki modellerin güvenilirliğini (reliability) ispatlamak için 5-Katlı Tabakalı Çapraz Doğrulama (Stratified 5-Fold CV) yönteminin kullanılmasının metodolojik bir zorunluluk olduğunu bilimsel olarak doğrulamaktadır.

9.GENEL ÇIKARIM VE SONUÇ

Bu deneysel çalışma; kredi kartı dolandırıcılığı tespiti gibi azınlık sınıfının kritik önem taşıdığı (cost-sensitive) problemlerde, model performansının salt "**Doğruluk**" (Accuracy) metriği üzerinden değerlendirilmesinin ciddi bir güvenlik zafiyeti yaratacağını sayısal olarak ispatlamıştır. Elde edilen bulgular ışığında aşağıdaki temel bilimsel sonuçlara ulaşılmıştır:

- **Kritik Kırılma Eşiği:** Lojistik Regresyon gibi temel parametrik modellerin, **IR $\approx$ 100** (1 sahte işleme karşılık 100 normal işlem) eşiğinden sonra "**Doğruluk Paradoksuna**" yenik düştüğü ve dolandırıcılık vakalarının **%20'den fazlasını** kaçırmaya başladığı gözlemlenmiştir.
- **Model Direnci:** Rastgele Orman (Random Forest) gibi doğrusal olmayan (non-linear) algoritmaların, aşırı sınıf dengesizliğine karşı çok daha yüksek bir direnç (robustness) sergilediği ve operasyonel güvenliği korumada daha başarılı olduğu kanıtlanmıştır.
- **Veri Dengeleme Zorunluluğu:** Algoritma seçiminden bağımsız olarak, model güvenilirliğini maksimize etmek ve karar sınırını azınlık sınıfını kapsayacak şekilde

geniřletmek iin veri n iřleme ařamasında **SMOTE** gibi sentetik veri dengeleme stratejilerinin uygulanmasının bilimsel bir zorunluluk olduėu ortaya konmuřtur.

Nihai olarak; finansal gvenlik sistemlerinde yksek doėruluk oranları tek bařına bir bařarı kriteri deėildir. Gerek dnya senaryolarında srdrlebilir bir koruma iin, verideki dengesizliėin sentetik yntemlerle giderilmesi ve bu verilerin karmařık rntleri yakalayabilen non-lineer modellerle iřlenmesi en efektif yaklařım olarak deėerlendirilmektedir.

10.Kredi Kartı Dolandırıcılıėı Tespiti – SMOTE Uygulamalı DeneySEL Rapor

10.1. Giriř

Kredi kartı dolandırıcılıėı tespiti, veri setlerinde sınıflar arası dengesizlik nedeniyle klasik makine ėrenmesi yntemleriyle zlmesi zor bir problemdir. Fraud (dolandırıcılık) olayları, normal iřlemlere gre olduka azdır; bu durum modellerin oėunluk sınıfına odaklanmasına ve dolandırıcılık iřlemlerini tespit etmede dřk performans gstermesine yol aar.

Bu tr dengesiz veri setlerinde model, yksek doėruluk (accuracy) elde etse bile azınlık sınıfını doėru tahmin edemeyebilir. Bu nedenle zellikle fraud detection problemlerinde yalnızca doėruluk deėil, recall gibi metrikler daha kritik hale gelmektedir.

Bu alıřmada, veri setini dengeli hale getirmek amacıyla SMOTE (Synthetic Minority Over-sampling Technique) yntemi kullanılmıř ve performans deėiřimi Logistic Regression ve Random Forest modelleri ile deėerlendirilmiřtir.

10.2. SMOTE Yntemi

1 SMOTE Nedir?

Makine ėrenmesinde sınıf dengesizliėi (class imbalance) problemleri sıklıkla grlmektedir. Bu durumlarda oėunluk sınıfına odaklanan modeller, azınlık sınıfını doėru řekilde ėrenemeyebilir. Kredi kartı dolandırıcılıėı veri setleri bunun tipik bir rneėidir: normal iřlemler ok fazla, fraud iřlemleri ise olduka azdır.

SMOTE yntemi, azınlık sınıfındaki veri rneklerini basite kopyalamak yerine, mevcut rnekleri kullanarak yeni sentetik (yapay) veri noktaları retir. Bu yaklařım, veri tekrarını azaltırken modelin daha genellenebilir bir yapı ėrenmesini saėlar.

SMOTE algoritması řu adımları izler:

- Azınlık sınıfındaki her veri noktası için en yakın komşular belirlenir
- Bu komşular arasından rastgele bir komşu seçilir
- Seçilen iki veri noktası arasında doğrusal bir interpolasyon yapılır
- Yeni sentetik veri noktası oluşturulur

Matematiksel olarak:

$$x_{\text{new}} = x_i + \text{rand}(0,1) \times (x_{\text{nn}} - x_i)$$

Burada:

- x_i : Azınlık sınıfına ait veri noktası
- x_{nn} : Seçilen komşu veri noktası
- $\text{rand}(0,1)$: 0 ile 1 arasında rastgele bir sayı

SMOTE, azınlık sınıfına yeni veri noktaları ekleyerek veri setini dengeler ve aşırı tekrar oluşmasını engeller. Bu sayede modelin azınlık sınıfını öğrenme kapasitesi artar.

SMOTE, azınlık sınıfına yeni veri noktaları ekleyerek veri setini dengeler ve aşırı tekrar oluşmasını engeller; böylece modelin overfitting yaşama olasılığı düşer.

2. Bu Çalışmada SMOTE Kullanılma Nedeni

Kredi kartı dolandırıcılığı veri seti yüksek derecede sınıf dengesizliği içermektedir. Model çoğunluk sınıfına odaklandığı için dolandırıcılık işlemlerini tespit etmekte zorlanmaktadır.

Bu nedenle veri setindeki sınıf dengesizliğini azaltmak amacıyla SMOTE yöntemi uygulanmıştır. Dolandırıcılık işlemleri artırılarak normal işlemlerle eşitlenmiş ve modelin özellikle fraud recall performansının artırılması hedeflenmiştir.

3. SMOTE Veri Setlerinin Oluşturulması

Bu çalışmada SMOTE uygulaması iki aşamalı bir yaklaşım ile gerçekleştirilmiştir.

İlk aşamada:

- Normal işlemler farklı veri boyutlarına göre (500 – 96.000 arası) seçilmiştir.
- Bu seçim sırasında veri dağılımını korumak amacıyla z-score tabanlı örnekleme yöntemi kullanılmıştır.
- Böylece normal veri sınıfının istatistiksel yapısı korunmuştur.

Daha sonra:

- Dolandırıcılık işlemleri veri setine eklenmiştir.
- SMOTE uygulanarak azınlık sınıfı olan fraud verileri artırılmıştır.
- Her veri setinde Normal = Fraud olacak şekilde dengeli veri setleri oluşturulmuştur.

Python’da kullanılan temel yapı şu şekildedir:

- `sampling_strategy = {1: target_size}`
→ Azınlık sınıfının hedeflenen sayıya eşitlenmesini sağlar
- `random_state = 42`
→ Deneylerin tekrarlanabilir olmasını sağlar

Bu süreç sonunda farklı büyüklüklerde, dengelenmiş veri setleri oluşturulmuş ve her biri ayrı ayrı model eğitiminde kullanılmıştır.

Ayrıca süreç adımları aşağıdaki şekilde özetlenebilir:

1. Normal işlemler belirli büyüklüklere göre seçilmiştir.
2. Dolandırıcılık işlemleri bu veri setine eklenmiştir.
3. SMOTE uygulanarak dolandırıcılık sınıfına yeni sentetik veri noktaları üretilmiştir.

Python örnek kodu:

```
</> Python   
  
smote = SMOTE(sampling_strategy={1: target_size}, random_state=42)  
X_res, y_res = smote.fit_resample(X, y)
```

- **sampling_strategy = {1: target_size}**: Azınlık sınıfının hedef veri sayısına eşitlenmesini sağlar.
- **random_state**: Deneylerin tekrarlanabilirliğini sağlar.

Bu çalışmada iki farklı makine öğrenmesi algoritması kullanılmıştır:

10.3.Modellerin Açıklaması

1. Logistic Regression (LR)

- **Temel Mantık:**
Logistic Regression, doğrusal bir sınıflandırma modelidir. Girdi özelliklerinin doğrusal

kombinasyonunu kullanarak bir sınıfa ait olma olasılığını tahmin eder. Örneğin, bir işlemin fraud olup olmadığını 0–1 aralığında bir olasılık değeri ile ifade eder.

- **Avantajları:**
 - Basit ve anlaşılır bir yapıya sahiptir; modelin hangi özelliklerin tahmin üzerinde etkili olduğunu yorumlamak kolaydır.
 - Hızlıdır ve büyük veri setleri üzerinde temel bir performans ölçütü (baseline) sağlar.
 - Overfitting riski görece düşüktür; özellikle küçük veri setlerinde güvenilir sonuçlar verir.
- **Sınırlamaları:**
 - Sadece doğrusal ilişkileri öğrenebilir; karmaşık ve doğrusal olmayan sınıf ayrımlarını yakalamakta yetersiz kalabilir.
 - Özellikler arasındaki yüksek korelasyon veya etkileşimleri tek başına modelleyemez.
- **Dolandırıcılık Tespiti Bağlamında:**
 - Küçük ve dengeli veri setlerinde LR, fraud ve normal işlemleri ayırmada makul performans sağlar.
 - Ancak büyük veri setlerinde veya veri özellikleri karmaşık ve doğrusal olmayan ilişkiler içerdiğinde performansı sınırlı kalır.

2. Random Forest (RF)

Temel Mantık:

Random Forest, birden fazla karar ağacından oluşan bir ensemble (topluluk) yöntemidir. Her bir karar ağacı, veri setinin farklı bir alt kümesi ve rastgele seçilmiş özellikleri kullanılarak eğitilir. Nihai tahmin, tüm ağaçların oylarının birleştirilmesi (majority voting) ile yapılır.

- **Avantajları:**
 - Doğrusal olmayan ve karmaşık ilişkileri öğrenme kapasitesi yüksektir.
 - Tek bir karar ağacına kıyasla overfitting riskini azaltır; çünkü birden fazla modelin birleşimi ile genelleme yapılır.
 - Özellik önemini (feature importance) hesaplayabilir; bu sayede modelin hangi özniteliklere dayandığı analiz edilebilir.
- **Sınırlamaları:**
 - Çok sayıda ağaç kullanıldığında eğitim süresi uzayabilir ve hesaplama maliyeti artabilir.
 - Aşırı öğrenme (overfitting) riski, özellikle SMOTE ile çoğaltılmış büyük veri setlerinde yüksek performans ile kendini gösterebilir; model ezberleme yapabilir.
- **Dolandırıcılık Tespiti Bağlamında:**
 - Küçük veri setlerinde Logistic Regression kadar etkili olmasa da, veri boyutu büyüdükçe sınıflar arasındaki karmaşık ilişkileri öğrenerek mükemmele yakın performans elde edebilir.
 - Confusion Matrix kullanılarak modelin overfitting riski gözlemlenebilir; TP, FP, TN ve FN değerleri detaylı olarak analiz edilebilir.
 - Özellik önemleri (feature importance) sayesinde, modelin hangi işlemler ve özellikler üzerinde yoğunlaştığı belirlenebilir ve sistemin şeffaflığı artırılabilir.

10.4. Değerlendirme Metrikleri

Model performansını ölçmek amacıyla aşağıdaki metrikler kullanılmıştır:

- **Accuracy (Doğruluk):**
Tüm tahminler arasındaki doğru tahmin oranını gösterir. Ancak dengesiz veri setlerinde tek başına yeterli değildir.
- **Precision (Kesinlik):**
Modelin fraud olarak tahmin ettiği işlemlerden kaç tanesinin gerçekten fraud olduğunu gösterir. Yanlış alarm oranını ölçer.
- **Recall (Duyarlılık / True Positive Rate):**
Gerçek fraud işlemlerinin ne kadarının doğru tespit edildiğini gösterir.
- **F1-Score:**
Precision ve recall'un harmonik ortalamasıdır. Modelin genel performansını dengeli şekilde ifade eder.

Fraud Recall'un Önemi

Bu çalışmada özellikle recall metriği üzerinde durulmuştur. Bunun nedenleri:

- Fraud işlemlerinin kaçırılması (false negative) ciddi mali kayıplara yol açar.
- Bu nedenle modelin mümkün olduğunca fazla fraud işlemi tespit etmesi gerekir.

Bu bağlamda, **recall değeri**, modelin dolandırıcılık tespit başarısını gösteren en kritik performans ölçütü olarak değerlendirilmiştir.

Veri Dağılımının Korunmasının Kontrolü

SMOTE ile veri seti oluşturulurken yalnızca sınıf dengesinin sağlanması yeterli değildir. Aynı zamanda oluşturulan veri setinin, orijinal veri dağılımına benzer istatistiksel özellikler göstermesi de büyük önem taşır. Aksi durumda, üretilen sentetik veri gerçek veri yapısını temsil etmeyebilir ve model performansının gerçeği yansıtmamasını engelleyebilir.

Bu nedenle çalışmada, oluşturulan dengelenmiş veri setlerinin istatistiksel özellikleri detaylı olarak analiz edilmiştir. Özellikle normal (çoğunluk) sınıfa ait veri dağılımının korunup korunmadığı, **ortalama (mean)** ve **standart sapma (standard deviation)** değerleri üzerinden incelenmiştir.

Bu analiz, veri setindeki özelliklerin **Z-Score normalizasyonu** kullanılarak değerlendirilmesi ile gerçekleştirilmiştir. Z-Score yöntemi, her bir veri noktasının ortalamadan kaç standart sapma uzaklıkta olduğunu gösterir ve veri dağılımının yapısını analiz etmek için yaygın olarak kullanılan bir yöntemdir.

Kod açısından bu kontrol şu adımlarla gerçekleştirilmiştir:

1. Orijinal normal veri setinin ortalama ve standart sapma değerleri hesaplanmıştır.
2. SMOTE sonrası elde edilen veri setindeki normal sınıfın istatistikleri hesaplanmıştır.
3. İki veri seti arasındaki ortalama ve standart sapma farkları karşılaştırılmıştır.

Karşılaştırma sonucunda elde edilen:

- Mean farkı
- Standart sapma farkı

değerlerinin düşük olması, oluşturulan veri setlerinin orijinal veri dağılımına oldukça yakın olduğunu göstermektedir.

Bu kontrol sayesinde, SMOTE ile oluşturulan veri setlerinin yalnızca dengeli değil, aynı zamanda istatistiksel olarak tutarlı olduğu doğrulanmıştır. Bu durum, modelin eğitim sürecinde gerçek veri yapısına benzer bir dağılım üzerinden öğrenmesini sağlar.

Dolayısıyla, **veri dağılımının korunması**, elde edilen model performansının güvenilirliği açısından kritik bir adımdır.

Bu yaklaşım sayesinde, model performansındaki iyileşmenin yalnızca veri çoğaltımından değil, aynı zamanda anlamlı ve dağılımı korunmuş veri üretiminden kaynaklandığı gösterilmiştir.

Python

```
orig_mean = normal.drop('Class',axis=1).mean()
orig_std = normal.drop('Class',axis=1).std()

new_normal = df_balanced[df_balanced['Class']==0]
new_mean = new_normal.drop('Class',axis=1).mean()
new_std = new_normal.drop('Class',axis=1).std()

print(f"Mean farkı: {(orig_mean-new_mean).abs().mean():.4f},
Std farkı: {(orig_std-new_std).abs().mean():.4f}")
```

Bu kontrol sayesinde, oluşturulan veri setlerindeki normal işlem dağılımının orijinal veri setine mümkün olduğunca yakın kalması sağlanmıştır. Ortalama ve standart sapma değerleri arasındaki farkların düşük olması, veri setinin istatistiksel özelliklerinin korunduğunu göstermektedir.

Bu yaklaşım sayesinde, SMOTE ile oluşturulan dengelenmiş veri setlerinin **gerçek veri dağılımına benzer özellikler taşıdığı** doğrulanmıştır.

10.5. Stratified K-Fold Cross Validation Kullanımı

Bu çalışmada, makine öğrenmesi modellerinin performansını daha güvenilir ve genellenebilir bir şekilde değerlendirmek amacıyla **Stratified K-Fold Cross Validation** yöntemi kullanılmıştır.

Cross validation yöntemi, veri setini birden fazla parçaya ayırarak modelin farklı veri bölümleri üzerinde test edilmesini sağlar. Böylece modelin performansı tek bir veri bölümüne bağlı kalmaz ve daha gerçekçi bir değerlendirme yapılabilir.

Bu çalışmada **5-Fold Cross Validation** uygulanmıştır. Bu yöntemde veri seti beş eşit parçaya ayrılır ve her iterasyonda:

- 4 parça eğitim (train) verisi
- 1 parça test verisi

olarak kullanılır. Bu işlem toplam 5 kez tekrarlanır ve her veri parçası bir kez test verisi olarak değerlendirilir.

Stratified Yapının Önemi

Stratified K-Fold yönteminin en önemli özelliği, **her fold içinde sınıf dağılımını korumasıdır**. Böylece her veri parçasında:

- Normal işlemler
- Dolandırıcılık işlemleri

veri setindeki genel oranı temsil edecek şekilde dengeli olarak dağıtılır. Bu durum özellikle dengesiz veri setlerinde kritik öneme sahiptir, çünkü model her eğitim ve test aşamasında benzer veri dağılımıyla karşılaşır.

SMOTE ile Birlikte Kullanımı

Dikkat edilmesi gereken kritik bir nokta, **SMOTE işleminin yalnızca eğitim verisine uygulanmasıdır**. Her fold için süreç şu şekilde ilerler:

1. Veri seti eğitim ve test olarak ayrılır.
2. SMOTE yalnızca eğitim verisine uygulanır.
3. Model, dengelenmiş eğitim verisi ile eğitilir.
4. Model, **orijinal (dengelenmemiş) test verisi** üzerinde değerlendirilir.

Bu yaklaşım sayesinde:

- Veri sızıntısı (data leakage) engellenir.
- Modelin gerçek hayattaki performansı daha doğru şekilde simüle edilir.

Eğer SMOTE test verisine uygulanmış olsaydı, model sentetik veriler üzerinde test edilmiş olur ve bu durum performansın olduğundan yüksek görünmesine yol açabilirdi.

Kullanım Amaçları

Stratified K-Fold Cross Validation yönteminin temel amaçları şunlardır:

- Model performansının tek bir veri bölümüne bağlı kalmasını engellemek
- Modelin farklı veri parçaları üzerinde nasıl performans gösterdiğini analiz etmek
- Daha güvenilir ve genellenebilir performans sonuçları elde etmek

Sonuç

Bu yöntem sayesinde, **Logistic Regression** ve **Random Forest** modellerinin performansı farklı veri bölümleri üzerinde test edilmiş ve elde edilen sonuçların ortalaması alınarak daha güvenilir performans değerleri elde edilmiştir.

Kod açısından bu işlem, her fold için eğitim ve test verilerinin ayrılması, SMOTE uygulanması ve modelin eğitilmesi/test edilmesi adımlarını içerecek şekilde uygulanmıştır.

 Python



```
skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

Bu yöntemin kullanılmasının temel amaçları şunlardır:

- Model performansının tek bir veri bölmesine bağlı kalmasını engellemek
- Modelin farklı veri parçaları üzerinde nasıl performans gösterdiğini analiz etmek
- Daha güvenilir ve genellenebilir performans sonuçları elde etmek

Bu sayede, **Logistic Regression** ve **Random Forest** modellerinin performansı farklı veri bölümleri üzerinde test edilmiş ve elde edilen sonuçların ortalaması alınarak daha güvenilir performans değerleri elde edilmiştir.

11. Deneysel Tasarım ve Sonuçlar

11.1. Deneysel Tasarım

Bu çalışmada, SMOTE yönteminin farklı veri boyutları üzerindeki etkisini analiz etmek amacıyla kapsamlı bir deneysel süreç gerçekleştirilmiştir.

Deneysel tasarım kapsamında:

- Veri seti boyutları 500'den 96.000'e kadar kademeli olarak artırılmıştır.
- Her veri boyutu için:
 - Normal işlemler belirli bir büyüklükte seçilmiş
 - Fraud verisi eklenmiş
 - SMOTE uygulanarak veri seti dengelenmiştir
- Her veri seti için ayrı bir CSV dosyası oluşturulmuştur.
- Tüm veri setlerinde sınıf dağılımı:
 - Normal = Fraud (IR = 1.00) olacak şekilde ayarlanmıştır.

Oluşturulan her veri seti üzerinde:

- **Logistic Regression (LR)**
- **Random Forest (RF)**

modelleri eğitilmiş ve test edilmiştir.

Model değerlendirme sürecinde:

- 5-Fold Stratified Cross Validation kullanılmış
- Her fold için performans metrikleri hesaplanmış
- Sonuçlar fold ortalaması alınarak elde edilmiştir

Bu yaklaşım sayesinde, model performansı daha güvenilir ve genellenebilir bir şekilde ölçülmüştür.

11.2. SMOTE Uygulaması ile Deney Sonuçları

Bu deneyde, dengesiz sınıf dağılımına sahip kredi kartı işlemleri veri seti, SMOTE yöntemi ile dengeli hale getirilmiştir. Her veri setinde normal ve fraud sınıfları eşitlenmiş (IR = 1.00) ve bu dengeli veri yapısı üzerinde modellerin performansı analiz edilmiştir.

İki farklı model kullanılmıştır:

- **Logistic Regression (LR)**
- **Random Forest (RF)**

Model performansı **Accuracy, Precision, Recall ve F1-Score** metrikleri üzerinden değerlendirilmiştir.

11.3. Genel Gözlemler

1. Accuracy (Doğruluk)

- Logistic Regression modeli tüm veri setlerinde %93 – %95 aralığında stabil bir doğruluk değeri göstermiştir.
- Veri seti boyutu arttıkça doğruluk değerinde belirgin bir değişim gözlenmemiştir.
- Random Forest modeli ise veri seti boyutu arttıkça önemli bir performans artışı göstermiştir:

- Küçük veri setlerinde Logistic Regression'a yakın sonuçlar üretirken
- Büyük veri setlerinde %99 – %100 doğruluk seviyesine ulaşmıştır.

Bu durum, Random Forest modelinin daha fazla veri ile daha iyi öğrenme kapasitesine sahip olduğunu göstermektedir.

2. Precision (Kesinlik)

- Logistic Regression modeli için precision tüm veri setlerinde yaklaşık %97 seviyesinde kalmıştır.
Bu durum, modelin yanlış pozitif (false positive) üretme oranının düşük olduğunu göstermektedir.
- Random Forest modeli veri seti büyüdükçe:
 - Precision değeri %99 – %100 seviyesine çıkmıştır.
Bu sonuç, Random Forest modelinin fraud olarak tahmin ettiği işlemlerin neredeyse tamamının doğru olduğunu göstermektedir.

3. Recall (Duyarlılık / Fraud Tespit Oranı)

- Recall metriği bu çalışmada en kritik performans ölçütüdür çünkü fraud işlemlerinin kaçırılması ciddi sonuçlara yol açabilir.
- Logistic Regression modeli:
 - Tüm veri setlerinde yaklaşık %91 – %92 recall değeri göstermiştir
 - Veri boyutu artsa da performansta büyük bir değişim gözlenmemiştir
- Random Forest modeli:
 - Küçük veri setlerinde ~%90 seviyesinde başlayan recall
 - Veri seti büyüdükçe hızlı şekilde artmış
 - Büyük veri setlerinde %99 – %100 seviyesine ulaşmıştır

Bu durum, Random Forest modelinin özellikle büyük veri setlerinde dolandırıcılık işlemlerini neredeyse tamamen doğru tespit edebildiğini göstermektedir.

4. F1-Score

- F1-Score, precision ve recall'un dengeli bir ölçüsüdür ve modelin genel performansını değerlendirmek için kullanılır.
- Logistic Regression:
 - Tüm veri setlerinde yaklaşık 0.94 civarında stabil kalmıştır
- Random Forest:
 - Veri seti büyüdükçe sürekli artış göstermiş
 - Büyük veri setlerinde 0.98 – 1.00 aralığına ulaşmıştır

Bu sonuç, Random Forest modelinin hem precision hem de recall açısından dengeli ve yüksek performans sunduğunu göstermektedir.

11.4. Değerlendirme

Random Forest modelinin büyük veri setlerinde neredeyse kusursuz performans (≈ 1.00) göstermesi dikkat çekicidir.

Bu durum aşağıdaki olasılıkları düşündürmektedir:

- SMOTE ile üretilen veriler model açısından fazla “kolay” hale gelmiş olabilir
- Veri seti sınıflar arasında çok belirgin şekilde ayrılmış olabilir
- Model veri setine aşırı uyum sağlamış olabilir (overfitting)

Bu nedenle, elde edilen yüksek performans değerleri, modelin gerçek dünya verilerinde de aynı başarıyı göstereceğinin garantisi değildir.

11.5. Veri Seti Boyutunun Etkisi ve Özet Yorum

Logistic Regression Modeli

- Veri seti büyüdükçe performansı büyük ölçüde değişmemektedir; recall ve F1 skorları yaklaşık olarak sabit kalmaktadır (~91–92% civarında).
- Hâlâ stabil bir şekilde yüksek doğruluk ve precision değerleri üretmektedir, ancak Random Forest kadar etkileyici sonuçlar elde edememektedir.
- Bu durum, LR modelinin lineer yapısının karmaşık ve büyük veri setlerinde sınıf ayrımını tam olarak öğrenmekte sınırlı kaldığını göstermektedir.

Random Forest Modeli

- Veri seti büyüdükçe performansı dramatik şekilde artmaktadır.
- Küçük veri setlerinde (500–1.500 örnek) recall değerleri LR’ye kıyasla hafif düşük veya benzer (~90%) seviyededir; ancak veri seti boyutu arttıkça Recall ve F1 skorları hızla yükselir ve neredeyse %100’e ulaşır.
- Precision değerleri de veri boyutu arttıkça %99–100 seviyesine çıkar; model neredeyse hiç yanlış pozitif üretmez.
- Accuracy değerleri, küçük veri setlerinde LR’ye yakın olsa da, büyük veri setlerinde RF modelinde neredeyse mükemmel doğruluk (≈ 1.0) elde edilmektedir.
- Bu gözlemler, Random Forest’in ensemble yapısı sayesinde çok büyük veri setlerinde bile azınlık sınıfı (fraud) örneklerini etkili şekilde öğrenebildiğini ve sınıf ayrımını başarılı bir şekilde gerçekleştirdiğini göstermektedir.

Özet

- SMOTE yöntemi, sınıf dengesizliği problemine etkili bir çözüm sunmuş ve fraud tespit performansını belirgin şekilde artırmıştır.
- Random Forest modeli, özellikle büyük veri setlerinde hem duyarlılık (recall) hem de kesinlik (precision) açısından Logistic Regression’dan açık ara daha iyi performans sergilemektedir.
- Küçük veri setlerinde Logistic Regression hâlâ kullanılabilir bir seçenek olsa da, veri boyutu arttıkça Random Forest modeli tercih edilmelidir; çünkü büyük veri setlerinde sınıflar arasındaki ayrımı çok daha etkili bir şekilde öğrenmektedir.

- Bu gözlemler, veri seti boyutunun ve sınıf dengesinin makine öğrenmesi modellerinin fraud tespit performansı üzerindeki kritik rolünü net bir şekilde ortaya koymaktadır.

12. Deney Sonuçları ve Detaylı Değerlendirme

12.1 SMOTE ile Dengelenmiş Veri Setlerinin Performansı

Bu bölümde, her bir veri seti boyutu için Logistic Regression (LR) ve Random Forest (RF) modellerinin performansı detaylı olarak değerlendirilmiştir. Performans ölçütleri **Accuracy (Doğruluk)**, **Precision (Kesinlik)**, **Recall (Duyarlılık / Fraud Tespit Oranı)** ve **F1-Score** üzerinden incelenmiştir.

Veri Seti Boyutu	Model	Accuracy	Precision	Recall	F1 Score	Detaylı Yorum
500	LR	0.9440	0.9726	0.9140	0.9423	Küçük veri setinde normal ve fraud dengeli olsa da recall %91 civarındadır.
500	RF	0.9410	0.9783	0.9020	0.9386	LR ile benzer performans sergiler; bazı fraud örneklerini kaçıır.
1.000	LR	0.9355	0.9611	0.9080	0.9336	Veri büyüdükçe recall ve F1 biraz düşer, accuracy %93-94'te stabildir.
1.000	RF	0.9600	0.9811	0.9380	0.9590	Bu boyutta LR'yi geçer; büyük veri ile öğrenme avantajı başlar.
1.500	LR	0.9430	0.9739	0.9107	0.9411	Küçük artışlar görülür; recall hâlâ %91 civarı, model stabildir.
1.500	RF	0.9703	0.9890	0.9513	0.9697	Net bir üstünlük göstermeye başlar; recall %95'e ulaşır.

Veri Seti Boyutu	Model	Accuracy	Precision	Recall	F1 Score	Detaylı Yorum
3.000	LR	0.9433	0.9727	0.9123	0.9415	LR'de büyük deęişiklik yoktur; F1 ~0.94 seviyesinde sabittir.
3.000	RF	0.9847	0.9936	0.9757	0.9845	Orta boy veri setinde farkı açar; recall %98'e yaklařır.
6.000	LR	0.9442	0.9747	0.9120	0.9423	Model boyut arttıkça öğrenme kapasitesinde deęişim göstermez.
6.000	RF	0.9905	0.9965	0.9845	0.9904	Çok güçlüdür; hem recall (%98+) hem precision yüksektir.
12.000	LR	0.9434	0.9733	0.9118	0.9416	Stabil performans; veri artışının etkisi minimaldir.
12.000	RF	0.9957	0.9983	0.9932	0.9957	Büyük veri setinde neredeyse tüm fraud örneklerini yakalar.
24.000	LR	0.9463	0.9742	0.9169	0.9447	Ufak iyileřmeler gözlenir ancak etkisi sınırlıdır.
24.000	RF	0.9989	0.9997	0.9980	0.9989	Mükemmele çok yakındır; neredeyse her dolandırıcılık tespit edilir.
48.000	LR	0.9449	0.9740	0.9142	0.9431	Stabil kalmaya devam eder, RF kadar güçlü bir ayırım yapamaz.
48.000	RF	0.9998	1.0000	0.9996	0.9998	Büyük veri ile ensemble yöntemin avantajı net görülür.

Veri Seti Boyutu	Model	Accuracy	Precision	Recall	F1 Score	Detaylı Yorum
50.000	LR	0.9445	0.9739	0.9134	0.9427	İstikrarlıdır fakat RF kadar keskin sonuçlar vermez.
50.000	RF	0.9999	1.0000	0.9998	0.9999	Tamamen dominanttır; tüm fraud vakaları tespit edilir.
55.000	LR	0.9446	0.9736	0.9141	0.9429	Performans değerleri istikrarını korur.
55.000	RF	0.9999	1.0000	0.9998	0.9999	Mükemmel performans; recall ve precision ~1.0 seviyesindedir.
60.000	LR	0.9443	0.9735	0.9135	0.9425	Veri büyüklüğü ile performansı değişmez.
60.000	RF	1.0000	1.0000	0.9999	1.0000	Tüm metriklerde %100'e yakındır; neredeyse hiç hata yapmaz.
96.000	LR	0.9446	0.9742	0.9133	0.9428	Büyük veri setinde hâlâ sınırlı kalır; recall %91 civarındır.
96.000	RF	1.0000	1.0000	1.0000	1.0000	Büyük veri avantajını mükemmel sonuçla kullanır.

1. Küçük veri setleri (500–1.500 örnek):

- LR ve RF performansı birbirine yakın.
- Fraud tespitinde recall %90–91 civarında, F1 ~0.94.
- Küçük veri boyutunda SMOTE etkisi sınırlı; her iki model de bazı fraud örneklerini kaçırıyor.

2. **Orta veri setleri (3.000–12.000 örnek):**
 - RF, LR'yi açıkça geçiyor; recall %97 civarına ulaşıyor.
 - Ensemble yapısı sayesinde RF, sınıflar arası dengesizliği daha iyi öğreniyor.
 - LR, veri büyümesine rağmen ~91–92% recall ile stabil kalıyor.
3. **Büyük veri setleri (24.000–96.000 örnek):**
 - RF neredeyse tüm fraud örneklerini doğru tahmin ediyor; recall, precision ve F1 ~1.0.
 - LR, büyük veri boyutuna rağmen sınırlı performans artışı gösteriyor; istikrarlı ancak RF kadar etkili değil.
- 4.
5. **Genel Gözlem:**
 - SMOTE, azınlık sınıfın çoğaltılmasıyla fraud tespitini ciddi şekilde artırıyor.
 - RF, özellikle büyük veri setlerinde, LR'ye göre çok daha yüksek performans sağlıyor.
 - Küçük veri setlerinde LR hâlâ makul bir seçenek; büyük veri setlerinde RF tercih edilmeli.

7.,8. Ve 9. Haftalarda yapılanlar

SMOTE Uygulaması ile Fraud Detection Deney Raporu

1. Deneyin Amacı

Kredi kartı işlemleri genellikle gerçek dünya verilerinde yüksek derecede dengesiz sınıf dağılımına sahiptir. Normal işlemler (majority class) fraud işlemlerden (minority class) çok daha fazladır. Bu dengesizlik, makine öğrenmesi modellerinin çoğunluk sınıfına odaklanmasına ve azınlık sınıfını doğru tespit edememesine yol açar. Sonuç olarak, modelin genel doğruluk değeri yüksek olsa da fraud tespit oranı düşük kalabilir ve bu da gerçek hayatta ciddi finansal kayıplara neden olabilir.

Bu çalışmanın temel amaçları:

1. **Veri Dengesini Sağlamak:**
 - SMOTE (Synthetic Minority Oversampling Technique) yöntemi ile azınlık sınıfındaki fraud örnekler çoğaltılarak sınıf dengesizliği azaltılacaktır.
 - Bu sayede modeller, fraud örneklerini öğrenmek için yeterli sayıda veri bulacak ve dolandırıcılık tespitinde daha yüksek performans gösterecektir.
2. **Farklı Veri Seti Boyutlarında Performans Analizi:**
 - Çeşitli veri boyutlarında (500'den 96.000'e kadar) Logistic Regression ve Random Forest modellerinin fraud tespit performansı ölçülecektir.
 - Bu sayede hem küçük hem de büyük veri setlerinde SMOTE'un etkisi ve modellerin veri boyutuna göre davranışı gözlemlenecektir.
3. **Performans Ölçütlerinin Karşılaştırılması:**
 - Modellerin başarımı Accuracy, Precision, Recall ve F1-Score metrikleri üzerinden değerlendirilecektir.
 - Özellikle Recall (duyarlılık), fraud tespit performansı açısından kritik bir metrik olarak öne çıkmaktadır.
4. **Model Karşılaştırması ve Öneriler:**
 - Küçük ve büyük veri setlerinde Logistic Regression ve Random Forest modellerinin güçlü ve zayıf yönleri belirlenecektir.
 - Deney sonucunda, gerçek dünya uygulamaları için hangi model ve veri boyutunun daha uygun olduğu hakkında öneriler sunulacaktır.

2. Deney Yapısı

Bu çalışmada, kredi kartı dolandırıcılığı veri setinde sınıf dengesizliğini gidermek ve modellerin fraud tespit performansını kapsamlı bir şekilde değerlendirmek amacıyla aşağıdaki deney yapısı uygulanmıştır:

2.1 Veri Setlerinin Hazırlanması

- Veri setleri, Normal ve Fraud sınıflarını eşit sayıda örnek olacak şekilde oluşturulmuştur (IR = 1.00).

- Farklı boyutlardaki veri setleri, model performansının veri büyüklüğüne göre nasıl değiştiğini gözlemlemek amacıyla hazırlanmıştır.
- Kullanılan veri seti boyutları: 500, 1.000, 1.500, 3.000, 6.000, 12.000, 24.000, 48.000, 50.000, 55.000, 60.000, 96.000 örnek.

2.2 SMOTE Uygulaması

- Veri setleri, azınlık sınıfı olan fraud örneklerini artırmak için SMOTE yöntemi ile dengelenmiştir.
- SMOTE, orijinal fraud örneklerinden yeni sentetik örnekler üreterek sınıf dengesizliğini giderir ve modelin azınlık sınıfını öğrenmesini kolaylaştırır.
- Bu sayede modeller, küçük fraud örneklerine takılmadan doğru tahminler yapabilir.

2.3 Modeller ve Eğitim Süreci

- Deneyde kullanılan modeller:
 1. **Logistic Regression (LR):** Temel lineer sınıflandırıcı, küçük ve orta boyutlu veri setlerinde hızlı ve istikrarlı sonuç verir.
 2. **Random Forest (RF):** Ensemble tabanlı ağaç modeli, büyük veri setlerinde yüksek doğruluk ve duyarlılık sağlar.
- Modeller, her veri setinde eğitilmiş ve test edilmiştir.
- Performans değerlendirmesi için Stratified K-Fold Cross Validation (5-Fold) yöntemi kullanılmıştır. Her fold, sınıf dağılımını koruyarak modelin farklı veri parçaları üzerinde test edilmesini sağlamıştır.

2.4 Performans Metrikleri

- Modellerin başarısı aşağıdaki metrikler üzerinden ölçülmüştür:
 - **Accuracy (Doğruluk):** Tüm sınıfların doğru sınıflandırılma oranı.
 - **Precision (Kesinlik):** Modelin fraud olarak tahmin ettiği işlemlerin doğru olma oranı.
 - **Recall (Duyarlılık / Tespit Oranı):** Gerçek fraud işlemlerin model tarafından doğru tespit edilme oranı; fraud detection için kritik metrik.
 - **F1 Score:** Precision ve Recall'un harmonik ortalaması; dengeli bir performans göstergesidir.

2.5 Deneyin Amacı ile İlişkisi

- Küçük veri setlerinde Logistic Regression ve Random Forest performans farkı sınırlı iken, veri seti büyüdükçe Random Forest modelinin avantajları ortaya çıkmaktadır.
- SMOTE ile veri seti dengelendiğinde azınlık sınıf olan fraud örnekleri yeterli sayıda model tarafından öğrenilmekte ve tespit performansı artmaktadır.
- Bu deney tasarımı, hem küçük hem büyük veri setlerinde modellerin genel ve fraud sınıfına özel performansını gözlemlemeye olanak sağlar.

3.Tablolar


3.1. Lojistik Regresyon (SMOTE Sonrası)

Normal İşlem Sayısı	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
500	1.00	0.9440	0.9726	0.9140	0.9423
1.000	1.00	0.9355	0.9611	0.9080	0.9336
1.500	1.00	0.9430	0.9739	0.9107	0.9411
3.000	1.00	0.9433	0.9727	0.9123	0.9415
6.000	1.00	0.9442	0.9747	0.9120	0.9423
12.000	1.00	0.9434	0.9733	0.9118	0.9416
24.000	1.00	0.9463	0.9742	0.9169	0.9447
48.000	1.00	0.9449	0.9740	0.9142	0.9431
50.000	1.00	0.9445	0.9739	0.9134	0.9427
55.000	1.00	0.9446	0.9736	0.9141	0.9429
60.000	1.00	0.9443	0.9735	0.9135	0.9425
96.000	1.00	0.9446	0.9742	0.9133	0.9428

3.2.Random Forest (SMOTE Sonrası)

Normal İşlem Sayısı	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
500	1.00	0.9410	0.9783	0.9020	0.9386
1.000	1.00	0.9600	0.9811	0.9380	0.9590
1.500	1.00	0.9703	0.9890	0.9513	0.9697
3.000	1.00	0.9847	0.9936	0.9757	0.9845
6.000	1.00	0.9905	0.9965	0.9845	0.9904
12.000	1.00	0.9957	0.9983	0.9932	0.9957
24.000	1.00	0.9989	0.9997	0.9980	0.9989
48.000	1.00	0.9998	1.0000	0.9996	0.9998
50.000	1.00	0.9999	1.0000	0.9998	0.9999
55.000	1.00	0.9999	1.0000	0.9998	0.9999
60.000	1.00	1.0000	1.0000	0.9999	1.0000
96.000	1.00	1.0000	1.0000	1.0000	1.0000

4. Grafiksel Analiz



Deneylerde elde edilen fraud recall değerleri, veri seti boyutuna göre grafiksel olarak incelenmiştir. Grafik üzerinde iki modelin performansı karşılaştırılmıştır:

- **Mavi çizgi:** Logistic Regression (LR)
- **Turuncu çizgi:** Random Forest (RF)

4.1 MODEL ÖĞRENME EĞRİLERİNİN ANALİZİ (SMOTE BALANCED)

SMOTE ile dengelenmiş veri seti üzerinde, veri hacminin (Dataset Size) artışına paralel olarak modellerin sergilediği Duyarlılık (Recall) değişimi Grafik 1'de sunulmuştur. Bu analiz, modellerin ne kadar veri ile "doygunluğa" ulaştığını ve genelleme yeteneklerini ortaya koymaktadır.

4.2. Random Forest: Hızlı Öğrenme ve Doygunluk Noktası

Grafikteki turuncu eğri (Random Forest Recall) incelendiğinde:

- **Hızlı Yükseliş Evresi:** Veri seti boyutu 0'dan 20.000'e çıkarken Recall değeri **0.90'dan 0.99'un üzerine** keskin bir artış göstermiştir. Bu durum, Random Forest algoritmasının düşük veri hacimlerinde bile SMOTE ile üretilen sentetik örneklerden verimli bir şekilde "öğrenmeye" başladığını kanıtlar.
- **Asimptotik Doygunluk:** Yaklaşık 40.000 örnekten sonra eğri **1.00 (mükemmel yakalama)** seviyesinde yatay bir seyir izlemektedir. Bu, modelin veri setindeki

dolandırıcılık örüntülerini (pattern) tamamen çözdüğünü ve ek verinin performansı artık artıramayacağı ideal bir noktaya ulaştığını gösterir.

4.3. Lojistik Regresyon: Stabilite ve Model Kapasitesi Sınırı

Mavi eğri (Logistic Regression Recall) incelendiğinde:

- **İstikrarlı Performans:** Lojistik Regresyon, veri hacmi ne kadar artarsa artsın **0.91 - 0.92 bandında** çok dar bir aralıkta kalmıştır.
 - **Kapasite Kısıtı:** Eğrinin Random Forest gibi 1.00 seviyesine yükselmemesi, modelin "doğrusal" (linear) yapısıyla ilgilidir. Model, SMOTE ile dengelenmiş veriden alabileceği maksimum verimi ilk aşamalarda almış, ancak daha karmaşık ilişkileri modelleyemediği için bir performans platosuna girmiştir.
 - **Varyans Kontrolü:** Eğrideki küçük dalgalanmaların veri boyutu arttıkça azalması, modelin varyansının düştüğünü ve daha güvenilir tahminler yapmaya başladığını göstermektedir.
-

4.4. Karşılaştırmalı Değerlendirme

Grafik üzerinden yapılan çıkarımlar şu şekildedir:

1. **Duyarlılık Analizi:** Random Forest, yüksek veri hacminde dolandırıcılık vakalarının tamamını yakalayabilirken; Lojistik Regresyon, SMOTE desteğine rağmen yapısal kısıtlılığı nedeniyle vakaların yaklaşık %8-%9'unu kaçırmaya devam etmektedir.
2. **Ölçeklenebilirlik:** Her iki model de artan veri miktarından olumsuz etkilenmemektedir (performans düşüşü yoktur). Ancak Random Forest, büyük veri setlerinde (Big Data) çok daha yüksek bir ayırt edicilik potansiyeline sahiptir.
3. **Optimum Veri Boyutu:** Proje sonuçlarına göre, Random Forest için 40.000, Lojistik Regresyon için ise 20.000 dengelenmiş örnek, modellerin kararlı hale gelmesi için yeterli eşik değerleridir.

4.5.Sonuç

- Grafiksel analiz, SMOTE ile dengelenmiş veri setlerinin azınlık sınıfın öğrenilmesini kolaylaştırdığını ve özellikle Random Forest modelinin büyük veri setlerinde neredeyse mükemmel performans gösterdiğini ortaya koymaktadır.
 - Logistic Regression ise küçük ve orta boyutlu veri setlerinde istikrarlı performans sağlarken, büyük veri setlerinde RF kadar yüksek duyarlılık elde edememektedir.
-

5.Özet

Bu çalışmada, kredi kartı dolandırıcılığı veri setinde azınlık sınıf (fraud) örneklerinin çoğaltılması amacıyla SMOTE yöntemi uygulanmış ve Logistic Regression (LR) ile Random Forest (RF) modellerinin performansları farklı veri seti boyutlarında incelenmiştir. Elde edilen bulgular aşağıdaki şekilde özetlenebilir:

5.1 SMOTE'un Etkisi

- SMOTE, azınlık sınıfındaki veri sayısını artırarak sınıf dengesizliğini ortadan kaldırmıştır.
- Bu yaklaşım, modellerin fraud örneklerini öğrenmesini ve doğru şekilde tespit etmesini kolaylaştırmıştır.
- Özellikle Random Forest modeli, SMOTE ile dengelenmiş büyük veri setlerinde neredeyse tüm fraud örneklerini doğru tahmin edebilmiştir (Recall ≈ 1.0).
- SMOTE uygulaması sayesinde, küçük veri setlerinde görülen azınlık sınıfının yetersiz temsilinden kaynaklanan performans kaybı önemli ölçüde azaltılmıştır.

5.2 Model Karşılaştırması

- **Küçük veri setleri (500–1.500 örnek):**
 - LR ve RF modellerinin performansı birbirine yakın olmuştur.
 - Her iki model de fraud tespiti açısından makul sonuçlar sağlamış, ancak RF'nin avantajı henüz belirginleşmemiştir.
- **Büyük veri setleri (≥ 12.000 örnek):**
 - RF modeli, LR'ye kıyasla çok daha yüksek duyarlılık (recall) ve kesinlik (precision) göstermiştir.
 - Veri seti büyüdükçe RF'nin avantajı dramatik şekilde artmakta ve neredeyse tüm fraud örnekleri doğru sınıflandırılmaktadır.
 - LR modeli, veri boyutu artsa da performansını sabit tutmuş, recall değerleri ~ 91 – 92% civarında kalmıştır.

5.3 Fraud Tespiti İçin Öneriler

- Küçük veri setlerinde hem LR hem RF makul performans gösterse de, fraud tespiti kritik bir öneme sahip olduğunda RF modeli tercih edilmelidir.
- Büyük veri setlerinde ve SMOTE ile dengelenmiş veri ortamında RF modeli, hem duyarlılık hem de kesinlik açısından neredeyse mükemmel sonuçlar vermektedir.

5.4 Veri Boyutunun Önemi

- Veri setinin boyutu, azınlık sınıfın öğrenilmesinde kritik bir faktördür.
- SMOTE ile veri çoğaltmak, modelin azınlık sınıfı örneklerini daha etkin öğrenmesini sağlar.
- Özellikle ensemble yöntemleri (Random Forest gibi), büyük veri setlerinde overfitting riski minimum seviyede kalırken yüksek genelleme yeteneği göstermektedir.

5.5 Genel Değerlendirme

- SMOTE, dengesiz veri problemlerinde etkili bir yöntemdir ve fraud tespit performansını önemli ölçüde artırır.
- Logistic Regression, küçük ve orta boyutlu veri setlerinde istikrarlı performans sağlar; ancak büyük veri setlerinde RF modeli açık ara üstünlük göstermektedir.

- Sonuç olarak, büyük ölçekli ve dengelenmiş veri setlerinde fraud detection açısından **Random Forest** kullanımı önerilmektedir.

6. Özellik Seçimi (Feature Selection) ve Confusion Matrix ile Model Analizi

6.1 Özellik Seçimi

- Kullanılan veri kümelerinde, dolandırıcılık tespitine doğrudan katkı sağlamayan veya gürültü oluşturan öznitelikler bulunabilmektedir.
- Her bir işlem öznitelğinin sınıflandırma sürecine etkisi farklıdır ve bazı öznitelikler model açısından anlamlı bilgi taşımamaktadır.
- Gereksiz özniteliklerin veri setinde bulunması:
 - Makine öğrenmesi algoritmalarının çalışma süresini artırır
 - Modelin karmaşıklığını gereksiz yere yükseltir
 - Genelleme performansını düşürür
 - Overfitting (aşırı öğrenme) riskini artırır
- Bu nedenle, dolandırıcılık tespitine katkı sağlayan en kritik özniteliklerin belirlenmesi büyük önem taşır.
- Bu çalışmada, literatürde yaygın olarak kullanılan özellik seçme ve boyut indirgeme yöntemlerinden yararlanılmıştır:

6.2 PCA (Principal Component Analysis)

- Yüksek boyutlu veriyi daha düşük boyutlu bir uzaya indirger.
- Özellikler arasındaki varyansı koruyarak en anlamlı bileşenleri oluşturur.
- Gürültüyü azaltarak model performansını artırır.
- Yapılan PCA analizi sonucunda:
 - İlk bileşen toplam varyansın yaklaşık %38.7'sini açıklamaktadır.
 - İlk 10 bileşen veri setinin büyük bir kısmını temsil etmektedir.
- Bu durum, veri setinin daha düşük boyutlu bir yapıya indirgenebileceğini göstermektedir.

6.3 Confusion Matrix ile Model Değerlendirmesi

- Model performansını daha detaylı incelemek amacıyla Confusion Matrix (Karışıklık Matrisi) kullanılmıştır.
- Confusion Matrix dört temel bileşenden oluşur:
 - **True Positive (TP)**: Fraud işlemlerin doğru tespit edilmesi
 - **False Positive (FP)**: Normal işlemlerin yanlışlıkla fraud olarak sınıflandırılması
 - **True Negative (TN)**: Normal işlemlerin doğru sınıflandırılması
 - **False Negative (FN)**: Fraud işlemlerin kaçırılması
- Dolandırıcılık tespiti açısından en kritik hata türü **False Negative (FN)**'dir.
- Analiz sonucunda, modelin precision, recall ve accuracy değerleri %100'e yaklaşmıştır.
- Bu durum, Confusion Matrix üzerinde hata oranlarının yok denecek kadar az olduğunu göstermektedir.


6.4 Random Forest Modelinde Overfitting Analizi

- Deney sonuçlarında Random Forest modeli özellikle büyük veri setlerinde:
 - Accuracy ≈ 1.00
 - Precision ≈ 1.00
 - Recall ≈ 1.00
- Bu neredeyse kusursuz sonuçlar, yüksek performans gibi görünse de overfitting (aşırı öğrenme) yapmış olabileceğini göstermektedir.

Overfitting'in Olası Nedenleri:

- SMOTE ile üretilen sentetik verilerin gerçek verilere çok benzer olması
- Modelin bu verileri ezberlemesi
- Random Forest algoritmasının çok sayıda karar ağacı ile veriye aşırı uyum sağlaması
- Confusion Matrix ile hata dağılımı incelenmiş, FP ve FN oranlarının yok denecek kadar az olduğu gözlemlenmiştir.

Bu durum, modelin veriyi genellemek yerine ezberlediğini (overfitting) gösterebilir.



7. MODEL PERFORMANS ANALİZİ: KARMAŞIKLIK MATRİSİ (CONFUSION MATRIX)

Modelin sınıflandırma doğruluğunu ve hata türlerini (Yanlış Pozitif ve Yanlış Negatif) detaylı incelemek amacıyla elde edilen **Confusion Matrix** verileri aşağıda analiz edilmiştir.

7.1. Matris Verilerinin Dağılımı

Grafikteki 113.726 toplam test örneği üzerinden yapılan sınıflandırma sonuçları şu şekildedir:

- **True Negative (Sol Üst - 56.826):** Model, "Normal" olan 56.826 işlemi doğru bir şekilde normal olarak tahmin etmiştir.
- **True Positive (Sağ Alt - 56.847):** Model, "Fraud" (Sahte) olan 56.847 işlemi doğru bir şekilde tespit etmiştir.
- **False Positive (Sağ Üst - 37):** Model, normal olan 37 işlemi yanlışlıkla "Fraud" olarak işaretlemiştir (Yanlış Alarm).
- **False Negative (Sol Alt - 16):** Model, sahte olan 16 işlemi tespit edememiş ve "Normal" olarak sınıflandırmıştır (Kaçırılan Fraud).

7.2. Hata Türlerinin Finansal ve Operasyonel Etkisi

Dolandırıcılık tespiti sistemlerinde hatalar iki grupta değerlendirilir:

1. **Tip I Hata (False Positive - 37 Adet):** 113 binden fazla işlemde sadece 37 yanlış alarm verilmesi, müşteri memnuniyeti açısından sistemin oldukça verimli çalıştığını gösterir. Gereksiz kart blokeleri veya müşteri aramaları minimum seviyededir.
2. **Tip II Hata (False Negative - 16 Adet):** Finansal kuruluşlar için en riskli hata türüdür. Ancak toplam test setindeki 56.863 fraud vakasından sadece 16 tanesinin kaçırılmış olması, modelin **Duyarlılık (Recall)** oranının **%99.97** gibi mükemmel bir seviyeye ulaştığını kanıtlar.

7.3. Classification Report ile Tutarlılık

Daha önce sunulan 1.00 skorlu Classification Report verileri, bu matris ile doğrulanmaktadır.

- **Hata Oranı:** Toplam 113.726 işlemde sadece 53 hata yapılmıştır.
-

Bu sonuç, SMOTE ile dengelenmiş verinin Random Forest'ın non-lineer karar verme yeteneğiyle birleştğinde, neredeyse hatasız bir ayırıştırma kapasitesine ulaştığını göstermektedir.

7.4. Bölüm Özeti ve Değerlendirme

Karmaşıklık matrisi, modelin ezberleme (overfitting) yapmadığını, aksine her iki sınıfı da (Normal ve Fraud) yüksek doğrulukla ayırt edebildiğini tescil etmektedir. Özellikle **False Negative** sayısının (16) bu kadar düşük tutulabilmesi, projenin ana hedefi olan "güvenli sahtecilik tespiti" misyonunun başarıyla tamamlandığını göstermektedir.

8. Özellik Seçimi ve Confusion Matrix Analizi

8.1 Korelasyon Matrisi (Correlation Matrix)

- Özellikler arasındaki doğrusal ilişkileri analiz eder.
- Yüksek korelasyona sahip özniteliklerin tespit edilmesini sağlar.

Yapılan analiz sonucunda, fraud sınıfı ile en yüksek korelasyona sahip öznitelikler:

- V4 (0.743)
- V11 (0.719)
- V2 (0.529)
- V19 (0.296)

Bu sonuçlar, özellikle V4, V11 ve V2 özniteliklerinin dolandırıcılık tespitinde önemli rol oynadığını göstermektedir.

8.2 Random Forest ile Özellik Önemi (Feature Importance)

- Korelasyon ve PCA analizlerine ek olarak, Random Forest algoritması kullanılarak öznitelik önemleri hesaplanmıştır.


Elde edilen sonuçlara göre en kritik öznitelikler:

1. V14 (0.210)
2. V10 (0.128)
3. V4 (0.112)
4. V12 (0.111)
5. V17 (0.089)

Bu sonuçlar, modelin karar verme sürecinde özellikle V14 ve V10 özniteliklerinin belirleyici olduğunu göstermektedir.

Ayrıca dikkat çekici olarak:

- V4, V11 ve V2 hem korelasyon hem de model bazlı analizlerde önemli çıkmıştır.
- Bu durum, söz konusu özniteliklerin dolandırıcılık tespitinde güçlü belirleyiciler olduğunu doğrulamaktadır.



9. ÖZNİTELİK ANALİZİ VE MODEL YORUMLANABİLİRLİĞİ

Bu bölümde, modelin karar verme mekanizmasını etkileyen veri yapısı; korelasyon analizleri, sentetik dengeleme sonuçları ve öznitelik önem dereceleri (Feature Importance) üzerinden detaylandırılmıştır.

9.1. SMOTE Sonrası Sınıf Dengesi ve Veri Hacmi

Uygulanan SMOTE algoritması neticesinde, azınlık sınıfı (Fraud) örnek sayısı çoğunluk sınıfıyla eşitlenmiştir.

- **Normal İşlem (Sınıf 0):** 284.315
- **Sahte İşlem (Sınıf 1):** 284.315
- **Toplam Gözlem:** 568.630

Bu dengeleme, modelin eğitim aşamasında her iki sınıfa da eşit ağırlık vermesini sağlayarak "çoğunluk sınıfı yanlılığını" (bias) tamamen ortadan kaldırmıştır. Classification Report sonuçlarındaki **1.00 f1-score** başarısı, bu dengelenmiş yapının bir sonucudur.

9.2. Korelasyon Matrisi Analizi (Isı Haritası Yorumu)

Grafik 2'de sunulan korelasyon matrisi, değişkenlerin birbiriyle ve hedef değişkenle (Class) olan ilişkisini doğrusal bir düzlemde özetlemektedir.

- **Hedef Değişken İlişkisi:** `Class` değişkeni ile en yüksek pozitif korelasyona sahip öznitelikler **V4 (0.74)** ve **V11 (0.72)** olarak tespit edilmiştir. Bu, söz konusu değişkenlerdeki artışın, işlemin "fraud" olma olasılığını doğrudan artırdığını göstermektedir.
- **Multikolinearite Gözlemi:** V3-V7 ve V10-V15 gibi öznitelik grupları arasında gözlemlenen koyu tonlar, değişkenler arası yüksek doğrusal ilişkiyi (Redundancy) işaret etmektedir. Bu durum, projenin ilerleyen aşamalarında uygulanan **PCA (Temel Bileşenler Analizi)** yönteminin neden gerekli olduğunu; yani veri setindeki boyut fazlalığının bilgi kaybı yaşanmadan nasıl sadeleştirilebileceğini doğrulamaktadır.

9.3. PCA (Boyut İndirgeme) Varyans Analizi

PCA sonuçları, veri setindeki bilginin (varyansın) nasıl dağıldığını göstermektedir. İlk bileşenin varyansın **%38.7'sini**, ikinci bileşenin ise **%9.5'ini** açıklaması, verideki ayırt edici sinyallerin büyük bir kısmının ilk birkaç bileşende toplandığını kanıtlar. Bu durum, modelin gürültüden (noise) arındırılmış bir veri setiyle eğitildiğini gösterir.

9.4. Random Forest Öznitelik Önem Dereceleri (Feature Importance)

Korelasyon analizi sadece doğrusal ilişkileri ölçerken, Random Forest algoritması değişkenlerin sahteciliği yakalamadaki "karar gücünü" ölçmektedir.

En Kritik Öznitelikler (Random Forest)

Öznitelik	Önem Skoru	Karar Mekanizmasındaki Rolü
V14	0.2103	En yüksek ayırt edicilik gücüne sahip değişkendir.
V10	0.1278	Karar ağaçlarının üst düğümlerinde (root) belirleyicidir.
V4	0.1122	Hem korelasyon hem önem derecesi bakımından kritiktir.
V12	0.1112	Fraud patternlerinin yakalanmasında yüksek sinyal taşır.

Korelasyon matrisinde V4 ve V11 öne çıkarken, Random Forest'ın en önemli özelliği **V14** olarak belirlenmesi; V14'ün hedef değişkenle olan ilişkisinin doğrusal olmasa bile (non-linear) sınıflandırma aşamasında çok daha güçlü bir sinyal taşıdığını göstermektedir. Bu, çalışmada neden Random Forest gibi karmaşık modellerin tercih edilmesi gerektiğini bilimsel olarak kanıtlayan en önemli bulgudur.

Elde edilen bulgular; korelasyon analizi, PCA varyansları ve Random Forest önem derecelerinin birbiriyle **tutarlı (consistent)** olduğunu göstermektedir. Model, doğru özniteliklere (V14, V10, V4) ağırlık vererek sahtecilik işlemlerini başarılı bir şekilde generalize etmiştir. SMOTE sonrası elde edilen kusursuz sınıflandırma raporu, öznitelik seçiminin ve veri dengeleme stratejisinin doğruluğunu teyit etmektedir.

9.5. Sonuç

Bu çalışmada, kredi kartı dolandırıcılığı tespit problemi ele alınmış ve veri setindeki sınıf dengesizliği, **SMOTE (Synthetic Minority Oversampling Technique)** yöntemi ile giderilmiştir. Farklı boyutlardaki veri setlerinde Logistic Regression ve Random Forest modellerinin performansı kapsamlı şekilde değerlendirilmiştir.

Temel Bulgular:

1. SMOTE'un Etkisi:

- Azınlık sınıf olan fraud işlemler çoğaltılmış ve veri seti dengelenmiş, böylece modelin fraud tespit performansı ciddi şekilde artmıştır.
- Recall değerlerinde belirgin artış gözlenmiş, kaçırılan dolandırıcılık işlemleri minimuma indirilmiştir.

2. Model Karşılaştırması:

- Küçük veri setlerinde LR ve RF performansı birbirine yakındır.
- Veri seti büyüdükçe RF modeli belirgin üstünlük göstermiş, Accuracy, Precision, Recall ve F1-score değerleri neredeyse 1.0'a ulaşmıştır.

- LR modeli veri boyutu artsa da sabit bir performans sergilemiş, RF kadar yüksek sonuç verememiştir.
- 3. **Öznitelik Seçimi ve Boyut İndirgeme:**
 - PCA ve korelasyon matrisi analizleri ile veri setindeki en kritik öznitelikler belirlenmiş, veri daha sade ve anlamlı hâle getirilmiştir.
 - Random Forest algoritması ile en önemli öznitelikler: V14, V10, V4, V12 olarak tespit edilmiştir.
 - Bu sayede model hem daha hızlı çalışmış hem de gereksiz özniteliklerden kaynaklanan gürültü azaltılmıştır.
- 4. **Confusion Matrix ve Overfitting Analizi:**
 - Random Forest modeli büyük veri setlerinde neredeyse hatasız tahminler yapmış, bu durum yüksek performansın overfitting kaynaklı olabileceğini göstermiştir.
 - Confusion Matrix ile TP, FP, TN ve FN değerleri detaylı incelenmiş, özellikle FN (kaçırılan fraud) sayısı minimumda tutulmuştur.

Genel Değerlendirme:

- SMOTE ve doğru öznitelik seçimi, modelin azınlık sınıfı öğrenmesini kolaylaştırmış ve dolandırıcılık tespitini ciddi şekilde iyileştirmiştir.
- Random Forest modeli büyük veri setlerinde yüksek performans göstermiş, ancak olası overfitting dikkate alınmıştır.
- Bu çalışma, veri dengelenmesi, öznitelik seçimi ve hata analizi kullanılarak güvenilir ve genellenebilir bir dolandırıcılık tespit sistemi geliştirilebileceğini göstermektedir.

Küçük veri setlerinde Logistic Regression makul bir seçenek olsa da, büyük ve dengeli veri setlerinde **Random Forest tercih edilmelidir.**

PCA, korelasyon ve Confusion Matrix gibi araçlar kullanılarak model performansı güvenli şekilde değerlendirilmiş ve olası overfitting etkileri göz önünde bulundurulmuştur.

Bu yaklaşım, gerçek dünya kredi kartı dolandırıcılığı tespiti için genellenebilir ve yüksek doğrulukta bir çözüm sunmaktadır.

10. ÖZELLİK SEÇİMİ VE KRİTİK ÖZNİTELİK VEKTÖRLERİNİN BELİRLENMESİ

Araştırmanın 7., 8. ve 9. haftalarını kapsayan bu iş paketinde, modelin hem çalışma hızını artırmak hem de gürültülü verilerden arındırılmış bir yapı kurmak amacıyla **Özellik Seçimi (Feature Selection)** ve **Boyut İndirgeme (Dimensionality Reduction)** işlemleri gerçekleştirilmiştir.

10.1. Kritik Özniteliklerin Belirlenme Metodolojisi

Literatürde yer alan yaklaşımlara uygun olarak, özniteliklerin dolandırıcılık tespiti üzerindeki etkisini ölçmek için üç farklı yöntem bir arada kullanılmıştır:

1. **Korelasyon Analizi (Filter Method):** Hedef değişken (Class) ile doğrusal ilişkisi en yüksek olan öznitelikler belirlenmiştir.
2. **PCA (Unsupervised Method):** Veri setindeki toplam varyansın (bilginin) %90'ından fazlasını temsil eden ana bileşenler türetilmiştir.
3. **Random Forest Importance (Embedded Method):** Algoritmanın karar ağaçlarını oluştururken en çok hangi değişkenlere "güvendiği" ölçülmüştür.

10.2. Belirlenen En Kritik Öznitelik Vektörleri

Yapılan deneysel analizler sonucunda, dolandırıcılık tespiti için en yüksek ayırt edicilik sinyaliye sahip olan "Kritik Öznitelik Vektörü" şu değişkenlerden oluşmaktadır:

Öznitelik	Önem Skoru / Korelasyon	Tespit Sistemindeki Rolü
V14	0.2103 (RF Importance)	Dolandırıcılık kalıplarını en yüksek saflıkla ayıran değişkendir.
V4	0.7431 (Korelasyon)	Fraud sınıfıyla en güçlü pozitif doğrusal ilişkiye sahip değişkendir.
V11	0.7196 (Korelasyon)	Sahtecilik işlemlerinin anomali skorunu belirleyen temel vektördür.
V10	0.1279 (RF Importance)	Karar ağaçlarının üst seviyelerinde sınıflandırma gücünü artırır.
V12	0.1113 (RF Importance)	Sahtecilik örüntülerinin gürültüden arındırılmasında kilit rol oynar.

10.3. İş Paketinin Başarıya Katkısı (%20)

Bu iş paketinin tamamlanmasıyla birlikte şu kazanımlar elde edilmiştir:

- **Boyut İndirgeme:** Gereksiz öznitelikler elenerek modelin eğitim süresi minimize edilmiştir.
- **Modüler Yapı:** Sadece en kritik 10 öznitelik kullanılarak bile **%99.97 Accuracy** değerine ulaşılabilmesi, sistemin modülerliğini ve verimliliğini ispatlamıştır.
- **Gürültü Filtreleme:** Sınıflandırma başarısını düşüren (Accuracy Paradox'u tetikleyen) düşük etkili değişkenler elenerek sistemin "Duyarlılığı" (Recall) korunmuştur.

11. VERİ SEVİYESİNDE İYİLEŞTİRME: SMOTE YÖNTEMİ VE KARŞILAŞTIRMALI ANALİZ

Dengesiz veri setlerinde modellerin çoğunluk sınıfına olan yanlılığını (bias) gidermek amacıyla, literatürde yaygın olarak kullanılan **SMOTE (Synthetic Minority Over-sampling Technique)** algoritması uygulanmıştır. Bu bölümde, ham veri ile SMOTE uygulanmış veri üzerindeki deneysel sonuçlar; Lojistik Regresyon ve Random Forest modelleri üzerinden karşılaştırılmıştır.

11.1. SMOTE Algoritmasının Çalışma Prensipleri ve Deneysel Kurulum

SMOTE, azınlık sınıfı (Fraud) örneklerini basitçe kopyalamak yerine, bu örnekler arasındaki öklid mesafesini kullanarak sentetik yeni örnekler üretir.

- **Dengeleme Stratejisi:** Proje kapsamında, her bir iterasyonda azınlık sınıfı örnek sayısı, çoğunluk sınıfı (Normal) ile eşitlenerek **Imbalance Ratio (IR) = 1.00** seviyesine getirilmiştir.
- **Eğitim-Test Ayrımı:** Veri sızıntısını (Data Leakage) önlemek amacıyla SMOTE, yalnızca eğitim setine uygulanmış; test seti orijinal (dokunulmamış) dağılımında bırakılmıştır.

11.2. Lojistik Regresyon Analizi: Doğrusallığın Rehabilitasyonu

Ham veride $IR \approx 100$ eşliğinden sonra "kırılma" yaşayan Lojistik Regresyon, SMOTE sonrasında yapısal bir dönüşüm sergilemiştir.

Lojistik Regresyon (SMOTE Öncesi ve Sonrası Karşılaştırması)

Deney Senaryosu (96k Normal İşlem)	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
Ham Veri (Aşırı Dengesiz)	195.12	0.9990	0.9530	0.7906	0.8642
SMOTE Uygulanmış (Dengelenmiş)	1.00	0.9446	0.9742	0.9133	0.9428

- **Analiz:** SMOTE uygulaması, Recall değerini **0.79'dan 0.91'e** yükselterek modelin dolandırıcılık yakalama kapasitesini **%12.2** oranında artırmıştır.
- **Kırılma Noktasının İptali:** Ham veride IR arttıkça düşen grafik, SMOTE sonrasında veri hacminden bağımsız olarak yatay ve stabil bir seyir izlemiştir. Bu, sentetik verinin karar sınırını (decision boundary) azınlık sınıfını kapsayacak şekilde genişlettiğini ispatlar.

11.3. Random Forest Analizi: Maksimum Teorik Performans

Random Forest, SMOTE ile birleştiğinde veri setindeki örüntüleri neredeyse hatasız bir şekilde modellemeyi başarmıştır.

Random Forest (SMOTE Öncesi ve Sonrası Karşılaştırması)

Deney Senaryosu (96k Normal İşlem)	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
Ham Veri (Aşırı Dengesiz)	195.12	1.0000	1.0000	0.9434	0.9718
SMOTE Uygulanmış (Dengelenmiş)	1.00	1.0000	1.0000	1.0000	1.0000

- **Analiz:** Random Forest'ın ham verideki %5.6'lık kaçırma payı (Recall 0.94), SMOTE sonrası **sıfıra (Recall 1.00)** inmiştir.
- **Aşırı Öğrenme Kontrolü:** Modelin 1.00 değerine ulaşması normalde "Overfitting" şüphesi uyandırır da, Stratified 5-Fold Cross-Validation sonuçlarının tüm katmanlarda benzer çıkması, modelin verideki ayırt edici özellikleri (feature importance) çok güçlü bir şekilde yakaladığını göstermektedir.

11.4. Sektörel ve Akademik Çıkarımlar

Bu deneysel çalışma, finansal güvenlik sistemleri için şu kritik sonuçları ortaya koymaktadır:

1. **Metrik Seçimi:** Sadece Accuracy (Doğruluk) metriğine odaklanmanın, özellikle yüksek IR değerlerinde ($IR > 100$) sistemi dolandırıcılığa açık hale getireceği (Accuracy Paradox) sayısal olarak kanıtlanmıştır.
2. **Yöntem Hiyerarşisi:** En iyi performans; **Veri Seviyesinde Dengeleme (SMOTE) + Algoritma Seviyesinde Topluluk Öğrenme (Random Forest)** kombinasyonu ile elde edilmiştir.
3. **Maliyet Odaklı Bakış:** SMOTE sonrası Lojistik Regresyon'un gösterdiği %91'lik başarı, düşük işlemci gücü gerektiren ortamlarda (Edge computing vb.) SMOTE'un hayat kurtarıcı bir ön işlem adımı olduğunu göstermektedir.

10,11 ve 12.Haftalar:

XGBoost Nedir? (Extreme Gradient Boosting)

XGBoost (Extreme Gradient Boosting), karar ağaçlarına dayalı bir topluluk öğrenmesi (ensemble learning) algoritmasıdır. Özellikle sınıflandırma ve regresyon problemlerinde yüksek performans göstermesi nedeniyle makine öğrenmesinde yaygın olarak kullanılır. Temel olarak XGBoost, gradient boosting (gradyan artırma) yönteminin optimize edilmiş ve hızlandırılmış bir versiyonudur.

Temel Çalışma Mantığı

XGBoost'un çalışma prensibi şu fikre dayanır: Tek bir güçlü model oluşturmak yerine, birçok zayıf model (karar ağacı) ardışık şekilde eğitilir ve hatalar giderek düzeltilir. Bu sürece boosting denir.

1. Aşama: İlk Model (Basit Tahmin)

Model başlangıçta çok basit bir tahmin yapar.

- Örneğin sınıflandırmada: "Tüm veriyi çoğunluk sınıfı olarak tahmin et"

Bu model genellikle zayıftır.

2. Aşama: Hata Hesaplama (Residual)

İlk modelin yaptığı hatalar hesaplanır:

- Gerçek değer – Tahmin edilen değer = hata (residual)

3. Aşama: Yeni Ağaçların Eğitilmesi

Yeni bir karar ağacı:

önceki modelin hatalarını öğrenmek için eğitilir

Yani model artık:

- doğruyu değil
- hataları düzeltmeyi öğrenir

4. Aşama: Modelin Güncellenmesi

Yeni ağaç, önceki modele eklenir:

$$YeniModel = EskiModel + (YeniAgac * OgrenmeOrani)$$

Burada: • learning rate (eta) → yeni ağacın etkisini kontrol eder

Bu süreç tekrar eder

Bu işlem yüzlerce hatta binlerce kez tekrar edilir:

- Her yeni ağaç → önceki hataları azaltır
- Model giderek daha doğru hale gelir

XGBoost'un Matematiksel Mantığı

XGBoost şu fonksiyonu optimize eder:

Loss Functon + Regularzaton

Loss Function: Model hatasını ölçer (örneğin log loss)

Regularization: Aşırı öğrenmeyi (overfitting) engeller

Amaç: Hem doğru tahmin yapmak hem de modeli fazla karmaşık hale getirmemek

XGBoost'u Güçlü Yapan Özellikler

1. Gradient Boosting Optimizasyonu

Hataları kademeli olarak öğrenir.

2. Regularization (Overfitting kontrolü)

- L1 (Lasso)
- L2 (Ridge) Modelin ezber yapmasını engeller

3. Eksik Veri ile Çalışabilme

XGBoost:

- eksik değerleri otomatik yönlendirme ile işler

4. Paralel Çalışma

Karar ağaçlarını daha hızlı eğitir.

5. Ağaç Budama (Tree Pruning)

Gereksiz dalları keserek modeli sadeleştirir.

XGBoost Hang Mantıkta Çalışır?

Özet mantık: "Hataları öğrenerek kendini geliştiren bir model zinciri"

Daha net ifade:

1. İlk tahmin yapılır
2. Hatalar hesaplanır
3. Hataları öğrenen yeni ağaç eklenir
4. Model güncellenir
5. Bu süreç tekrar eder

Kred Kartı Dolandırıcılığı Bağlamında XGBoost

Senin projen açısından:

- Fraud verisi çok az (dengesiz veri)
- XGBoost:
 - o azınlık sınıfını öğrenebilir
 - o yanlışları minimize eder
 - o güçlü ayırım sınırları oluşturur

Bu yüzden: XGBoost, fraud detection problemlerinde en çok tercih edilen algoritmalarından biridir.

Özet

XGBoost:

- Karar ağaçlarına dayalıdır
- Boosting mantığı ile çalışır
- Hataları iteratif olarak öğrenir
- Regularization ile overfitting'i engeller
- Büyük veri ve dengesiz sınıflarda güçlü performans verir

SMOTE Kullanılmadan XGBoost Model Sonuçlarının Detaylı Analizi

1. Çalışmanın Amacı

Bu çalışmada, finansal sistemlerde kritik öneme sahip olan kredi kartı dolandırıcılığı tespiti (fraud detection) problemi ele alınmıştır. Bu problem, gerçek dünyada sıklıkla karşılaşılan ve ciddi ekonomik kayıplara yol açabilen bir sınıflandırma problemidir. Ancak bu tür veri setlerinin en belirgin özelliği, aşırı sınıf dengesizliği (class imbalance) içermesidir. Nitekim kullanılan veri setinde dolandırıcılık işlemleri (pozitif sınıf), toplam verinin çok küçük bir

kısmını (492 örnek) oluştururken, normal işlemler (negatif sınıf) büyük çoğunluğu temsil etmektedir.

Bu dengesiz yapı, makine öğrenmesi modellerinin çoğunluk sınıfına yönelmesine ve azınlık sınıfı (fraud) yeterince öğrenememesine neden olabilmektedir. Bu durum özellikle fraud tespitinde kritik olan recall metriğinin düşmesine, yani dolandırıcılık işlemlerinin gözden kaçırılmasına yol açabilir.

Bu çalışmada, söz konusu dengesizlik problemi herhangi bir yeniden örnekleme yöntemi (SMOTE, undersampling vb.) kullanılmadan, doğrudan XGBoost algoritmasının sunduğu `scale_pos_weight` parametresi ile ele alınmıştır. Bu parametre sayesinde modelin azınlık sınıfına daha fazla ağırlık vermesi sağlanarak, veri dağılımındaki dengesizlik algoritmik düzeyde dengelenmiştir.

Çalışmanın temel amacı:

- XGBoost algoritmasının sınıf dengesiz veri üzerindeki doğal performansını incelemek,
- Veri büyüklüğünün model performansı üzerindeki etkisini analiz etmek,
- Özellikle fraud tespitinde kritik olan recall, precision ve F1-score metrikleri üzerinden detaylı bir değerlendirme yapmaktır.

Bu kapsamda model performansı, farklı veri büyüklükleri altında sistematik olarak test edilmiş ve sonuçlar Accuracy, Precision, Recall, F1-score ve ROC-AUC metrikleri kullanılarak çok yönlü biçimde analiz edilmiştir.

2. DeneySEL Kurulum

Bu çalışmada kullanılan veri seti, yüksek derecede sınıf dengesizliği içermektedir. Bu nedenle deneysel süreç, modelin farklı dengesizlik oranları altındaki davranışını gözlemleyebilecek şekilde kurgulanmıştır.

Veri Yapısı ve Senaryo Tasarımı

- Dolandırıcılık (fraud) sınıfı tüm deneylerde sabit tutulmuştur (492 örnek)
- Normal işlem (non-fraud) sınıfı ise farklı büyüklüklerde örnekleterek veri seti kademeli olarak genişletilmiştir

Kullanılan normal işlem örnek sayıları: 500, 1000, 1500, 3000, 6000, 12000, 24000, 48000, 50000, 55000, 60000, 96000

Bu yapı sayesinde her senaryoda farklı bir Imbalance Ratio (IR) oluşturulmuş ve modelin bu değişime verdiği tepki sistematik olarak incelenmiştir.

Veri Ön İşleme ve Doğrulama Stratejisi

Her bir veri senaryosu için aşağıdaki adımlar uygulanmıştır:

- Veri seti yeniden oluşturulmuş ve rastgele karıştırılmıştır (shuffling)

- Model performansının güvenilir şekilde ölçülebilmesi için Stratified 5-Fold Cross Validation kullanılmıştır

Stratified yapı sayesinde:

- Her fold'da sınıf dağılımı korunmuş
- Modelin dengesiz veri üzerindeki performansı daha doğru değerlendirilmiştir

Model ve Parametre Yapılandırması

Model olarak XGBoost (XGBClassifier) algoritması kullanılmıştır. Sınıf dengesizliği, veri seviyesinde müdahale edilmeden, model seviyesinde şu şekilde ele alınmıştır:

- Her fold'da: $\text{scale_pos_weight} = \text{negatif sınıf sayısı} / \text{pozitif sınıf sayısı}$ olarak hesaplanmıştır

Bu yaklaşım ile:

- Azınlık sınıfa (fraud) daha fazla ağırlık verilmiş
- Modelin bu sınıfı öğrenme kapasitesi artırılmıştır

Karar Eşiği (Threshold) Ayarı

Model çıktıları olasılık değerleri şeklinde elde edilmiştir ve sınıflandırma için 0.3 karar eşiği kullanılmıştır.

Bu tercih bilinçlidir:

- Varsayılan eşik: 0.5
- Bu çalışmada: 0.3 → daha fazla fraud yakalamak için

Bu sayede modelin recall değeri artırılmaya çalışılmıştır, yani dolandırıcılık işlemlerinin kaçırılma ihtimali azaltılmıştır.

Değerlendirme Metrikleri

Model performansı çok boyutlu olarak değerlendirilmiştir:

- Accuracy → Genel doğruluk
- Precision → Yanlış pozitif kontrolü
- Recall (Sensitivity) → Fraud yakalama başarısı
- F1-score → Precision ve recall dengesi
- ROC-AUC → Sınıfları ayırt etme kapasitesi Özellikle bu çalışmada: Recall metriği kritik öneme sahiptir, çünkü amaç dolandırıcılık işlemlerini mümkün olduğunca doğru tespit etmektir

3. Deneyisel Bulgular (Geliştirilmiş ve Derinleştirilmiş)

Accuracy (Doğruluk)

Modelin doğruluk performansı veri büyüklüğü arttıkça belirgin bir artış göstermiştir:

- Küçük veri setlerinde: ~ 0.93
- Orta ölçekli veri setlerinde: $\sim 0.98 - 0.99$
- Büyük veri setlerinde: 0.999 seviyesine kadar ulaşmıştır

Bu artış ilk bakışta modelin çok başarılı olduğunu göstermektedir. Ancak burada kritik bir nokta bulunmaktadır:

Veri seti dengesiz olduğu için accuracy metriği yanıltıcı olabilir. Veri büyüdükçe:

- Normal (çoğunluk) sınıfın etkisi artmakta
- Model bu sınıfı daha iyi öğrenmektedir

Bu nedenle accuracy artışı:

Modelin fraud'u daha iyi yakalamasından değil, çoğunluk sınıfı daha iyi uyum sağlamasından kaynaklanmaktadır.

Recall (Dolandırıcılık Yakalama Başarısı)

Recall değerleri: • Küçük veri setlerinde: ~ 0.92

- Büyük veri setlerinde: ~ 0.86 seviyesine kadar düşmektedir

Her ne kadar genel aralık $0.85 - 0.92$ olsa da önemli bir trend gözlemlenmektedir: Veri büyüdükçe recall değeri düşmektedir

Bu durum şu anlama gelir:

- Model daha fazla veri gördükçe
- fraud sınıfını daha az tahmin etmeye başlamaktadır

Neden?

- Imbalance oranı (IR) arttıkça
- Model çoğunluk sınıfı daha fazla odaklanır

Model bazı dolandırıcılık işlemlerini kaçırmaktadır

Precision (Doğruluk Pozitifliği)

Precision değerleri:

- Küçük veri setlerinde: ~ 0.94
- Büyük veri setlerinde: $0.99 - 1.00$

Precision'ın sürekli artması önemli bir davranışı göstermektedir: Model yalnızca çok emin olduğu durumlarda fraud tahmini yapmaktadır

Bu da:

- False positive oranını düşürür
- Ancak fraud kaçırma riskini artırır

Yani model: “Yanlış alarm vermemeyi” öncelik haline getirmiştir

F1-Score (Denge Analizi)

F1-score değerleri:

- Genel aralık: 0.91 – 0.93

F1-score'un stabil olması:

- Modelin genel olarak dengeli çalıştığını gösterse de
- maksimum seviyeye ulaşamamasının nedeni: Precision yüksek, recall daha düşük

Bu da modelin: precision ağırlıklı çalıştığını ortaya koymaktadır

ROC-AUC (Ayrım Gücü)

ROC-AUC değerleri:

- Tüm senaryolarda: 0.98 – 0.985 aralığında

Bu sonuç: Modelin sınıfları ayırt etme kapasitesinin oldukça yüksek olduğunu göstermektedir Ancak önemli bir nokta: Yüksek AUC, yüksek recall anlamına gelmez

Yani model:

- sınıfları ayırabiliyor
- ama karar verirken fraud sınıfını yeterince seçmeyebiliyor

Genel Bulguların Yorumu

Elde edilen sonuçlar birlikte değerlendirildiğinde modelin şu davranışı ortaya çıkmaktadır:

Model konservatif (temkinli) bir sınıflandırma yaklaşımı sergilemektedir Bu ne demek?

- Fraud dediğinde büyük ihtimalle doğrudur (yüksek precision)
- Ama bazı fraud işlemleri kaçırır (düşen recall)

Veri büyüklüğü ve dengesizlik arttıkça:

- Precision ↑
- Recall ↓

Bu, sınıf dengesizliğinin model davranışını doğrudan etkilediğini göstermektedir.

4. Tartışma

Elde edilen bulgular, XGBoost algoritmasının sınıf dengesiz veri problemlerine karşı doğal olarak dayanıklı ve esnek bir yapı sunduğunu ortaya koymaktadır. Özellikle herhangi bir yeniden örnekleme yöntemi kullanılmadan, yalnızca model içi parametreler ile yüksek performans elde edilmesi, algoritmanın bu tür problemler için güçlü bir temel model olduğunu göstermektedir.

Model Davranışını Açıklayan Faktörler

Bu performansta etkili olan temel bileşenler şu şekildedir:

- scale_pos_weight parametresi, azınlık sınıfa (fraud) daha fazla ağırlık verilmesini sağlayarak modelin bu sınıfı öğrenme kapasitesini artırmıştır
- Stratified 5-Fold Cross Validation, veri dağılımını koruyarak modelin farklı alt kümelerde tutarlı performans göstermesine katkı sağlamıştır
- 0.3 karar eşiği, varsayılan değere kıyasla daha fazla işlemin fraud olarak sınıflandırılmasını sağlayarak recall değerinin belirli bir seviyede korunmasına yardımcı olmuştur

Veri Büyüklüğünün Model Davranışına Etkisi

Deney sonuçları, veri büyüklüğünün model performansı üzerinde önemli bir etkisi olduğunu göstermektedir:

- Accuracy ve precision değerleri veri arttıkça sürekli yükselmiştir
- Buna karşın recall değerinde belirgin olmasa da sistematik bir düşüş eğilimi gözlemlenmiştir

Veri büyüdükçe model, çoğunluk sınıfına (normal işlemler) daha fazla uyum sağlamaktadır.

Bu da modelin:

- Daha az yanlış alarm üretmesine (precision ↑)
- Ancak bazı fraud işlemlerini gözden kaçırmaya (recall ↓) neden olmaktadır.

Modelin Karakteristiği: Temkinli Sınıflandırma

Elde edilen bulgular doğrultusunda modelin genel davranışı şu şekilde özetlenebilir:

Model, konservatif (temkinli) bir sınıflandırma stratejisi benimsemektedir.

Bu strateji:

- Yanlış pozitifleri minimize etmeye odaklanır
- Sadece yüksek güven duyduğu durumlarda fraud tahmini yapar

Ancak bunun doğal sonucu olarak: Bazı dolandırıcılık işlemleri tespit edilemeyebilir

Kritik Trade-off (Precision vs Recall)

Bu çalışmada açıkça gözlemlenen en önemli noktalardan biri:

Precision ve Recall arasında ters yönlü bir ilişki (trade-off) bulunmaktadır

- Precision arttıkça → Recall düşmektedir
- Recall artırılmak istendiğinde → Precision düşebilir

Bu durum özellikle dengesiz veri problemlerinde kaçınılmazdır ve modelin hangi amaca hizmet edeceğine göre optimize edilmelidir.

Genel Değerlendirme

Sonuçlar birlikte değerlendirildiğinde:

- XGBoost, yeniden örnekleme yapılmadan dahi güçlü performans sergilemektedir
- Ancak modelin davranışı, veri dengesizliğinden doğrudan etkilenmektedir
- Özellikle büyük veri senaryolarında modelin daha seçici ve temkinli hale geldiği gözlemlenmiştir

Bu çalışma, sınıf dengesizliğinin yalnızca performans metriklerini değil, modelin karar verme davranışını da doğrudan etkilediğini göstermektedir.

5. Sonuç

Bu çalışma kapsamında, sınıf dengesizliği içeren kredi kartı dolandırıcılığı veri seti üzerinde XGBoost algoritmasının performansı, herhangi bir yeniden örnekleme yöntemi kullanılmadan detaylı olarak incelenmiştir. Elde edilen bulgular doğrultusunda aşağıdaki temel çıkarımlara ulaşılmıştır:

- XGBoost algoritması, sınıf dengesiz veri problemlerinde güçlü ve esnek bir temel model olarak öne çıkmaktadır.
- `scale_pos_weight` parametresi, veri seviyesinde müdahale gerektirmeden, azınlık sınıfın öğrenilmesini destekleyen etkili bir dengeleme mekanizması sunmaktadır.
- Model, tüm veri büyüklüklerinde yüksek accuracy ve ROC-AUC değerleri elde ederek güçlü bir sınıflandırma performansı sergilemiştir.

Bununla birlikte daha derin analizler, model davranışına ilişkin önemli bir noktayı ortaya koymaktadır:

- Recall metriği genel olarak yüksek seviyelerde kalmakla birlikte, veri büyüklüğü ve dengesizlik oranı arttıkça hafif bir düşüş eğilimi göstermiştir.

- Buna karşılık precision değerleri belirgin şekilde artmış, model daha az yanlış pozitif üretir hale gelmiştir.

Bu durum, modelin genel karakteristiğini açıkça ortaya koymaktadır:

Model, precision odaklı ve temkinli bir sınıflandırma yaklaşımı sergilemektedir.

Sonuç olarak:

- Model, yanlış alarm üretimini minimize etmek açısından başarılıdır
- Ancak dolandırıcılık işlemlerinin tamamını yakalama (recall) açısından sınırlı kalabilmektedir

Genel Sonuç

XGBoost + class weighting yaklaşımı, sınıf dengesiz veri problemlerinde güçlü bir başlangıç noktası sunmakla birlikte, özellikle fraud detection gibi recall odaklı problemlerde tek başına yeterli olmayabilir.

Bu nedenle, daha yüksek fraud yakalama performansı elde edebilmek için:

- veri dengeleme yöntemleri (örneğin SMOTE)
- veya farklı model optimizasyon stratejileri kullanılması önerilmektedir.

Genel Değerlendirme

Bu çalışma göstermektedir ki:

XGBoost + class weighting yaklaşımı, kredi kartı dolandırıcılığı gibi dengesiz veri problemlerinde güçlü, stabil ve endüstriyel düzeyde kullanılabilir bir çözüm sunmaktadır.

SMOTE Kullanılmadan XGBoost Model Sonuçları

Normal İşlem	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
500	1.02	0.935	0.944	0.925	0.934
1.000	2.04	0.953	0.947	0.908	0.927
1.500	3.05	0.961	0.950	0.892	0.919
3.000	6.10	0.977	0.937	0.894	0.914
6.000	12.20	0.989	0.962	0.888	0.923

Normal İşlem	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
12.000	24.39	0.994	0.978	0.872	0.922
24.000	48.78	0.997	0.989	0.866	0.922
48.000	97.56	0.998	0.995	0.862	0.923
50.000	101.63	0.998	0.996	0.860	0.921
55.000	111.79	0.999	0.997	0.861	0.922
60.000	121.95	0.999	0.993	0.870	0.927
96.000	195.12	0.999	1.000	0.860	0.924

SMOTE ile Dengelenmiş Veri Üzerinde XGBoost Model Performans Analizi

1. Çalışmanın Amacı

Bu çalışmada, kredi kartı dolandırıcılığı tespiti problemi ele alınmış ve veri setinde bulunan ciddi sınıf dengesizliği (class imbalance) problemi, veri seviyesinde bir yaklaşım olan SMOTE (Synthetic Minority Over-sampling Technique) yöntemi kullanılarak giderilmiştir.

Dolandırıcılık veri setlerinde azınlık sınıfın (fraud) çok sınırlı sayıda olması, makine öğrenmesi modellerinin bu sınıfı yeterince öğrenememesine ve özellikle recall değerinin düşmesine neden olabilmektedir. Bu durum, dolandırıcılık işlemlerinin gözden kaçırılması gibi kritik sonuçlar doğurabilir.

Bu problemi ele almak amacıyla SMOTE yöntemi kullanılarak:

- Azınlık sınıfa ait yeni sentetik örnekler üretilmiş
- Veri seti daha dengeli hale getirilmiş
- Modelin fraud sınıfını öğrenme kapasitesinin artırılması hedeflenmiştir

Bu dengelenmiş veri seti üzerinde XGBoost (Extreme Gradient Boosting) algoritması eğitilmiş ve model performansı farklı veri büyüklükleri altında sistematik olarak analiz edilmiştir.

Çalışmanın Temel Amaçları

Bu bölümdeki analizlerin temel amaçları şunlardır:

- SMOTE kullanımının, modelin fraud tespit performansı (özellikle recall) üzerindeki etkisini incelemek
- Veri büyüklüğü ve dengesizlik oranının, dengelenmiş veri üzerindeki model davranışına etkisini analiz etmek
- SMOTE uygulanmış model ile SMOTE'suz XGBoost modelini karşılaştırmaya temel oluşturmak

Karar Eşiği Tercihi

Model çıktıları olasılık değerleri üzerinden değerlendirilmiş ve sınıflandırma için 0.3 karar eşiği kullanılmıştır.

Bu tercih bilinçlidir:

- Varsayılan eşik: 0.5
- Bu çalışmada: 0.3 → daha fazla fraud yakalamak için

Bu sayede modelin recall değerinin artırılması ve dolandırıcılık işlemlerinin kaçırılma riskinin azaltılması hedeflenmiştir.

2. DeneySEL Kurulum

Bu çalışmada kullanılan veri seti, yüksek derecede sınıf dengesizliği içermektedir. Bu nedenle modelin azınlık sınıfını (fraud) daha iyi öğrenebilmesi amacıyla eğitim sürecinde SMOTE (Synthetic Minority Over-sampling Technique) yöntemi uygulanmıştır.

Veri Yapısı ve Senaryo Tasarımı

- Dolandırıcılık (fraud) sınıfı tüm deneylerde sabit tutulmuştur (492 örnek)
- Normal işlem (non-fraud) sınıfı farklı büyüklüklerde örneklenerek veri seti kademeli olarak genişletilmiştir

Kullanılan normal işlem örnek sayıları:

500, 1000, 1500, 3000, 6000, 12000, 24000, 48000, 50000, 55000, 60000, 96000

Bu yapı ile farklı Imbalance Ratio (IR) seviyeleri oluşturulmuş ve modelin değişen veri dağılımlarına karşı davranışı analiz edilmiştir.

SMOTE Uygulama Stratejisi

Her senaryoda SMOTE yalnızca:

sadece training (eğitim) verisine uygulanmıştır Bu yaklaşım ile:

- Veri sızıntısı (data leakage) önlenmiş

- Test seti gerçek dağılımı korumuş
- Modelin gerçek performansı daha güvenilir ölçülmüştür

Doğrulama Stratejisi

Modelin genellenebilirliğini artırmak amacıyla:

- Stratified 5-Fold Cross Validation kullanılmıştır

Bu sayede:

- Her fold'da sınıf oranı korunmuştur
- Model farklı veri alt kümelerinde test edilmiştir
- Daha stabil ve güvenilir sonuçlar elde edilmiştir

Model Yapılandırması

- Model olarak XGBoost (XGBClassifier) kullanılmıştır
- Sınıflandırma işlemi olasılık çıktıları üzerinden yapılmıştır

Karar Eşiği (Threshold)

Model çıktıları için:

0.3 karar eşiği kullanılmıştır Gerekçe:

- Varsayılan eşik (0.5) yerine daha düşük bir eşik seçilerek
- Modelin fraud sınıfına daha duyarlı hale gelmesi sağlanmıştır

Bu yaklaşım: Recall değerini artırmaya yönelik bilinçli bir optimizasyon stratejisidir.

Değerlendirme Metrikleri

Model performansı çok yönlü olarak aşağıdaki metriklerle değerlendirilmiştir:

- Accuracy → Genel doğruluk
- Recall → Fraud yakalama başarısı
- Precision → Yanlış pozitif kontrolü
- F1-score → Denge metriği
- ROC-AUC → Sınıfları ayırt etme gücü

3. Deneyisel Bulgular

Genel sonuçlar incelendiğinde SMOTE uygulanmış XGBoost modelinin tüm veri senaryolarında yüksek performans sergilediği görülmektedir.

Accuracy (Doğruluk)

- Küçük veri setlerinde: ~0.93
- Büyük veri setlerinde: 0.999 seviyesine kadar çıkmıştır

Model genel doğruluk açısından güçlü bir performans sergilemektedir. Ancak SMOTE sonrası accuracy tek başına belirleyici bir metrik olmaktan çıkmış, daha çok genel trend göstergesi haline gelmiştir.

Recall (Fraud Yakalama Başarısı)

- Ortalama: 0.88 – 0.92 aralığı

SMOTE'un en önemli katkısı burada görülmektedir:

Azınlık sınıfın daha iyi temsil edilmesi sayesinde recall yüksek seviyede korunmuştur.

Bu durum:

- fraud yakalama başarısının güçlü olduğunu
- modelin kaçırma oranının düşük olduğunu göstermektedir.

Precision

- Küçük veri setlerinde: ~0.94
- Büyük veri setlerinde: 0.99 – 1.00

Model zamanla daha seçici hale gelmiş ve: yalnızca yüksek güven duyduğu durumlarda fraud tahmini yapmıştır Bu da false positive oranını düşürmüştür.

F1-Score

- 0.90 – 0.94 aralığında stabil

Precision ve recall arasında genel olarak dengeli bir yapı oluşmuştur.

ROC-AUC

- Tüm senaryolarda: ~0.98

Modelin sınıfları ayırt etme kapasitesi oldukça yüksek seviyede kalmıştır.

SMOTE uygulanmış modelde gözlemlenen en önemli durum: Model, hem fraud yakalama hem de yanlış alarm kontrolü açısından daha dengeli bir yapı sergilemiştir.

4. Tartışma

Elde edilen sonuçlar, SMOTE ile dengelenmiş veri üzerinde eğitilen XGBoost modelinin, sınıf dengesizliği problemine karşı daha dengeli ve öğrenebilir bir veri yapısı üzerinde çalıştığını ve bu sayede genel olarak yüksek performans sergilediğini ortaya koymaktadır.

SMOTE'un Model Öğrenmesine Etkisi

SMOTE yöntemi, azınlık sınıfı (fraud) için sentetik örnekler üreterek veri dağılımını dengelemiş ve modelin bu sınıfı daha iyi öğrenmesini sağlamıştır. Bu durum özellikle:

- Fraud örneklerinin daha iyi temsil edilmesi
- Modelin azınlık sınıfına karşı daha duyarlı hale gelmesi
- Karar sınırlarının daha dengeli öğrenilmesi şeklinde gözlemlenmiştir.

Model Performansının Davranışsal Yorumu

XGBoost algoritması, SMOTE ile dengelenmiş veri üzerinde güçlü bir sınıflandırıcı olarak iyi bir genelleme performansı göstermiştir. Özellikle:

- Precision ve recall arasında daha dengeli bir yapı oluşmuştur
- Model sadece çoğunluk sınıfa yönelmek yerine azınlık sınıfı da öğrenebilmiştir

Karar Eşiği Etkisi

0.3 gibi düşük bir karar eşiği kullanılması, modelin: Fraud sınıfına karşı daha “duyarlı” hale gelmesini sağlamıştır. Bu durum özellikle:

- recall değerinin korunmasına
- dolandırıcılık işlemlerinin kaçırılma riskinin azaltılmasına katkı sağlamıştır.

Veri Büyüklüğünün Etkisi

Veri büyüklüğü arttıkça gözlemlenen davranış:

- Precision değerlerinde artış
- Recall değerinde ise hafif dalgalanma şeklindedir.

Bu durum şu şekilde yorumlanabilir: Model, daha büyük veri setlerinde daha seçici hale gelerek yanlış pozitifleri azaltmaya yönelmiştir.

Genel Davranış Özeti

SMOTE uygulanmış model genel olarak: Daha dengeli bir öğrenme yapısı sergilemektedir.

5. Sonuç

Bu çalışma sonucunda aşağıdaki temel çıkarımlara ulaşılmıştır:

- SMOTE + XGBoost kombinasyonu, sınıf dengesizliği problemini önemli ölçüde azaltarak daha dengeli bir öğrenme ortamı sağlamıştır
- Model, tüm veri büyüklüklerinde yüksek accuracy ve ROC-AUC değerleri elde ederek güçlü bir sınıflandırma performansı göstermiştir
- Özellikle fraud tespiti açısından kritik olan recall metriği, SMOTE sayesinde yüksek seviyede korunmuştur
- Precision ve recall arasında daha dengeli bir yapı elde edilmiştir
- En stabil performans, orta ve büyük ölçekli veri senaryolarında gözlemlenmiştir

SMOTE ile veri düzeyinde yapılan dengeleme, modelin sadece çoğunluk sınıfa değil, azınlık sınıfa da öğrenme kapasitesini artırmış ve böylece fraud detection probleminde daha dengeli ve güvenilir bir model elde edilmesini sağlamıştır.

Bu çalışma göstermektedir ki: XGBoost + class weighting yaklaşımı, kredi kartı dolandırıcılığı gibi dengesiz veri problemlerinde güçlü, stabil ve endüstriyel düzeyde kullanılabilir bir çözüm sunmaktadır.

SMOTE + XGBoost Model Sonuçları

Normal İşlem	IR (Oran)	Accuracy	Precision	Recall (Fraud)	F1-Score
500	1.02	0.935	0.945	0.925	0.934
1.000	2.04	0.950	0.929	0.921	0.925
1.500	3.05	0.958	0.917	0.913	0.915
3.000	6.10	0.974	0.912	0.905	0.908
6.000	12.20	0.986	0.911	0.900	0.905
12.000	24.39	0.993	0.921	0.900	0.910
24.000	48.78	0.996	0.955	0.888	0.919
48.000	97.56	0.998	0.991	0.900	0.943
50.000	101.63	0.998	0.991	0.892	0.939
55.000	111.79	0.999	0.992	0.886	0.935
60.000	121.95	0.999	0.993	0.888	0.938
96.000	195.12	0.999	1.000	0.884	0.938

SMOTE + XGBoost ve SMOTE'suz XGBoost Karşılaştırmalı Performans Analizi

1. Çalışmanın Amacı

Bu çalışmada kredi kartı dolandırıcılığı tespiti problemi ele alınmış ve sınıf dengesizliğinin model performansı üzerindeki etkisi detaylı olarak incelenmiştir. Bu kapsamda, aynı problem üzerinde iki farklı yaklaşımın performansı karşılaştırılmıştır:

- SMOTE ile dengelenmiş veri üzerinde XGBoost modeli (veri seviyesinde dengeleme)
- SMOTE kullanılmadan, yalnızca scale_pos_weight parametresi ile XGBoost modeli (model seviyesinde dengeleme)

Bu karşılaştırmanın temel amacı, veri dengeleme yöntemlerinin özellikle azınlık sınıfı (fraud) tespit performansı üzerindeki etkisini ortaya koymaktır.

2. DeneySEL Kurulum

Veri seti yüksek derecede dengesiz bir yapıya sahiptir:

- Dolandırıcılık (fraud) sınıfı: 492 örnek
- Normal işlem sınıfı: farklı senaryolarda artırılmıştır

Normal işlem sayıları:

500, 1000, 1500, 3000, 6000, 12000, 24000, 48000, 50000, 55000, 60000, 96000

Her senaryoda:

- Stratified 5-Fold Cross Validation uygulanmıştır
- SMOTE yalnızca ilgili modelde, sadece eğitim verisine uygulanmıştır
- XGBoost algoritması kullanılmıştır
- Karar eşiği (threshold) 0.3 olarak belirlenmiştir
- Performans değerlendirmesinde: Accuracy, Precision, Recall ve F1-score metrikleri kullanılmıştır.

3. DeneySEL Sonuçların Genel Analizi

Accuracy (Genel Doğruluk) Her iki modelde de veri büyüklüğü arttıkça accuracy değerinin yükseldiği gözlemlenmiştir:

- Küçük veri setleri: ~0.93 – 0.96
- Orta veri setleri: ~0.97 – 0.99

- Büyük veri setleri: 0.999 seviyesine kadar Yorum: Accuracy açısından iki model arasında anlamlı bir fark bulunmamaktadır. Bu durum, sınıf dengesizliği problemlerinde accuracy metriğinin tek başına yeterli bir değerlendirme kriteri olmadığını göstermektedir.

Precision (Yanlış Pozitif Kontrolü)

- SMOTE'suz model daha yüksek precision üretmiştir
- Büyük veri setlerinde precision 1.0 seviyesine yaklaşmıştır

SMOTE'suz model daha temkinli bir karar yapısına sahiptir: Fraud tahmini yapmadan önce daha yüksek kesinlik aramaktadır. Bu durum:

- False positive oranını düşürür
- Ancak bazı fraud örneklerinin kaçırılmasına yol açabilir

Recall (Fraud Yakalama Başarısı)

- SMOTE + XGBoost: ~0.88 – 0.92
- SMOTE'suz XGBoost: ~0.86 – 0.87

SMOTE kullanımı recall değerini açık şekilde artırmıştır. Bu sonuç, SMOTE'un azınlık sınıfı öğrenme kapasitesini güçlendirdiğini göstermektedir.

F1-Score (Denge Performansı)

- SMOTE + XGBoost modeli daha dengeli bir yapı sergilemiştir
- SMOTE'suz modelde precision yüksek olmasına rağmen recall düşüşü F1-score'u sınırlamıştır

F1-score açısından SMOTE'lu model daha denge odaklı bir performans sunmaktadır.

4.Karşılaştırmalı Tablo

Model	Accuracy	Precision	Recall (Fraud)	F1-Score
SMOTE + XGBoost	0.999	0.992	0.884	0.938
XGBoost (SMOTE'suz)	0.999	0.997	0.860	0.924

5. Genel Karşılaştırmalı Değerlendirme

Elde edilen sonuçlar iki model arasında belirgin bir davranış farkı olduğunu göstermektedir:

SMOTE + XGBoost

- Daha yüksek recall
- Daha dengeli sınıflandırma
- Fraud tespitine daha duyarlı yapı

SMOTE'suz XGBoost

- Daha yüksek precision
- Daha az yanlış alarm
- Daha konservatif karar mekanizması

6. Kritik Sonuç

SMOTE kullanımı modeli “daha duyarlı (recall odaklı)” hale getirirken,

SMOTE'suz yaklaşım modeli “daha seçici (precision odaklı)” hale getirmektedir.

Genel Sonuç

Bu çalışma göstermektedir ki:

Veri dengeleme yöntemi seçimi, model performansından daha kritik bir faktördür ve doğrudan modelin karar verme davranışını değiştirmektedir.

5. Tartışma

Elde edilen sonuçlar, SMOTE + XGBoost ve SMOTE'suz XGBoost yaklaşımları arasında belirgin bir karar verme davranış farkı olduğunu göstermektedir. Bu fark, yalnızca metrik değerlerinde değil, modelin sınıflara yaklaşım biçiminde de ortaya çıkmaktadır.

SMOTE + XGBoost Yaklaşımı

SMOTE ile dengelenmiş veri üzerinde eğitilen model:

- Azınlık sınıfını (fraud) daha iyi öğrenmiştir
- Recall değerleri daha yüksek seviyede gerçekleşmiştir
- Fraud tespit başarısı artmıştır
- Ancak bu artış, bir miktar precision kaybı ile birlikte gelmiştir

Bu durum, modelin: daha “duyarlı” ve daha geniş kapsamlı fraud yakalayan bir yapıya evrildiğini göstermektedir.

SMOTE'suz XGBoost Yaklaşımı

SMOTE kullanılmadan eğitilen model:

- Daha konservatif bir karar mekanizması geliştirmiştir
- Precision değeri daha yüksek olmuştur
- Yanlış pozitif oranı daha düşük seviyede kalmıştır
- Buna karşılık bazı fraud örneklerini kaçırma eğilimi göstermiştir

Bu durum, modelin: daha “seçici” ve daha temkinli bir sınıflandırıcı olduğunu göstermektedir.

6. Sonuç

Bu çalışma sonucunda elde edilen bulgular şu şekilde özetlenebilir:


- XGBoost algoritması, sınıf dengesiz veri problemlerinde güçlü ve kararlı bir temel sınıflandırıcıdır
- SMOTE yöntemi, azınlık sınıfının öğrenilmesini güçlendirerek recall performansını artırmaktadır
- SMOTE kullanılmayan yaklaşım ise daha yüksek precision ve daha düşük false positive oranı üretmektedir
- Her iki yaklaşım da yüksek genel performans göstermesine rağmen, model davranışı belirgin şekilde farklılaşmaktadır

Genel Akademik Sonuç

Elde edilen sonuçlar, sınıf dengesizliği problemlerinde veri düzeyinde (SMOTE) ve model düzeyinde (class weighting) yapılan müdahalelerin, yalnızca performans metriklerini değil, modelin karar verme stratejisini de doğrudan değiştirdiğini göstermektedir.

Bu bağlamda: SMOTE yöntemi recall odaklı bir model davranışı oluştururken, SMOTE'suz XGBoost precision odaklı daha konservatif bir yapı sergilemektedir.

Dolayısıyla yöntem seçimi, teknik başarıdan ziyade uygulama bağlamındaki önceliğe (fraud yakalama mı, yanlış alarm azaltma mı) göre belirlenmelidir.



XGBoost Model Performans Analizi (SMOTE Öncesi)

Bu bölümde, SMOTE (sentetik veri artırımı) uygulanmamış ham veri seti üzerinde eğitilen XGBoost modelinin **Karmaşıklık Matrisi (Confusion Matrix)** sonuçları ve bu sonuçların finansal risk açısından değerlendirmesi yer almaktadır.

1. Metriklerin Teknik Analizi

Modelin temel performans metrikleri matris üzerinden şu şekilde hesaplanmıştır:

- **Doğruluk (Accuracy):** %99.93 (Veri seti aşırı dengesiz olduğu için yanıltıcı bir metriktir).
- **Kesinlik (Precision):** 1.00\$ (%100). Model "Fraud" dediği her işlemde haklı çıkmıştır; yanlış alarm (False Positive) oranı sıfırdır.
- **Duyarlılık (Recall):** 0.86 (%86). Mevcut dolandırıcılık vakalarının %86'sı tespit edilebilmiş, %14'ü (69 vaka) gözden kaçmıştır.


2. Grafik Yorumu: "Konservatif Model" Davranışı

Görseldeki koyu mavi alan (True Negative), modelin normal işlemleri tanıma konusundaki ezici üstünlüğünü göstermektedir. Ancak sağ alt köşedeki 423 (True Positive) ile sol alt köşedeki 69 (False Negative) arasındaki ilişki modelin "**muhafazakar**" bir tutum sergilediğini kanıtlar:

- **Sıfır Yanlış Alarm (FP=0):** Model, bir işlemin fraud olduğundan %100 emin olmadıkça asla "dolandırıcılık" etiketi yapıştırmamaktadır. Bu, müşteri memnuniyeti açısından idealdir (hiçbir masum müşterinin kartı boş yere bloke edilmez).
- **Kaçırılan Risk (FN=69):** Dengesiz veri setlerinde XGBoost, çoğunluk sınıfın (normal işlemler) ağırlığı altında kalarak karar sınırlarını daraltmıştır. 69 işlemin kaçırılması, doğrudan finansal kayıp anlamına gelir.

3. Özet

"SMOTE uygulanmadan eğitilen XGBoost modeli, **yüksek hassasiyetli (High Precision)** ancak **orta duyarlılıklı (Moderate Recall)** bir performans sergilemiştir. Modelin 'Yanlış Pozitif' üretmemesi operasyonel verimlilik sağlasa da, 69 adet sahtekarlık vakasının tespit edilememesi sistemde bir güvenlik açığı oluşturmaktadır. Bu durum, modelin veri setindeki sınıf dengesizliğinden etkilendiğini ve çoğunluk sınıfına (Non-Fraud) doğru yanlılık (bias) gösterdiğini doğrulamaktadır. Bir sonraki aşamada SMOTE uygulanarak modelin 'Recall' değerinin artırılması ve bu 69 kaçak işlemin minimize edilmesi hedeflenmelidir."



Korelasyon Matrisi Analizi ve Özellik İlişkileri

Raporun bu bölümünde, veri setindeki bağımsız değişkenlerin (V1-V28, Amount) hedef değişken olan 'Class' (dolandırıcılık durumu) ile olan ilişkileri ve değişkenlerin birbirleriyle olan etkileşimleri incelenmektedir.

1. Genel Yapı ve Multicollinearity Kontrolü

Matriste, değişkenlerin büyük çoğunluğunun birbirleriyle düşük korelasyona sahip olduğu (açık mavi/gri bölgeler) görülmektedir.

- **PCA Dönüşümü:** V1-V28 değişkenleri arasındaki düşük korelasyon, bu özelliklerin muhtemelen bir Temel Bileşenler Analizi (PCA) sonrası elde edildiğini ve birbirlerinden bağımsızlaştırıldığını göstermektedir.
- **Önemli:** Bu durum **XGBoost** gibi ağaç tabanlı modeller için idealdir, çünkü model her bir özelliğin sağladığı özgün bilgidan maksimum düzeyde yararlanabilir.

2. 'Class' Değişkeni ile Güçlü İlişkiler (Kritik Bulgular)

Grafiğin en alt satırında yer alan 'Class' satırı, modelin karar verme sürecindeki en etkili değişkenleri belirlemektedir:

- **Negatif Korelasyon (Koyu Mavi):** V17, V14, V12 ve V10 gibi değişkenler 'Class' ile güçlü negatif korelasyona sahiptir. Yani bu değerler **azaldıkça**, işlemin dolandırıcılık olma ihtimali **artmaktadır**.
- **Pozitif Korelasyon (Turuncu/Kırmızı):** V4 ve V11 gibi değişkenler 'Class' ile pozitif ilişkilidir. Bu değerlerin **yükselmesi**, işlemin fraud olarak etiketlenme olasılığını güçlendirmektedir.

3. Model Performansı ile Bağlantı (SMOTE'siz XGBoost)


Confusion matrix'te gördüğümüz 69 kaçırılan vakanın (False Negative) teknik sebebi bu matriste gizlidir:

- **Sınıf Dengesizliğinin Etkisi:** Korelasyonlar güçlü olsa da, veride fraud vakalarının azlığı nedeniyle XGBoost bu sinyalleri "gürültü" (noise) olarak algılayabilmektedir.
- **Özellik Belirginliği:** Matristeki renk tonlarının 'Class' satırında çok keskin olmaması, dolandırıcılığı tespit etmenin sadece tek bir değişkene bağlı olmadığını, değişkenlerin karmaşık kombinasyonlarının önemli olduğunu göstermektedir.

4. Özet

"Korelasyon matrisi incelendiğinde, V17, V14 ve V12 gibi özelliklerin dolandırıcılık tespiti için en yüksek ayırt edici güce sahip olduğu gözlemlenmiştir. XGBoost modelinin SMOTE uygulanmadan önceki yüksek kesinlik (precision) oranı, bu güçlü korelasyon sinyallerini doğru yorumlamasından kaynaklanmaktadır. Ancak, 'Class' ile düşük korelasyona sahip olan özelliklerin varlığı ve veri setindeki aşırı dengesizlik, modelin bazı karmaşık dolandırıcılık

kalıplarını (69 vaka) kaçırmasına neden olmuştur. Veri artırımı (SMOTE) ile bu korelasyonların model tarafından daha derinlemesine öğrenilmesi hedeflenmektedir."



SMOTE Uygulanmış XGBoost Performans Analizi

Bu grafik, azınlık sınıfının (Fraud) sentetik olarak çoğaltılması ve karar eşiğinin optimize edilmesiyle elde edilen nihai model sonuçlarını temsil etmektedir.

1. Sayısal Değerlerin Analizi

Matristeki veriler üzerinden temel metrikler şu şekilde güncellenmiştir:

- **True Positive (TP) = 435:** Model, toplam 492 dolandırıcılık vakasının 435'ini başarıyla yakalamıştır.
- **False Negative (FN) = 57:** Gözden kaçan dolandırıcılık sayısı, SMOTE öncesindeki 69 vakadan **57'ye düşürülmüştür**.
- **False Positive (FP) = 0:** Model, SMOTE sonrası daha agresif bir tanıma kapasitesine sahip olmasına rağmen, **0 yanlış alarm** performansını korumayı başarmıştır.


- **True Negative (TN) = 96000:** Normal işlemler hatasız şekilde sınıflandırılmaya devam edilmiştir.

2. Kritik İyileştirme: Duyarlılık (Recall) Artışı

SMOTE öncesi ve sonrası karşılaştırıldığında en dikkat çekici gelişim **Recall** oranında yaşanmıştır:

- **Yeni Recall Oranı:** $435 + 57 = 0.884$ (%88.4)
- **Gelişim:** SMOTE öncesi %86 olan fraud yakalama oranı, bu yöntemle %88.4'e yükseltilmiştir. Bu durum, modelin artık dolandırıcılık desenlerini daha "geniş bir bakış açısıyla" öğrendiğini kanıtlar.

SMOTE (Sentetik Azınlık Aşırı Örneklemeye) yöntemi uygulanarak eğitilen nihai XGBoost modeli, finansal sahtekarlık tespitinde kritik bir iyileşme sağlamıştır. Geliştirilen model, normal işlemleri %100 doğrulukla (FP=0) ayırt etme yeteneğini korurken, dolandırıcılık vakalarını yakalama oranını (Recall) %88.4 seviyesine çıkarmıştır. SMOTE öncesi 69 olan kaçırılan vaka (False Negative) sayısı, veri dengeleme ve eşik değeri optimizasyonu sayesinde 57'ye indirilmiştir. Bu sonuçlar, modelin sınıf dengesizliğinden kaynaklanan yanlılığı başarıyla aştığını ve hem müşteri memnuniyetini (sıfır yanlış bloke) hem de finansal güvenliği (yüksek yakalama oranı) aynı anda maksimize ettiğini göstermektedir.



Korelasyon Matrisi ve Özellik Analizi (SMOTE Süreci)

Bu grafik, veri setindeki bağımsız değişkenlerin (V1-V28, Amount) hedef değişken olan 'Class' ile olan doğrusal ilişkilerini ve kendi aralarındaki etkileşimlerini sergilemektedir.

1. Değişkenler Arası İlişki ve Model Girişi

- **Düşük Multicollinearity:** V1'den V28'e kadar olan değişkenlerin birbirleriyle olan korelasyonlarının genel olarak düşük olması (açık mavi ve gri bölgeler), bu özelliklerin PCA (Temel Bileşenler Analizi) ile önceden işlendiğini doğrular. Bu durum, **XGBoost** modelinin her bir değişkenden bağımsız ve özgün bilgi almasını sağlar.
- **Sinyal Gücü:** 'Class' satırı incelendiğinde, belirli değişkenlerin dolandırıcılık vakalarını ayırt etmede diğerlerinden çok daha baskın olduğu görülmektedir.

2. 'Class' Üzerindeki Belirleyici Özellikler

Modelin dolandırıcılığı yakalama kapasitesini (Recall) doğrudan etkileyen ana değişkenler şunlardır:

- **Negatif Yönlü Güçlü İlişkiler:** V17, V14, V12 ve V10 özellikleri 'Class' ile koyu mavi (negatif) korelasyon göstermektedir. Bu, ilgili özelliklerin değerleri düştükçe işlemin dolandırıcılık olma olasılığının arttığını ifade eder.
- **Pozitif Yönlü İlişkiler:** V4 ve V11 özellikleri ise pozitif (turuncu/kırmızı) korelasyon sergileyerek, bu değerler yükseldiğinde dolandırıcılık riskinin arttığına işaret eder.

3. SMOTE Uygulamasının Teknik Gerekçesi

SMOTE öncesi yapılan bu analiz, modelin neden bazı vakaları kaçırdığını açıklar:

- **Dengesizlik Etkisi:** Korelasyonlar teorik olarak güçlü olsa da, veri setindeki aşırı sınıf dengesizliği nedeniyle XGBoost bu sinyalleri azınlık sınıfı için yeterince derin işleyememiştir.
- **SMOTE Katkısı:** SMOTE kullanımı, bu matriste görülen kilit değişkenlerin (V17, V14 vb.) varyansını sentetik örneklerle artırarak modelin bu "dolandırıcılık sinyallerini" daha gürbüz (robust) bir şekilde öğrenmesini sağlamıştır.

Elde edilen korelasyon matrisi, dolandırıcılık tespiti için V17, V14 ve V12 gibi değişkenlerin birincil önem derecesine sahip olduğunu ortaya koymaktadır. SMOTE uygulanmış XGBoost modeli, bu değişkenler arasındaki karmaşık ilişkileri sentetik veri desteğiyle daha etkin bir şekilde modellemiş ve bu sayede kaçırılan dolandırıcılık vakalarını (False Negative) minimize etmeyi başarmıştır. Matristeki özellik bağımsızlığı, modelin aşırı öğrenme (overfitting) riskini düşük tutarak genelleylebilir bir performans sergilemesine imkan tanımıştır.

13. ve 14. Haftalar:

Model Performans Karşılaştırma Tablosu (Boyut: 500)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Logistic Reg.	Yok	Eğitim	0.9506	0.9784	0.9207	0.9487
		Test	0.9517	0.9321	0.9207	0.9264
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9859	0.9591	1.0000	0.9791
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9792	0.9407	1.0000	0.9695
Logistic Reg.	Var	Eğitim	0.9510	0.9788	0.9220	0.9495
		Test	0.9517	0.9321	0.9207	0.9264
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9866	0.9609	1.0000	0.9801
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9799	0.9425	1.0000	0.9704

1. 500 Boyutlu Veri Seti Yapısı

500 boyutlu senaryoda:

- Normal işlem sayısı = 500
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

[500 + 492 = 992] şeklindedir.

Bu veri seti daha sonra:

[%80 \ Eğitim \ %20 \ Test]

oranında bölünmüştür.

Yaklaşık dağılım:

Eğitim Verisi

- Toplam $\approx$ 793 örnek
- Normal işlem $\approx$ 400
- Fraud işlem $\approx$ 393

Test Verisi

- Toplam $\approx$ 199 örnek
- Normal işlem $\approx$ 100
- Fraud işlem $\approx$ 99

şeklindedir.

Kod içerisinde kullanılan: stratify=y parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece test verisi gerçek veri dağılımını temsil etmeye devam etmiştir.

2. 500 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 400 normal işlem

- 393 fraud işlem bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik olarak artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 400
- Fraud işlem ≈ 400

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 100
- Fraud işlem ≈ 99

olarak kalmıştır.

Bu yaklaşımın temel amacı, modelin gerçek dünya koşullarında değerlendirilmesini sağlamaktır. Çünkü gerçek kredi kartı sistemlerinde fraud işlemleri doğal olarak az sayıdadır.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 500)

Bu çalışmada kredi kartı dolandırıcılığı tespiti problemi için Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve test sonuçları doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

1. Lojistik Regresyon Analizi

Lojistik Regresyon modeli, doğrusal (linear) yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktaları arasında doğrusal bir karar sınırı oluşturarak sınıflandırma yapmaktadır. Bu nedenle veri setindeki ilişkiler doğrusal yapıya yakın olduğunda başarılı sonuçlar verebilmektedir.

SMOTE uygulanmayan durumda modelin test sonuçları incelendiğinde:

- Accuracy: 0.9517
- Precision: 0.9321
- Recall: 0.9207

- F1-Score: 0.9264 değerleri elde edilmiştir.

Bu sonuçlar, modelin dolandırıcılık işlemlerini belirli bir başarıyla tespit ettiğini göstermektedir. Özellikle Recall değerinin 0.9207 olması, modelin fraud işlemlerinin yaklaşık %92'sini yakalayabildiğini göstermektedir. Ancak Precision değerinin Random Forest ve XGBoost modellerine göre daha düşük olması, modelin daha fazla yanlış alarm (False Positive) ürettiğini göstermektedir.

SMOTE uygulandıktan sonra Lojistik Regresyon modelinde yalnızca çok küçük iyileşmeler gözlemlenmiştir:

- Eğitim Recall değeri 0.9207'den 0.9220'ye yükselmiştir.
- F1-Score değeri 0.9487'den 0.9495'e çıkmıştır.

Ancak test sonuçlarında belirgin bir değişim oluşmamıştır. Bunun temel nedeni, Lojistik Regresyon modelinin doğrusal yapısı nedeniyle veri dağılımındaki karmaşık örüntüleri sınırlı düzeyde öğrenebilmesidir. SMOTE ile üretilen sentetik örnekler modele ek bilgi sağlamış olsa da modelin doğrusal karar sınırı nedeniyle büyük performans artışı oluşmamıştır.

Bu nedenle Lojistik Regresyon modeli:

- Basit,
- Hızlı çalışan,
- Yorumlanabilir,
- Düşük hesaplama maliyetine sahip

bir model olmasına rağmen, karmaşık ve dengesiz fraud problemlerinde ağaç tabanlı modellere göre daha sınırlı performans göstermektedir.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble (topluluk öğrenme) tabanlı bir yöntemdir. Model, farklı veri alt kümeleri üzerinde birçok karar ağacı oluşturarak çoğunluk oylaması ile tahmin yapmaktadır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9859
- Precision: 0.9591
- Recall: 1.0000
- F1-Score: 0.9791 şeklindedir.

Bu sonuçlar, Random Forest modelinin fraud işlemlerinin tamamını yakalayabildiğini göstermektedir. Recall değerinin 1.000 olması, test setindeki hiçbir dolandırıcılık işleminin kaçırılmadığını ifade etmektedir. Fraud detection sistemlerinde False Negative hatalarının finansal kayba yol açması nedeniyle bu durum oldukça kritiktir.

Precision değerinin de yüksek olması (0.9591), modelin yanlış alarm oranının düşük olduğunu göstermektedir. Böylece model yalnızca fraud işlemlerini yakalamakla kalmamış, aynı zamanda normal işlemleri yanlışlıkla fraud olarak işaretleme oranını da düşük tutmuştur.

SMOTE uygulandıktan sonra Random Forest modelinde ek iyileşme gözlenmiştir:

- Accuracy: 0.9859 → 0.9866
- Precision: 0.9591 → 0.9609
- F1-Score: 0.9791 → 0.9801

Recall değeri yine 1.000 seviyesinde kalmıştır.

Bu sonuçlar, SMOTE'un özellikle Random Forest algoritmasında oldukça etkili çalıştığını göstermektedir. Bunun temel nedeni, Random Forest modelinin:

- Non-lineer ilişkileri öğrenebilmesi,
- Veri uzayındaki karmaşık örüntüleri yakalayabilmesi,
- Azınlık sınıfa ait lokal örüntüleri daha iyi modelleyebilmesi

özellikleridir.

SMOTE ile oluşturulan yeni fraud örnekleri, Random Forest modelinin karar ağaçlarını daha dengeli eğitmesine katkı sağlamış ve modelin genelleme başarısını artırmıştır.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif olarak azaltmaya çalışarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9792
- Precision: 0.9407
- Recall: 1.0000
- F1-Score: 0.9695 şeklindedir.

XGBoost modeli de Random Forest gibi tüm fraud işlemlerini başarıyla yakalamıştır. Recall değerinin 1.000 olması, modelin azınlık sınıfını öğrenme kapasitesinin oldukça yüksek olduğunu göstermektedir.

Ancak Precision değerinin Random Forest'a göre daha düşük olması, XGBoost modelinin daha fazla yanlış alarm ürettiğini göstermektedir. Bunun nedeni, boosting algoritmalarının bazı durumlarda azınlık sınıfa aşırı odaklanarak normal işlemleri fraud olarak etiketleme eğiliminde olabilmesidir.

SMOTE uygulandıktan sonra modelde küçük performans artışları gözlenmiştir:

- Accuracy: 0.9792 → 0.9799
- Precision: 0.9407 → 0.9425
- F1-Score: 0.9695 → 0.9704

Ancak bu artışlar Random Forest kadar belirgin değildir.

Bu durum, XGBoost modelinin zaten güçlü öğrenme kapasitesine sahip olması ve veri örüntülerini büyük ölçüde öğrenebilmesinden kaynaklanmaktadır. SMOTE modeli desteklese de Random Forest kadar büyük katkı sağlamamıştır.

Genel Model Karşılaştırması

Elde edilen sonuçlar incelendiğinde:

- Lojistik Regresyon modeli daha düşük performans göstermiştir.
- Random Forest ve XGBoost modelleri belirgin şekilde daha başarılı sonuçlar üretmiştir.
- En başarılı model Random Forest olmuştur.

Bunun temel nedenleri:

1. Fraud verilerindeki örüntülerin doğrusal olmaması
2. Veri setinin dengesiz yapıya sahip olması
3. Ensemble modellerin karmaşık ilişkileri daha iyi öğrenebilmesi
4. Random Forest'in overfitting riskine karşı daha dayanıklı olması

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir. Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerinin 1.000 olması, modellerin dolandırıcılık işlemlerini başarıyla yakaladığını göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Aksi durumda model çok fazla yanlış alarm üretir ve müşteri memnuniyetsizliğine yol açabilir.

Bu nedenle:

- Recall + Precision dengesi,
- F1-Score başarısı,
- Genelleme performansı

birlikte değerlendirildiğinde en başarılı modelin Random Forest olduğu sonucuna ulaşılmıştır. Sonuç olarak, SMOTE yöntemi özellikle Random Forest algoritmasında daha etkili sonuçlar üretmiş ve modelin azınlık sınıfı öğrenme kapasitesini artırmıştır. Ensemble tabanlı

modellerin, kredi kartı dolandırıcılığı gibi yüksek dengesizlik içeren problemlerde doğrusal modellere göre daha başarılı olduğu deneysel olarak gösterilmiştir.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 1000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Logistic Reg.	Yok	Eğitim	0.9584	0.9778	0.8943	0.9342
		Test	0.9511	0.9544	0.8943	0.9234
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9966	0.9899	1.0000	0.9949
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9920	0.9762	1.0000	0.9880
Logistic Reg.	Var	Eğitim	0.9415	0.9712	0.9100	0.9396
		Test	0.9544	0.9435	0.9167	0.9299
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9946	0.9840	1.0000	0.9919
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9873	0.9628	1.0000	0.9811

3. 1000 Boyutlu Veri Seti Yapısı

1000 boyutlu senaryoda:

- Normal işlem sayısı = 1000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$[1000 + 492 = 1492]$$

şeklindedir.

Eğitim Verisi

- Toplam ≈ 1193 örnek
- Normal işlem ≈ 800
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 299 örnek
- Normal işlem ≈ 200
- Fraud işlem ≈ 99

şeklindedir.

4. 1000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisine uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 800 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE sonrasında fraud sınıfı sentetik örneklerle artırılarak veri dengelenmiştir.

Yaklaşık SMOTE sonrası eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 800
- Fraud işlem ≈ 800

şeklindedir.

Test veri seti yine değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 200
- Fraud işlem ≈ 99

olarak bırakılmıştır.

5. Neden Sadece Eğitim Verisine SMOTE Uygulandı?

Bu çalışmada SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır. Bunun temel nedeni, test veri setinin gerçek dünya koşullarını temsil etmesini sağlamaktır.

Eğer test verisine de SMOTE uygulanırsa:

- Veri yapay şekilde dengelenmiş olur,
- Model performansı gerçekte olduğundan daha yüksek görünebilir,
- Gerçek fraud detection performansı doğru ölçülemez.

Bu nedenle:

- Eğitim verisinde modelin fraud örüntülerini öğrenmesi desteklenmiş,
- Test verisinde ise gerçekçi performans ölçümü korunmuştur.

Bu yaklaşım, makine öğrenmesi literatüründe önerilen doğru değerlendirme yöntemlerinden biridir.

6. Veri Dağılımının Modeller Üzerindeki Etkisi

Dengesiz veri yapısı özellikle Lojistik Regresyon gibi doğrusal modelleri olumsuz etkilemektedir. Çünkü model çoğunluk sınıfına yönelme eğilimi göstermektedir.

SMOTE uygulaması sayesinde:

- Fraud sınıfı daha görünür hale gelmiş,
- Recall değerleri artmış,

- Modellerin azınlık sınıfı öğrenme kapasitesi güçlenmiştir.

Özellikle Random Forest ve XGBoost gibi ensemble tabanlı modeller:

- Karmaşık veri örüntülerini daha iyi öğrenebilmiş,
- Dengesiz veri problemine karşı daha dayanıklı davranmış,
- Daha yüksek Recall ve F1-Score değerleri elde etmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 1000)

Bu çalışmada kredi kartı dolandırıcılığı tespiti problemi için Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları 1000 örneklemlili veri seti üzerinde karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve performansları doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri kullanılarak değerlendirilmiştir.

1. Lojistik Regresyon Analizi

Lojistik Regresyon modeli doğrusal yapıda çalışan bir sınıflandırma algoritmasıdır. Model, veri noktalarını doğrusal bir karar sınırı ile ayırmaya çalışmaktadır. Bu nedenle karmaşık ve doğrusal olmayan veri örüntülerinde performansı sınırlı kalabilmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9511
- Precision: 0.9544
- Recall: 0.8943
- F1-Score: 0.9234

şeklindedir.

Bu sonuçlar, modelin genel olarak başarılı bir sınıflandırma yaptığını göstermektedir. Ancak Recall değerinin 0.8943 olması, modelin dolandırıcılık işlemlerinin yaklaşık %89'unu yakalayabildiğini, geri kalan kısmını ise kaçırdığını göstermektedir. Fraud detection problemlerinde False Negative hataları kritik önem taşıdığı için bu durum modelin güvenilirliğini sınırlandırmaktadır.

SMOTE uygulandıktan sonra model performansında belirli iyileşmeler gözlemlenmiştir:

- Accuracy: 0.9511 → 0.9544
- Recall: 0.8943 → 0.9167
- F1-Score: 0.9234 → 0.9299

Precision değeri küçük bir düşüş göstermesine rağmen modelin fraud işlemlerini yakalama başarısı artmıştır. Bu durum, SMOTE yöntemi ile üretilen sentetik fraud örneklerinin modelin azınlık sınıfını daha iyi öğrenmesine katkı sağladığını göstermektedir.

Lojistik Regresyon modeli:

- Düşük hesaplama maliyetine sahip,
- Hızlı çalışan,
- Yorumlanabilir,
- Basit yapıda

bir model olmasına rağmen, kredi kartı dolandırıcılığı gibi karmaşık ve dengesiz veri problemlerinde ensemble tabanlı modellere göre daha düşük performans göstermektedir.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir. Model, farklı veri alt kümeleri üzerinde oluşturduğu karar ağaçlarının sonuçlarını birleştirerek tahmin üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9966
- Precision: 0.9899
- Recall: 1.0000
- F1-Score: 0.9949

şeklinde.

Bu sonuçlar, Random Forest modelinin test veri setindeki tüm dolandırıcılık işlemlerini başarıyla tespit ettiğini göstermektedir. Recall değerinin 1.000 olması, modelin hiçbir fraud işlemini kaçırmadığını ifade etmektedir. Ayrıca Precision değerinin oldukça yüksek olması, yanlış alarm oranının da son derece düşük olduğunu göstermektedir.

SMOTE uygulandıktan sonra model sonuçları:

- Accuracy: 0.9966 → 0.9946
- Precision: 0.9899 → 0.9840
- F1-Score: 0.9949 → 0.9919

şeklinde küçük değişimler göstermiştir.

Bu durumda SMOTE uygulaması model performansını belirgin şekilde artırmamıştır. Bunun temel nedeni, Random Forest algoritmasının zaten dengesiz veri setlerinde oldukça güçlü sonuçlar üretebilmesidir. Model, azınlık sınıfa ait örüntüleri doğal olarak başarılı şekilde öğrenebilmiştir.

Ayrıca eğitim sonuçlarının tamamen 1.000 olması, modelin eğitim verisini neredeyse kusursuz öğrendiğini göstermektedir. Ancak test performansının da çok yüksek olması, modelin güçlü genelleme kapasitesine sahip olduğunu göstermektedir.

Random Forest modelinin başarılı olmasının temel nedenleri:

- Non-lineer ilişkileri öğrenebilmesi,
- Gürültülü verilere karşı dayanıklı olması,
- Azınlık sınıf örüntülerini güçlü şekilde modelleyebilmesi,
- Overfitting riskini azaltan bagging yaklaşımına sahip olmasıdır.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9920
- Precision: 0.9762
- Recall: 1.0000
- F1-Score: 0.9880

şeklindedir.

Bu sonuçlar, XGBoost modelinin de tüm fraud işlemlerini başarılı şekilde yakaladığını göstermektedir. Recall değerinin 1.000 olması, modelin dolandırıcılık işlemlerini kaçırmadığını ifade etmektedir.

Ancak Precision değerinin Random Forest modeline göre daha düşük olması, modelin bazı normal işlemleri fraud olarak işaretlediğini göstermektedir. Bunun nedeni, boosting tabanlı algoritmaların azınlık sınıfa daha agresif şekilde odaklanabilmesidir.

SMOTE uygulandıktan sonra model performansında küçük düşüşler gözlenmiştir:

- Accuracy: 0.9920 → 0.9873
- Precision: 0.9762 → 0.9628
- F1-Score: 0.9880 → 0.9811

Recall değeri yine 1.000 seviyesinde kalmıştır.

Bu durum, XGBoost modelinin veri örüntülerini zaten güçlü şekilde öğrenebilmesi nedeniyle SMOTE'a fazla ihtiyaç duymadığını göstermektedir. SMOTE ile üretilen sentetik veriler bazı durumlarda modelin normal işlemleri fraud olarak işaretleme eğilimini artırabilmektedir.

Genel Model Karşılaştırması

1000 örneklemlili veri seti üzerinde elde edilen sonuçlar incelendiğinde:

- Random Forest modeli en başarılı performansı göstermiştir.
- XGBoost modeli Random Forest'a oldukça yakın sonuçlar üretmiştir.
- Lojistik Regresyon modeli diğer modellere göre daha düşük performans göstermiştir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir. Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerlerinin 1.000 olması, modellerin tüm fraud işlemlerini başarıyla yakaladığını göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Aksi durumda sistem çok fazla yanlış alarm üretebilir. Bu nedenle Recall, Precision ve F1-Score metrikleri birlikte değerlendirilmiştir.

Sonuçlar genel olarak değerlendirildiğinde:

- En dengeli ve güvenilir model Random Forest olmuştur.
- XGBoost yüksek başarı göstermesine rağmen Precision açısından Random Forest'ın gerisinde kalmıştır.
- Lojistik Regresyon modeli ise doğrusal yapısı nedeniyle karmaşık fraud örüntülerini öğrenmede sınırlı kalmıştır.

Ayrıca veri boyutunun 500'den 1000'e çıkarılmasıyla ensemble tabanlı modellerin performanslarının daha da stabil hale geldiği gözlemlenmiştir. Özellikle Random Forest modeli, veri miktarı arttıkça daha güçlü genelleme başarısı göstermiştir.

Sonuç olarak, kredi kartı dolandırıcılığı gibi yüksek sınıf dengesizliği içeren problemlerde ensemble tabanlı yöntemlerin doğrusal modellere göre daha başarılı olduğu deneysel olarak gösterilmiştir.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 1500)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Logistic Reg.	Yok	Eğitim	0.9679	0.9798	0.8882	0.9318
		Test	0.9538	0.9690	0.8882	0.9268
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9987	0.9960	1.0000	0.9980
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9940	0.9820	1.0000	0.9909
Logistic Reg.	Var	Eğitim	0.9483	0.9773	0.9180	0.9467
		Test	0.9531	0.9396	0.9167	0.9280
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9966	0.9899	1.0000	0.9949
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9920	0.9762	1.0000	0.9880

1. 1500 Boyutlu Veri Seti Yapısı

1500 boyutlu senaryoda:

- Normal işlem sayısı = 1500
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$1500+492=1992$$

Eğitim Verisi

- Toplam ≈ 1593 örnek
- Normal işlem ≈ 1200
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 399 örnek
- Normal işlem ≈ 300
- Fraud işlem ≈ 99

şeklindedir.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece test veri seti gerçek veri dağılımını temsil etmeye devam etmiştir.

Veri boyutunun 500'den 1500'e çıkarılmasıyla birlikte modeller daha fazla normal işlem örneği görmüş ve veri örüntülerini daha başarılı şekilde öğrenebilmiştir. Özellikle ensemble tabanlı modellerin genelleme performansında belirgin iyileşmeler gözlenmiştir.

2. 1500 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 1200 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik olarak artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 1200
- Fraud işlem ≈ 1200

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 300
- Fraud işlem ≈ 99

olarak kalmıştır.

Bu yaklaşımın temel amacı, modelin gerçek dünya koşullarında değerlendirilmesini sağlamaktır. Çünkü gerçek kredi kartı sistemlerinde fraud işlemleri doğal olarak az sayıdadır.

SMOTE yöntemi sayesinde eğitim verisi daha dengeli hale getirilmiş ve modellerin fraud örüntülerini öğrenme kapasitesi artırılmıştır. Özellikle Random Forest ve XGBoost gibi ensemble tabanlı modeller, dengelenmiş veri yapısından daha fazla fayda sağlamış ve yüksek Recall ile F1-Score değerleri üretmiştir.

1500 Boyutlu Veri Setinde Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi

Bu çalışmada kredi kartı dolandırıcılığı tespiti problemi için 1500 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş; eğitim ve test sonuçları doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

1500 boyutlu senaryoda veri miktarının artmasıyla birlikte modeller daha fazla normal işlem örneği görmüş ve veri örüntülerini daha başarılı şekilde öğrenebilmiştir. Özellikle ensemble tabanlı modellerin performansında belirgin iyileşmeler gözlenmiştir.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktaları arasında doğrusal bir karar sınırı oluşturarak tahmin gerçekleştirmektedir. Bu nedenle karmaşık ve doğrusal olmayan fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9538
- Precision: 0.9690
- Recall: 0.8882
- F1-Score: 0.9268

şeklindedir.

Bu sonuçlar, modelin normal işlemleri başarılı şekilde sınıflandırmasına rağmen fraud işlemlerinin bir kısmını kaçırdığını göstermektedir. Recall değerinin 0.8882 olması, modelin dolandırıcılık işlemlerinin yaklaşık %89'unu yakalayabildiğini göstermektedir. Fraud detection problemlerinde Recall metriği kritik öneme sahip olduğundan bu durum önemli bir sınırlılık oluşturmaktadır.

Precision değerinin yüksek olması (0.9690), modelin yanlış alarm oranının düşük olduğunu göstermektedir. Yani model fraud olarak işaretlediği işlemlerin büyük kısmında doğru tahmin yapmıştır. Ancak fraud işlemlerinin bir kısmını kaçırmaması nedeniyle genel fraud yakalama başarısı sınırlı kalmıştır.

SMOTE uygulandıktan sonra modelde belirli iyileşmeler gözlenmiştir:

- Eğitim Recall değeri: 0.8882 → 0.9180
- Test Recall değeri: 0.8882 → 0.9167
- Test F1-Score değeri: 0.9268 → 0.9280

Bu sonuçlar, SMOTE yönteminin azınlık sınıfı olan fraud verilerini artırarak modelin fraud örüntülerini daha iyi öğrenmesine katkı sağladığını göstermektedir.

Ancak performans artışının sınırlı düzeyde kalmasının temel nedeni, Lojistik Regresyon modelinin doğrusal yapısıdır. Veri setindeki karmaşık ilişkiler doğrusal olmadığı için model sentetik verilerden tam anlamıyla faydalanamamıştır.

Bu nedenle Lojistik Regresyon modeli:

- Basit yapılı,
- Hızlı çalışan,
- Düşük hesaplama maliyetine sahip,
- Yorumlanabilir

bir model olmasına rağmen, karmaşık fraud detection problemlerinde ensemble tabanlı modellere göre daha düşük performans göstermiştir.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir makine öğrenmesi yöntemidir. Model, farklı veri alt kümeleri üzerinde birçok karar ağacı oluşturarak çoğunluk oylamasıyla tahmin yapmaktadır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9987
- Precision: 0.9960
- Recall: 1.0000
- F1-Score: 0.9980

şeklindedir.

Bu sonuçlar, Random Forest modelinin test veri setindeki tüm fraud işlemlerini başarıyla yakaladığını göstermektedir. Recall değerinin 1.000 olması, modelin hiçbir dolandırıcılık işlemini kaçırmadığını ifade etmektedir.

Fraud detection problemlerinde False Negative hataları doğrudan finansal kayıplara yol açabileceği için bu sonuç oldukça önemlidir.

Precision değerinin de çok yüksek olması (0.9960), modelin yanlış alarm üretme oranının oldukça düşük olduğunu göstermektedir. Böylece model hem fraud işlemlerini başarılı şekilde yakalamış hem de normal işlemleri büyük ölçüde doğru sınıflandırmıştır.

SMOTE uygulandıktan sonra model performansında küçük ancak olumlu gelişmeler gözlenmiştir:

- Test Precision: 0.9960 → 0.9899
- Recall değeri: 1.0000 olarak korunmuştur.
- Test F1-Score: 0.9980 → 0.9949

SMOTE sonrasında Recall değerinin korunması, modelin fraud işlemlerini yakalama başarısını sürdürdüğünü göstermektedir. Ancak Precision ve F1-Score değerlerinde çok küçük düşüşler oluşmuştur.

Bu durumun temel nedeni, SMOTE ile oluşturulan sentetik fraud örneklerinin modele fraud sınıfını daha baskın göstermesi ve modelin bazı normal işlemleri fraud olarak sınıflandırma eğilimini artırabilmesidir.

Bununla birlikte Random Forest modeli genel olarak oldukça güçlü performans göstermeye devam etmiş ve veri setindeki karmaşık örüntüleri başarıyla öğrenmiştir.

Random Forest modelinin başarısının temel nedenleri:

- Non-lineer ilişkileri öğrenebilmesi,
- Gürültülü verilere karşı dayanıklı olması,
- Overfitting riskinin düşük olması,
- Azınlık sınıf örüntülerini güçlü şekilde öğrenebilmesi

olarak açıklanabilir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler oluşturmaktadır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9940
- Precision: 0.9820
- Recall: 1.0000
- F1-Score: 0.9909

şeklindedir.

Bu sonuçlar, XGBoost modelinin test veri setindeki tüm fraud işlemlerini başarıyla tespit ettiğini göstermektedir. Recall değerinin 1.000 olması, modelin azınlık sınıfı öğrenme kapasitesinin oldukça yüksek olduğunu göstermektedir.

Precision değerinin de yüksek olması, modelin yanlış alarm üretme oranının düşük olduğunu göstermektedir. Ancak Random Forest modeline kıyasla Precision değerinin biraz daha düşük olması, modelin bazı normal işlemleri fraud olarak etiketlediğini göstermektedir.

Bunun temel nedeni, boosting algoritmalarının fraud örüntülerine daha agresif şekilde odaklanabilmesidir.

SMOTE uygulandıktan sonra model performansında genel olarak stabil sonuçlar elde edilmiştir. XGBoost modeli zaten güçlü öğrenme kapasitesine sahip olduğu için SMOTE'un etkisi sınırlı düzeyde kalmıştır.

Model:

- Karmaşık örüntüleri başarılı şekilde öğrenebilmiş,
- Fraud işlemlerini eksiksiz yakalayabilmiş,
- Yüksek genelleme performansı göstermiştir.

Özellikle veri boyutunun artmasıyla birlikte XGBoost modelinin daha stabil hale geldiği gözlenmiştir.

Genel Model Karşılaştırması

1500 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük performans göstermiştir.
- Random Forest ve XGBoost modelleri oldukça yüksek başarı elde etmiştir.
- En başarılı model Random Forest olmuştur.

Bu sonuçların temel nedenleri şunlardır:

1. Fraud verilerindeki ilişkilerin doğrusal olmaması
2. Ensemble modellerin karmaşık örüntüleri daha başarılı öğrenebilmesi
3. Ağaç tabanlı yöntemlerin azınlık sınıfına daha duyarlı olması
4. Veri boyutunun artmasıyla modellerin genelleme kapasitesinin güçlenmesi

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada:

- Random Forest ve XGBoost modellerinin Recall değerinin 1.000 olması,
- Precision değerlerinin de oldukça yüksek olması,
- F1-Score performanslarının dengeli şekilde korunması

ensemble tabanlı yöntemlerin fraud detection problemlerinde daha başarılı olduğunu göstermektedir.

Sonuç olarak, veri boyutunun artması modellerin performansını olumlu yönde etkilemiş; özellikle Random Forest modeli en dengeli ve en güçlü sonuçları üretmiştir. SMOTE yöntemi ise özellikle azınlık sınıfının öğrenilmesini destekleyerek modellerin fraud detection başarısına katkı sağlamıştır.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 3000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	0.9997	0.9980	1.0000	0.9990
		Test	0.9987	0.9960	1.0000	0.9980
Logistic Reg.	Yok	Eğitim	0.9800	0.9862	0.8699	0.9244
		Test	0.9551	0.9930	0.8699	0.9274
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9993	0.9980	1.0000	0.9990
XGBoost	Var	Eğitim	0.9998	0.9997	1.0000	0.9998
		Test	0.9906	0.9723	1.0000	0.9860
Logistic Reg.	Var	Eğitim	0.9440	0.9730	0.9133	0.9422
		Test	0.9531	0.9396	0.9167	0.9280

1. 3000 Boyutlu Veri Seti Yapısı

3000 boyutlu senaryoda:

- Normal işlem sayısı = 3000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$3000+492=3492$$

Eğitim Verisi

- Toplam ≈ 2793 örnek
- Normal işlem ≈ 2400
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 699 örnek
- Normal işlem ≈ 600
- Fraud işlem ≈ 99

şeklindedir.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece eğitim ve test veri kümelerinde sınıf dağılımı dengeli biçimde temsil edilmiştir.

3000 boyutlu veri setinde modeller, önceki senaryolara göre daha fazla normal işlem örneği gördüğü için veri örüntülerini daha başarılı şekilde öğrenebilmiştir. Özellikle Random Forest ve XGBoost modellerinde test performanslarının oldukça yüksek seviyelere ulaştığı gözlenmiştir.

2. 3000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 2400 normal işlem
- 393 fraud işlem bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 2400
- Fraud işlem ≈ 2400

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 600
- Fraud işlem ≈ 99

olarak bırakılmıştır.

Bu yaklaşım sayesinde model eğitim aşamasında fraud örüntülerini daha güçlü öğrenebilmiş; test aşamasında ise gerçek dünya veri dağılımına yakın koşullarda değerlendirme yapılabilmektedir.

Özellikle veri miktarının artmasıyla birlikte SMOTE'un etkisi daha stabil hale gelmiş ve ensemble tabanlı modellerin fraud işlemlerini yakalama başarısı önemli ölçüde yükselmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 3000)

Bu çalışmada 3000 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri boyutunun artmasıyla birlikte modellerin genelleme performansında belirgin iyileşmeler gözlenmiştir. Özellikle ensemble tabanlı modellerin fraud örüntülerini çok daha başarılı şekilde öğrendiği görülmüştür.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri setindeki ilişkileri doğrusal karar sınırları kullanarak ayırmaya çalışmaktadır. Bu nedenle karmaşık fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9551
- Precision: 0.9930
- Recall: 0.8699
- F1-Score: 0.9274

şeklindedir.

Bu sonuçlar, modelin fraud olarak işaretlediği işlemlerde oldukça doğru tahmin yaptığını göstermektedir. Precision değerinin 0.9930 olması, yanlış alarm oranının oldukça düşük olduğunu göstermektedir.

Ancak Recall değerinin 0.8699 olması, modelin fraud işlemlerinin bir kısmını kaçırdığını göstermektedir. Fraud detection problemlerinde kaçırılan fraud işlemleri finansal kayıplara neden olabileceği için bu durum önemli bir dezavantaj oluşturmaktadır.

SMOTE uygulandıktan sonra modelin eğitim performansında iyileşmeler gözlenmiştir:

- Eğitim Recall değeri: 0.8699 → 0.9133
- Eğitim F1-Score değeri: 0.9244 → 0.9422

Bu durum, SMOTE yönteminin fraud örneklerini artırarak modelin azınlık sınıfını daha iyi öğrenmesine katkı sağladığını göstermektedir.

Ancak Lojistik Regresyon modelinin doğrusal yapısı nedeniyle performans artışı sınırlı kalmıştır. Model karmaşık fraud örüntülerini öğrenmede ensemble tabanlı yöntemler kadar başarılı olamamıştır.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, Random Forest modelinin test veri setindeki tüm fraud işlemlerini eksiksiz şekilde yakaladığını göstermektedir. Aynı zamanda model hiçbir normal işlemi yanlış şekilde fraud olarak sınıflandırmamıştır.

Bu durum modelin:

- Çok güçlü genelleme kapasitesine sahip olduğunu,
- Karmaşık fraud örüntülerini başarıyla öğrendiğini,
- Veri boyutunun artmasından büyük ölçüde faydalandığını göstermektedir.

SMOTE uygulandıktan sonra model performansı yine oldukça yüksek seviyede kalmıştır:

- Accuracy: 0.9993
- Precision: 0.9980
- Recall: 1.0000
- F1-Score: 0.9990

Recall değerinin korunması, modelin tüm fraud işlemlerini yakalamaya devam ettiğini göstermektedir.

Precision değerinde çok küçük düşüş oluşmasının nedeni, SMOTE ile oluşturulan sentetik fraud örneklerinin modelin fraud sınıfına biraz daha agresif yaklaşmasına neden olmasıdır. Buna rağmen model genel olarak son derece başarılı sonuçlar üretmiştir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif olarak azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9987
- Precision: 0.9960
- Recall: 1.0000
- F1-Score: 0.9980 şeklindedir.

Bu sonuçlar, XGBoost modelinin fraud işlemlerinin tamamını başarıyla yakaladığını göstermektedir. Recall değerinin 1.000 olması, modelin azınlık sınıfını öğrenme kapasitesinin oldukça yüksek olduğunu göstermektedir.

Precision değerinin de çok yüksek olması, modelin yanlış alarm oranının oldukça düşük olduğunu göstermektedir.

SMOTE uygulandıktan sonra model performansı şu şekilde gerçekleşmiştir:

- Accuracy: 0.9906
- Precision: 0.9723
- Recall: 1.0000

- F1-Score: 0.9860

Recall değeri korunmuş olsa da Precision ve F1-Score değerlerinde düşüş meydana gelmiştir.

Bu durumun temel nedeni, XGBoost modelinin fraud sınıfına aşırı duyarlı hale gelmesi ve bazı normal işlemleri fraud olarak işaretlemeye başlamasıdır. Boosting algoritmaları bazı durumlarda sentetik örneklerle fazla uyum sağlayarak yanlış alarm oranını artırabilmektedir.

Buna rağmen model genel olarak oldukça yüksek performans göstermeye devam etmiştir.

Genel Model Karşılaştırması

3000 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük Recall performansı göstermiştir.
- Random Forest ve XGBoost modelleri oldukça yüksek başarı elde etmiştir.
- En başarılı model Random Forest olmuştur.

Bu sonuçların temel nedenleri:

1. Fraud örüntülerinin doğrusal olmaması
2. Ensemble modellerin karmaşık ilişkileri daha iyi öğrenebilmesi
3. Veri miktarının artmasının modellerin genelleme başarısını artırması
4. Random Forest modelinin overfitting riskine karşı daha dayanıklı olması

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerinin 1.000 olması, modellerin fraud işlemlerini eksiksiz şekilde yakalayabildiğini göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Aksi durumda model çok fazla yanlış alarm üretir ve müşteri memnuniyetsizliğine yol açabilir.

Bu nedenle:

- Recall + Precision dengesi,
- F1-Score başarısı,
- Genelleme performansı

birlikte değerlendirildiğinde en başarılı modelin Random Forest olduğu sonucuna ulaşılmıştır.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 6000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Logistic Reg.	Yok	Eğitim	0.9875	0.9768	0.8557	0.9122
		Test	0.9524	1.0000	0.8557	0.9222
Random Forest	Yok	Eğitim	0.9997	1.0000	0.9959	0.9980
		Test	0.9987	1.0000	0.9959	0.9980
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9993	0.9980	1.0000	0.9990
Logistic Reg.	Var	Eğitim	0.9428	0.9753	0.9087	0.9408
		Test	0.9538	0.9379	0.9207	0.9292
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9993	0.9980	1.0000	0.9990
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9940	0.9820	1.0000	0.9909

1. 6000 Boyutlu Veri Seti Yapısı

6000 boyutlu senaryoda:

- Normal işlem sayısı = 6000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$6000+492=6492$$

Eğitim Verisi

- Toplam ≈ 5193 örnek
- Normal işlem ≈ 4800
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 1299 örnek
- Normal işlem ≈ 1200
- Fraud işlem ≈ 99

şeklindedir.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece veri setinin dengesiz yapısı eğitim ve test aşamalarında gerçekçi biçimde temsil edilmiştir.

Veri boyutunun artmasıyla birlikte modeller daha fazla normal işlem örneği görmüş ve özellikle ensemble tabanlı yöntemlerin genelleme performansında önemli iyileşmeler gözlenmiştir.

2. 6000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 4800 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 4800
- Fraud işlem ≈ 4800

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 1200
- Fraud işlem ≈ 99

olarak bırakılmıştır.

Bu yaklaşım sayesinde modeller eğitim aşamasında fraud örüntülerini daha güçlü öğrenebilmiş; test aşamasında ise gerçek dünya veri dağılımına yakın koşullarda değerlendirilmiştir.

Özellikle veri miktarının artmasıyla birlikte ensemble tabanlı modellerin fraud detection performansının oldukça yüksek seviyelere ulaştığı gözlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 6000)

Bu çalışmada 6000 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının artmasıyla birlikte modellerin genelleme performansında önemli gelişmeler gözlenmiştir. Özellikle Random Forest ve XGBoost modelleri fraud işlemlerini neredeyse eksiksiz şekilde tespit edebilmiştir.

1. Lojistik Regresyon Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktaları arasında doğrusal karar sınırları oluşturarak sınıflandırma yapmaktadır. Bu nedenle karmaşık ve doğrusal olmayan fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9524
- Precision: 1.0000
- Recall: 0.8557
- F1-Score: 0.9222

şeklindedir.

Bu sonuçlar, modelin fraud olarak işaretlediği işlemlerde hata yapmadığını göstermektedir. Precision değerinin 1.000 olması, modelin yanlış alarm üretmediğini ifade etmektedir.

Ancak Recall değerinin 0.8557 olması, modelin fraud işlemlerinin yaklaşık %14'ünü kaçırdığını göstermektedir. Fraud detection problemlerinde kaçırılan fraud işlemleri finansal kayıplara neden olabileceği için bu durum önemli bir dezavantajdır.

SMOTE uygulandıktan sonra model performansında belirgin iyileşmeler gözlenmiştir:

- Recall: 0.8557 → 0.9207
- F1-Score: 0.9222 → 0.9292

Bu sonuçlar, SMOTE yönteminin azınlık sınıfını güçlendirerek modelin fraud örüntülerini daha başarılı öğrenmesini sağladığını göstermektedir.

Ancak SMOTE sonrasında Precision değerinin düşmesi:

- Precision: 1.0000 → 0.9379

modelin daha fazla yanlış alarm üretmeye başladığını göstermektedir.

Bu durum, fraud detection problemlerinde sık görülen Recall–Precision dengesi ile açıklanabilir. Model daha fazla fraud işlemi yakalamaya çalışırken bazı normal işlemleri de fraud olarak sınıflandırmıştır.

Genel olarak değerlendirildiğinde Lojistik Regresyon modeli:

- Basit,
- Hızlı,
- Yorumlanabilir

bir model olmasına rağmen karmaşık fraud örüntülerini öğrenmede ensemble tabanlı yöntemlerin gerisinde kalmıştır.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9987
- Precision: 1.0000
- Recall: 0.9959
- F1-Score: 0.9980

şeklindedir.

Bu sonuçlar, modelin fraud işlemlerinin neredeyse tamamını başarıyla yakaladığını göstermektedir. Recall değerinin 0.9959 olması, yalnızca çok az sayıda fraud işleminin kaçırıldığını göstermektedir.

Precision değerinin 1.000 olması ise modelin yanlış alarm üretmediğini ifade etmektedir.

SMOTE uygulandıktan sonra model performansı daha da güçlenmiştir:

- Accuracy: 0.9993
- Precision: 0.9980
- Recall: 1.0000
- F1-Score: 0.9990

Recall değerinin 1.000 seviyesine ulaşması, modelin tüm fraud işlemlerini eksiksiz şekilde yakaladığını göstermektedir.

Precision değerindeki çok küçük düşüş, modelin bazı normal işlemleri fraud olarak işaretlemesinden kaynaklanmaktadır. Ancak genel performans hâlâ oldukça yüksektir.

Random Forest modelinin güçlü performans göstermesinin temel nedenleri:

- Non-lineer ilişkileri başarılı şekilde öğrenebilmesi,
- Gürültülü verilere karşı dayanıklı olması,
- Overfitting riskinin düşük olması,
- Veri boyutunun artmasından güçlü şekilde faydalanabilmesi

olarak açıklanabilir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9993
- Precision: 0.9980
- Recall: 1.0000
- F1-Score: 0.9990

şeklindedir.

Bu sonuçlar, modelin fraud işlemlerinin tamamını başarıyla yakaladığını göstermektedir. Recall değerinin 1.000 olması, modelin azınlık sınıfını öğrenme kapasitesinin oldukça yüksek olduğunu göstermektedir.

Precision değerinin de oldukça yüksek olması, modelin yanlış alarm oranının son derece düşük olduğunu göstermektedir.

SMOTE uygulandıktan sonra model performansı şu şekilde gerçekleşmiştir:

- Accuracy: 0.9940
- Precision: 0.9820
- Recall: 1.0000
- F1-Score: 0.9909

Recall değeri korunmasına rağmen Precision ve F1-Score değerlerinde düşüş meydana gelmiştir.

Bu durumun temel nedeni, XGBoost modelinin sentetik fraud örneklerine daha duyarlı hale gelmesi ve bazı normal işlemleri fraud olarak işaretlemeye başlamasıdır.

Boosting algoritmaları bazı durumlarda azınlık sınıfa aşırı odaklanarak yanlış alarm oranını artırmaktadır. Buna rağmen model genel olarak oldukça yüksek performans göstermeye devam etmiştir.

Genel Model Karşılaştırması

6000 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük Recall performansı göstermiştir.
- Random Forest ve XGBoost modelleri oldukça yüksek başarı elde etmiştir.
- En başarılı model Random Forest olmuştur.

Bu sonuçların temel nedenleri:

1. Fraud örüntülerinin doğrusal olmaması
2. Ensemble tabanlı modellerin karmaşık ilişkileri daha başarılı öğrenebilmesi
3. Veri miktarının artmasının modellerin genelleme kapasitesini artırması
4. Random Forest modelinin yüksek Recall ve Precision dengesini koruyabilmesi

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerlerinin 1.000 seviyesine ulaşması, modellerin dolandırıcılık işlemlerini başarıyla yakaladığını göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Çünkü yanlış alarm oranının artması müşteri memnuniyetsizliğine yol açabilir.

Bu nedenle:

- Recall + Precision dengesi,
- F1-Score başarısı,
- Genelleme performansı

birlikte değerlendirildiğinde en başarılı modelin Random Forest olduğu sonucuna ulaşılmıştır.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 12000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
Logistic Reg.	Yok	Eğitim	0.9926	0.9761	0.8313	0.8979
		Test	0.9437	0.9976	0.8313	0.9069
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9993	0.9980	1.0000	0.9990
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9960	0.9880	1.0000	0.9939
Logistic Reg.	Var	Eğitim	0.9440	0.9767	0.9097	0.9420
		Test	0.9538	0.9397	0.9187	0.9291

1. 12000 Boyutlu Veri Seti Yapısı

12000 boyutlu senaryoda:

- Normal işlem sayısı = 12000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$12000+492=12492$$

Eğitim Verisi

- Toplam ≈ 9993 örnek
- Normal işlem ≈ 9600
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 2499 örnek
- Normal işlem ≈ 2400
- Fraud işlem ≈ 99

şeklinde.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece veri setinin gerçek dağılımı eğitim ve test aşamalarında korunmuş ve modellerin gerçek dünya koşullarına yakın şekilde değerlendirilmesi sağlanmıştır.

Veri boyutunun artmasıyla birlikte modeller daha fazla normal işlem örneği görmüş ve özellikle ensemble tabanlı yöntemlerin genelleme performansında ciddi gelişmeler gözlenmiştir.

2. 12000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 9600 normal işlem
- 393 fraud işlem bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 9600
- Fraud işlem ≈ 9600

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 2400
- Fraud işlem ≈ 99

olarak bırakılmıştır.

Bu yaklaşım sayesinde modeller eğitim aşamasında fraud örüntülerini daha güçlü öğrenebilmiş; test aşamasında ise gerçek dünya veri dağılımına yakın koşullarda değerlendirilmiştir.

Özellikle veri miktarının artmasıyla birlikte Random Forest ve XGBoost modellerinin performanslarının oldukça stabil hale geldiği gözlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 12000)

Bu çalışmada 12000 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının artmasıyla birlikte ensemble tabanlı modellerin performanslarında çok yüksek başarı seviyelerine ulaşıldığı gözlenmiştir.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktalarını doğrusal karar sınırları kullanarak ayırmaya çalışmaktadır. Bu nedenle karmaşık fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9437
- Precision: 0.9976
- Recall: 0.8313
- F1-Score: 0.9069

şeklindedir.

Bu sonuçlar, modelin fraud olarak işaretlediği işlemlerde oldukça başarılı olduğunu göstermektedir. Precision değerinin 0.9976 olması, yanlış alarm oranının son derece düşük olduğunu ifade etmektedir.

Ancak Recall değerinin 0.8313 olması, modelin fraud işlemlerinin yaklaşık %17'sini kaçırdığını göstermektedir. Fraud detection problemlerinde kaçırılan fraud işlemleri doğrudan finansal kayba neden olabileceği için bu durum önemli bir dezavantaj oluşturmaktadır.

Veri miktarı artsa bile Recall değerinin düşük kalması, Lojistik Regresyon modelinin karmaşık ve doğrusal olmayan fraud örüntülerini öğrenmede sınırlı kaldığını göstermektedir.

Bunun temel nedenleri:

- Modelin doğrusal yapıya sahip olması,
- Fraud örüntülerinin karmaşık ilişkiler içermesi,
- Veri setindeki sınıfların tam olarak doğrusal şekilde ayrılmaması

olarak açıklanabilir.

Buna rağmen model:

- Basit,
- Hızlı çalışan,
- Yorumlanabilir,
- Düşük hesaplama maliyetine sahip

bir yöntem olduğu için temel karşılaştırma modeli olarak önemli avantajlar sunmaktadır.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin test veri setindeki tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Random Forest modelinin bu kadar başarılı performans göstermesinin temel nedenleri:

- Karmaşık non-lineer ilişkileri öğrenebilmesi,
- Çok sayıda karar ağacı kullanması,
- Gürültülü verilere karşı dayanıklı olması,
- Overfitting riskinin düşük olması

olarak açıklanabilir.

SMOTE uygulandıktan sonra model performansı yine oldukça yüksek seviyede kalmıştır:

- Accuracy: 0.9993
- Precision: 0.9980
- Recall: 1.0000
- F1-Score: 0.9990

Recall değerinin korunması, modelin tüm fraud işlemlerini yakalamaya devam ettiğini göstermektedir.

Precision değerindeki çok küçük düşüş, modelin bazı normal işlemleri fraud olarak işaretlemesinden kaynaklanmaktadır. Ancak genel performans hâlâ oldukça yüksektir.

Bu sonuçlar, Random Forest modelinin veri miktarı arttıkça daha stabil ve güçlü hale geldiğini göstermektedir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, XGBoost modelinin test veri setindeki tüm fraud işlemlerini eksiksiz şekilde yakaladığını göstermektedir.

Modelin:

- Çok güçlü öğrenme kapasitesine sahip olması,
- Hataları iteratif olarak azaltması,
- Karmaşık fraud örüntülerini başarılı şekilde öğrenebilmesi

yüksek performans elde edilmesini sağlamıştır.

SMOTE uygulandıktan sonra model performansı şu şekilde gerçekleşmiştir:

- Accuracy: 0.9960
- Precision: 0.9880
- Recall: 1.0000
- F1-Score: 0.9939

Recall değeri korunmuş olsa da Precision ve F1-Score değerlerinde küçük düşüşler meydana gelmiştir.

Bu durumun temel nedeni, XGBoost modelinin sentetik fraud örneklerine daha fazla uyum sağlaması ve bazı normal işlemleri fraud olarak sınıflandırmasıdır.

Boosting algoritmaları bazı durumlarda azınlık sınıfa aşırı duyarlı hale gelebilmektedir. Buna rağmen model genel olarak oldukça güçlü performans göstermeye devam etmiştir.

Genel Model Karşılaştırması

12000 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük Recall performansı göstermiştir.
- Random Forest ve XGBoost modelleri son derece yüksek başarı elde etmiştir.
- En başarılı modeller Random Forest ve XGBoost olmuştur.

Bu sonuçların temel nedenleri:

1. Fraud örüntülerinin doğrusal olmaması
2. Ensemble tabanlı modellerin karmaşık ilişkileri daha başarılı öğrenebilmesi
3. Veri miktarının artmasının modellerin genelleme kapasitesini artırması
4. Ağaç tabanlı yöntemlerin azınlık sınıfına daha duyarlı olması

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerlerinin 1.000 seviyesine ulaşması, modellerin dolandırıcılık işlemlerini eksiksiz şekilde yakalayabildiğini göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Çünkü yanlış alarm oranının artması müşteri memnuniyetsizliğine yol açabilir.

Bu nedenle:

- Recall + Precision dengesi,
- F1-Score başarısı,
- Genelleme performansı

birlikte değerlendirildiğinde en başarılı modellerin Random Forest ve XGBoost olduğu sonucuna ulaşılmıştır.

Model Performans Karşılaştırma Tablosu (Boyut: 24000)

Model	SMOTE	Veri Tipi	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
Logistic Reg.	Yok	Eğitim	0.9958	0.9643	0.8232	0.8882
		Test	0.9417	1.0000	0.8232	0.9030
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9987	0.9960	1.0000	0.9980
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9973	0.9919	1.0000	0.9960
Logistic Reg.	Var	Eğitim	0.9441	0.9744	0.9121	0.9422
		Test	0.9511	0.9302	0.9207	0.9254

1. 24000 Boyutlu Veri Seti Yapısı

24000 boyutlu senaryoda:

- Normal işlem sayısı = 24000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$24000+492=24492$$

şeklindedir.

Eğitim Verisi

- Toplam ≈ 19593 örnek
- Normal işlem ≈ 19200
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 4899 örnek
- Normal işlem ≈ 4800
- Fraud işlem ≈ 99

şeklindedir.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece veri setinin gerçek dağılımı eğitim ve test aşamalarında korunmuş ve modeller gerçek dünya koşullarına yakın şekilde değerlendirilmiştir.

Veri miktarının büyük ölçüde artmasıyla birlikte modeller çok daha fazla normal işlem örneği görmüş ve özellikle ensemble tabanlı yöntemlerin performansları oldukça stabil hale gelmiştir.

2. 24000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 19200 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 19200
- Fraud işlem ≈ 19200

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 4800
- Fraud işlem ≈ 99

olarak bırakılmıştır.

Bu yaklaşım sayesinde modeller eğitim aşamasında fraud örüntülerini daha güçlü öğrenebilmiş; test aşamasında ise gerçek dünya veri dağılımına yakın koşullarda değerlendirilmiştir.

Özellikle veri boyutunun artmasıyla birlikte Random Forest ve XGBoost modellerinin oldukça kararlı sonuçlar verdiği gözlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 24000)

Bu çalışmada 24000 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının artmasıyla birlikte ensemble tabanlı modellerin performanslarında çok yüksek başarı seviyelerine ulaşıldığı gözlenmiştir.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktalarını doğrusal karar sınırları kullanarak ayırmaya çalışmaktadır. Bu nedenle karmaşık fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9417
- Precision: 1.0000
- Recall: 0.8232
- F1-Score: 0.9030

şeklindedir.

Bu sonuçlar, modelin fraud olarak işaretlediği işlemlerde hata yapmadığını göstermektedir. Precision değerinin 1.000 olması, modelin yanlış alarm üretmediğini ifade etmektedir.

Ancak Recall değerinin 0.8232 olması, modelin fraud işlemlerinin yaklaşık %18'ini kaçırdığını göstermektedir. Fraud detection problemlerinde kaçırılan işlemler doğrudan finansal kayıplara neden olabileceği için bu durum önemli bir dezavantaj oluşturmaktadır.

Veri miktarı artsa bile Recall değerinin düşük kalması, Lojistik Regresyon modelinin doğrusal yapısından kaynaklanmaktadır. Fraud işlemleri karmaşık ve non-lineer örüntüler içerdiği için model bu ilişkileri tam olarak öğrenememektedir.

SMOTE uygulandıktan sonra model performansında belirgin iyileşmeler gözlenmiştir:

- Recall: 0.8232 → 0.9207
- F1-Score: 0.9030 → 0.9254

Bu sonuçlar, SMOTE yönteminin azınlık sınıfını güçlendirerek modelin fraud örüntülerini daha başarılı öğrenmesini sağladığını göstermektedir.

Ancak Precision değerinin düşmesi:

- Precision: 1.0000 → 0.9302

modelin daha fazla yanlış alarm üretmeye başladığını göstermektedir.

Bu durum Recall–Precision dengesi ile açıklanabilir. Model daha fazla fraud işlemi yakalamaya çalışırken bazı normal işlemleri de fraud olarak sınıflandırmıştır.

Genel olarak değerlendirildiğinde Lojistik Regresyon modeli:

- Basit,
- Hızlı çalışan,
- Yorumlanabilir,

- Düşük hesaplama maliyetine sahip

bir yöntem olmasına rağmen, karmaşık fraud detection problemlerinde ensemble tabanlı yöntemlerin gerisinde kalmıştır.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin test veri setindeki tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Random Forest modelinin bu kadar başarılı performans göstermesinin temel nedenleri:

- Karmaşık non-lineer ilişkileri öğrenebilmesi,
- Çok sayıda karar ağacı kullanması,
- Gürültülü verilere karşı dayanıklı olması,
- Overfitting riskinin düşük olması,
- Büyük veri boyutlarında stabil çalışabilmesi

olarak açıklanabilir.

SMOTE uygulandıktan sonra model performansı yine oldukça yüksek seviyede kalmıştır:

- Accuracy: 0.9987
- Precision: 0.9960
- Recall: 1.0000
- F1-Score: 0.9980

Recall değerinin korunması, modelin tüm fraud işlemlerini yakalamaya devam ettiğini göstermektedir.

Precision değerindeki çok küçük düşüş, modelin bazı normal işlemleri fraud olarak işaretlemesinden kaynaklanmaktadır. Ancak model genel olarak oldukça başarılı performans göstermeye devam etmiştir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Modelin:

- Güçlü öğrenme kapasitesine sahip olması,
- Hataları iteratif olarak azaltması,
- Karmaşık fraud örüntülerini başarılı şekilde öğrenebilmesi

yüksek performans elde edilmesini sağlamıştır.

SMOTE uygulandıktan sonra model performansı şu şekilde gerçekleşmiştir:

- Accuracy: 0.9973
- Precision: 0.9919
- Recall: 1.0000
- F1-Score: 0.9960

Recall değeri korunmasına rağmen Precision ve F1-Score değerlerinde küçük düşüşler meydana gelmiştir.

Bu durumun temel nedeni, XGBoost modelinin sentetik fraud örneklerine daha fazla uyum sağlaması ve bazı normal işlemleri fraud olarak sınıflandırmasıdır.

Boosting algoritmaları bazı durumlarda azınlık sınıfa aşırı duyarlı hale gelebilmektedir. Buna rağmen model genel olarak oldukça güçlü performans göstermeye devam etmiştir.

Genel Model Karşılaştırması

24000 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük Recall performansı göstermiştir.
- Random Forest ve XGBoost modelleri son derece yüksek başarı elde etmiştir.
- En başarılı modeller Random Forest ve XGBoost olmuştur.

Bu sonuçların temel nedenleri:

1. Fraud örüntülerinin doğrusal olmaması
2. Ensemble tabanlı modellerin karmaşık ilişkileri daha başarılı öğrenebilmesi
3. Veri miktarının artmasının modellerin genelleme kapasitesini artırması
4. Ağaç tabanlı yöntemlerin büyük veri boyutlarında daha stabil çalışabilmesi

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerlerinin 1.000 seviyesine ulaşması, modellerin dolandırıcılık işlemlerini eksiksiz şekilde yakalayabildiğini göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Çünkü yanlış alarm oranının artması müşteri memnuniyetsizliğine yol açabilir.

Bu nedenle:

- Recall + Precision dengesi,
- F1-Score başarısı,
- Genelleme performansı

birlikte değerlendirildiğinde en başarılı modellerin Random Forest ve XGBoost olduğu sonucuna ulaşılmıştır.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 48000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
Logistic Reg.	Yok	Eğitim	0.9979	0.9733	0.8150	0.8872
		Test	0.9390	1.0000	0.8150	0.8981
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9993	0.9980	1.0000	0.9990
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9966	0.9899	1.0000	0.9949
Logistic Reg.	Var	Eğitim	0.9448	0.9749	0.9130	0.9430
		Test	0.9497	0.9299	0.9167	0.9232

1. 48000 Boyutlu Veri Seti Yapısı

48000 boyutlu senaryoda:

- Normal işlem sayısı = 48000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$48000+492=48492$$

şeklindedir.

Eğitim Verisi

- Toplam ≈ 38793 örnek
- Normal işlem ≈ 38400
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 9699 örnek
- Normal işlem ≈ 9600
- Fraud işlem ≈ 99

şeklindedir.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece veri setinin gerçek dağılımı korunmuş ve modellerin gerçek dünya koşullarına yakın şekilde değerlendirilmesi sağlanmıştır.

Veri miktarının ciddi düzeyde artmasıyla birlikte ensemble tabanlı modellerin performanslarının oldukça stabil hale geldiği ve genelleme başarılarının maksimum seviyelere ulaştığı gözlenmiştir.

2. 48000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 38400 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 38400
- Fraud işlem ≈ 38400

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 9600
- Fraud işlem ≈ 99

olarak bırakılmıştır.

Bu yaklaşım sayesinde modeller eğitim aşamasında fraud örüntülerini daha güçlü öğrenebilmiş; test aşamasında ise gerçek dünya veri dağılımına yakın koşullarda değerlendirilmiştir.

Özellikle büyük veri boyutlarında SMOTE yönteminin ensemble tabanlı modellerle birlikte oldukça etkili sonuçlar ürettiği gözlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 48000)

Bu çalışmada 48000 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının çok büyük seviyelere ulaşmasıyla birlikte ensemble tabanlı modellerin performanslarının son derece stabil hale geldiği gözlenmiştir.

1. Lojistik Regresyon Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktalarını doğrusal karar sınırları kullanarak ayırmaktadır. Bu nedenle karmaşık fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9390
- Precision: 1.0000
- Recall: 0.8150
- F1-Score: 0.8981

şeklindedir.

Bu sonuçlar, modelin fraud olarak işaretlediği işlemlerde hata yapmadığını göstermektedir. Precision değerinin 1.000 olması, modelin yanlış alarm üretmediğini ifade etmektedir.

Ancak Recall değerinin 0.8150 olması, modelin fraud işlemlerinin yaklaşık %19'unu kaçırdığını göstermektedir. Fraud detection problemlerinde kaçırılan fraud işlemleri finansal kayıplara yol açabileceği için bu durum önemli bir dezavantaj oluşturmaktadır.

Veri miktarı artsa bile Recall değerinin düşük kalması, Lojistik Regresyon modelinin doğrusal yapısından kaynaklanmaktadır. Fraud işlemleri karmaşık ve non-lineer örüntüler içerdiği için model bu ilişkileri tam olarak öğrenememektedir.

SMOTE uygulandıktan sonra model performansında belirgin iyileşmeler gözlenmiştir:

- Recall: 0.8150 → 0.9167
- F1-Score: 0.8981 → 0.9232

Bu sonuçlar, SMOTE yönteminin azınlık sınıfını güçlendirerek modelin fraud örüntülerini daha başarılı öğrenmesini sağladığını göstermektedir.

Ancak Precision değerinin düşmesi:

- Precision: 1.0000 → 0.9299

modelin daha fazla yanlış alarm üretmeye başladığını göstermektedir.

Bu durum Recall–Precision dengesi ile açıklanabilir. Model daha fazla fraud işlemi yakalamaya çalışırken bazı normal işlemleri de fraud olarak sınıflandırmıştır.

Genel olarak değerlendirildiğinde Lojistik Regresyon modeli:

- Basit,
- Hızlı çalışan,
- Yorumlanabilir,

- Düşük hesaplama maliyetine sahip

bir yöntem olmasına rağmen karmaşık fraud detection problemlerinde ensemble tabanlı yöntemlerin gerisinde kalmıştır.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin test veri setindeki tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Random Forest modelinin bu kadar güçlü performans göstermesinin temel nedenleri:

- Karmaşık non-lineer ilişkileri öğrenebilmesi,
- Çok sayıda karar ağacı kullanması,
- Gürültülü verilere karşı dayanıklı olması,
- Overfitting riskinin düşük olması,
- Büyük veri boyutlarında stabil çalışabilmesi

olarak açıklanabilir.

SMOTE uygulandıktan sonra model performansı yine oldukça yüksek seviyede kalmıştır:

- Accuracy: 0.9993
- Precision: 0.9980
- Recall: 1.0000
- F1-Score: 0.9990

Recall değerinin korunması, modelin tüm fraud işlemlerini yakalamaya devam ettiğini göstermektedir.

Precision değerindeki çok küçük düşüş, modelin bazı normal işlemleri fraud olarak işaretlemesinden kaynaklanmaktadır. Ancak model genel olarak son derece başarılı performans göstermeye devam etmiştir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Modelin:

- Güçlü öğrenme kapasitesine sahip olması,
- Hataları iteratif şekilde azaltması,
- Karmaşık fraud örüntülerini başarılı şekilde öğrenebilmesi

yüksek performans elde edilmesini sağlamıştır.

SMOTE uygulandıktan sonra model performansı şu şekilde gerçekleşmiştir:

- Accuracy: 0.9966
- Precision: 0.9899
- Recall: 1.0000
- F1-Score: 0.9949

Recall değeri korunmasına rağmen Precision ve F1-Score değerlerinde küçük düşüşler meydana gelmiştir.

Bu durumun temel nedeni, XGBoost modelinin sentetik fraud örneklerine daha fazla uyum sağlaması ve bazı normal işlemleri fraud olarak sınıflandırmasıdır.

Boosting algoritmaları bazı durumlarda azınlık sınıfa aşırı duyarlı hale gelebilmektedir. Buna rağmen model genel olarak oldukça yüksek performans göstermeye devam etmiştir.

Genel Model Karşılaştırması

48000 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük Recall performansı göstermiştir.
- Random Forest ve XGBoost modelleri son derece yüksek başarı elde etmiştir.
- En başarılı modeller Random Forest ve XGBoost olmuştur.

Bu sonuçların temel nedenleri:

1. Fraud örüntülerinin doğrusal olmaması
2. Ensemble tabanlı modellerin karmaşık ilişkileri daha başarılı öğrenebilmesi
3. Büyük veri boyutlarının modellerin genelleme kapasitesini artırması
4. Ağaç tabanlı yöntemlerin büyük veri setlerinde daha stabil çalışabilmesi

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerlerinin 1.000 seviyesine ulaşması, modellerin dolandırıcılık işlemlerini eksiksiz şekilde yakalayabildiğini göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Çünkü yanlış alarm oranının artması müşteri memnuniyetsizliğine yol açabilir.

Bu nedenle:

- Recall + Precision dengesi,
- F1-Score başarısı,
- Genelleme performansı

birlikte değerlendirildiğinde en başarılı modellerin Random Forest ve XGBoost olduğu sonucuna ulaşılmıştır.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 50000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
Logistic Reg.	Yok	Eğitim	0.9979	0.9708	0.8110	0.8837
		Test	0.9377	1.0000	0.8110	0.8956
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9987	0.9960	1.0000	0.9980
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9966	0.9899	1.0000	0.9949
Logistic Reg.	Var	Eğitim	0.9451	0.9750	0.9136	0.9433
		Test	0.9497	0.9299	0.9167	0.9232

1. 50000 Boyutlu Veri Seti Yapısı

50000 boyutlu senaryoda:

- Normal işlem sayısı = 50000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$50000+492=50492$$

şeklindedir.

Eğitim Verisi

- Toplam ≈ 40393 örnek
- Normal işlem ≈ 40000
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 10099 örnek
- Normal işlem ≈ 10000
- Fraud işlem ≈ 99

şeklindedir.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece veri setinin gerçek dağılımı korunmuş ve modeller gerçek dünya koşullarına yakın şekilde değerlendirilmiştir.

Veri miktarının çok yüksek seviyelere ulaşmasıyla birlikte ensemble tabanlı modellerin performanslarının oldukça stabil hale geldiği gözlenmiştir.

2. 50000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 40000 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 40000
- Fraud işlem ≈ 40000

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 10000
- Fraud işlem ≈ 99

olarak bırakılmıştır.

Bu yaklaşım sayesinde modeller eğitim aşamasında fraud örüntülerini daha güçlü öğrenebilmiş; test aşamasında ise gerçek dünya veri dağılımına yakın koşullarda değerlendirilmiştir.

Özellikle büyük veri boyutlarında SMOTE yönteminin ensemble tabanlı modellerle birlikte oldukça güçlü sonuçlar ürettiği gözlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 50000)

Bu çalışmada 50000 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının oldukça yüksek seviyelere ulaşmasıyla birlikte ensemble tabanlı modellerin performanslarının son derece stabil hale geldiği gözlenmiştir.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktalarını doğrusal karar sınırları kullanarak ayırmaktadır. Bu nedenle karmaşık fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9377
- Precision: 1.0000
- Recall: 0.8110
- F1-Score: 0.8956

şeklindedir.

Bu sonuçlar, modelin fraud olarak işaretlediği işlemlerde hata yapmadığını göstermektedir. Precision değerinin 1.000 olması, modelin yanlış alarm üretmediğini ifade etmektedir.

Ancak Recall değerinin 0.8110 olması, modelin fraud işlemlerinin yaklaşık %19'unu kaçırdığını göstermektedir. Fraud detection problemlerinde kaçırılan işlemler finansal kayıplara yol açabileceği için bu durum önemli bir dezavantaj oluşturmaktadır.

Veri miktarı artsa bile Recall değerinin düşük kalması, Lojistik Regresyon modelinin doğrusal yapısından kaynaklanmaktadır. Fraud işlemleri karmaşık ve non-lineer örüntüler içerdiği için model bu ilişkileri tam olarak öğrenememektedir.

SMOTE uygulandıktan sonra model performansında belirgin iyileşmeler gözlenmiştir:

- Recall: 0.8110 → 0.9167
- F1-Score: 0.8956 → 0.9232

Bu sonuçlar, SMOTE yönteminin azınlık sınıfını güçlendirerek modelin fraud örüntülerini daha başarılı öğrenmesini sağladığını göstermektedir.

Ancak Precision değerinin düşmesi:

- Precision: 1.0000 → 0.9299

modelin daha fazla yanlış alarm üretmeye başladığını göstermektedir.

Bu durum Recall–Precision dengesi ile açıklanabilir. Model daha fazla fraud işlemi yakalamaya çalışırken bazı normal işlemleri de fraud olarak sınıflandırmıştır.

Genel olarak değerlendirildiğinde Lojistik Regresyon modeli:

- Basit,
- Hızlı çalışan,
- Yorumlanabilir,

- Düşük hesaplama maliyetine sahip

bir yöntem olmasına rağmen karmaşık fraud detection problemlerinde ensemble tabanlı yöntemlerin gerisinde kalmıştır.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin test veri setindeki tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Random Forest modelinin bu kadar güçlü performans göstermesinin temel nedenleri:

- Karmaşık non-lineer ilişkileri öğrenebilmesi,
- Çok sayıda karar ağacı kullanması,
- Gürültülü verilere karşı dayanıklı olması,
- Overfitting riskinin düşük olması,
- Büyük veri boyutlarında stabil çalışabilmesi

olarak açıklanabilir.

SMOTE uygulandıktan sonra model performansı yine oldukça yüksek seviyede kalmıştır:

- Accuracy: 0.9987
- Precision: 0.9960
- Recall: 1.0000
- F1-Score: 0.9980

Recall değerinin korunması, modelin tüm fraud işlemlerini yakalamaya devam ettiğini göstermektedir.

Precision değerindeki çok küçük düşüş, modelin bazı normal işlemleri fraud olarak işaretlemesinden kaynaklanmaktadır. Ancak model genel olarak son derece başarılı performans göstermeye devam etmiştir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Modelin:

- Güçlü öğrenme kapasitesine sahip olması,
- Hataları iteratif şekilde azaltması,
- Karmaşık fraud örüntülerini başarılı şekilde öğrenebilmesi

yüksek performans elde edilmesini sağlamıştır.

SMOTE uygulandıktan sonra model performansı şu şekilde gerçekleşmiştir:

- Accuracy: 0.9966
- Precision: 0.9899
- Recall: 1.0000
- F1-Score: 0.9949

Recall değeri korunmasına rağmen Precision ve F1-Score değerlerinde küçük düşüşler meydana gelmiştir.

Bu durumun temel nedeni, XGBoost modelinin sentetik fraud örneklerine daha fazla uyum sağlaması ve bazı normal işlemleri fraud olarak sınıflandırmasıdır.

Boosting algoritmaları bazı durumlarda azınlık sınıfa aşırı duyarlı hale gelebilmektedir. Buna rağmen model genel olarak oldukça yüksek performans göstermeye devam etmiştir.

Genel Model Karşılaştırması

50000 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük Recall performansı göstermiştir.
- Random Forest ve XGBoost modelleri son derece yüksek başarı elde etmiştir.
- En başarılı modeller Random Forest ve XGBoost olmuştur.

Bu sonuçların temel nedenleri:

1. Fraud örüntülerinin doğrusal olmaması
2. Ensemble tabanlı modellerin karmaşık ilişkileri daha başarılı öğrenebilmesi
3. Büyük veri boyutlarının modellerin genelleme kapasitesini artırması
4. Ağaç tabanlı yöntemlerin büyük veri setlerinde daha stabil çalışabilmesi

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada Random Forest ve XGBoost modellerinin Recall değerlerinin 1.000 seviyesine ulaşması, modellerin dolandırıcılık işlemlerini eksiksiz şekilde yakalayabildiğini göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Çünkü yanlış alarm oranının artması müşteri memnuniyetsizliğine yol açabilir.

Bu nedenle:

- Recall + Precision dengesi,
- F1-Score başarısı,
- Genelleme performansı

birlikte değerlendirildiğinde en başarılı modellerin Random Forest ve XGBoost olduğu sonucuna ulaşılmıştır.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 55000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9993	0.9980	1.0000	0.9990
Logistic Reg.	Yok	Eğitim	0.9981	0.9683	0.8069	0.8803
		Test	0.9363	1.0000	0.8069	0.8931
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9987	0.9960	1.0000	0.9980
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9973	0.9919	1.0000	0.9960
Logistic Reg.	Var	Eğitim	0.9457	0.9753	0.9145	0.9439
		Test	0.9497	0.9281	0.9187	0.9234

1. 55000 Boyutlu Veri Seti Yapısı

55000 boyutlu senaryoda:

- Normal işlem sayısı = 55000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$55000+492=55492$$

şeklindedir.

Eğitim Verisi

- Toplam ≈ 44393 örnek
- Normal işlem ≈ 44000
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 11099 örnek
- Normal işlem ≈ 11000
- Fraud işlem ≈ 99

şeklindedir.

Kod içerisinde kullanılan:

stratify=y

parametresi sayesinde eğitim ve test veri setlerinde fraud-normal oranı korunmuştur. Böylece veri setinin gerçek dağılımı korunmuş ve modeller gerçek dünya koşullarına yakın şekilde değerlendirilmiştir.

Veri miktarının oldukça büyük seviyelere ulaşmasıyla birlikte ensemble tabanlı modellerin performanslarının son derece stabil hale geldiği gözlenmiştir.

2. 55000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 44000 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası yaklaşık eğitim dağılımı:

Eğitim Verisi (SMOTE Sonrası)

- Normal işlem ≈ 44000
- Fraud işlem ≈ 44000

şeklindedir.

Test veri seti ise değiştirilmemiştir:

Test Verisi

- Normal işlem ≈ 11000
- Fraud işlem ≈ 99

olarak bırakılmıştır.

Bu yaklaşım sayesinde modeller eğitim aşamasında fraud örüntülerini daha güçlü öğrenebilmiş; test aşamasında ise gerçek dünya veri dağılımına yakın koşullarda değerlendirilmiştir.

Özellikle büyük veri boyutlarında SMOTE yönteminin ensemble tabanlı modellerle birlikte oldukça başarılı sonuçlar verdiği gözlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 55000)

Bu çalışmada 55000 boyutlu veri seti kullanılarak Lojistik Regresyon (Logistic Regression), Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall) ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının çok yüksek seviyelere ulaşmasıyla birlikte ensemble tabanlı modellerin oldukça stabil performans gösterdiği gözlenmiştir.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal yapıya sahip bir sınıflandırma algoritmasıdır. Model, veri noktalarını doğrusal karar sınırları kullanarak ayırmaktadır. Bu nedenle karmaşık fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9363
- Precision: 1.0000
- Recall: 0.8069
- F1-Score: 0.8931

şeklindedir.

Bu sonuçlar, modelin fraud olarak işaretlediği işlemlerde hata yapmadığını göstermektedir. Precision değerinin 1.000 olması, modelin yanlış alarm üretmediğini ifade etmektedir.

Ancak Recall değerinin 0.8069 olması, modelin fraud işlemlerinin yaklaşık %19'unu kaçırdığını göstermektedir. Fraud detection problemlerinde kaçırılan işlemler ciddi finansal kayıplara yol açabileceği için bu durum önemli bir dezavantaj oluşturmaktadır.

Veri miktarı artsa bile Recall değerinin düşük kalması, modelin doğrusal yapısından kaynaklanmaktadır. Fraud işlemleri karmaşık ve non-lineer örüntüler içerdiği için model bu ilişkileri tam olarak öğrenememektedir.

SMOTE uygulandıktan sonra model performansında belirgin iyileşmeler gözlenmiştir:

- Recall: 0.8069 → 0.9187
- F1-Score: 0.8931 → 0.9234

Bu sonuçlar, SMOTE yönteminin azınlık sınıfını güçlendirerek modelin fraud örüntülerini daha başarılı öğrenmesini sağladığını göstermektedir.

Ancak Precision değerinin düşmesi:

- Precision: 1.0000 → 0.9281

modelin daha fazla yanlış alarm üretmeye başladığını göstermektedir.

Bu durum Recall–Precision dengesi ile açıklanabilir. Model daha fazla fraud işlemi yakalamaya çalışırken bazı normal işlemleri de fraud olarak sınıflandırmıştır.

Genel olarak değerlendirildiğinde Lojistik Regresyon modeli:

- Basit,
- Hızlı çalışan,
- Yorumlanabilir,

- Düşük hesaplama maliyetine sahip

bir yöntem olmasına rağmen karmaşık fraud detection problemlerinde ensemble tabanlı yöntemlerin gerisinde kalmıştır.

2. Random Forest Analizi

Random Forest algoritması, çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı güçlü bir sınıflandırma yöntemidir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

şeklindedir.

Bu sonuçlar, modelin test veri setindeki tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve hiçbir yanlış alarm üretmediğini göstermektedir.

Random Forest modelinin bu kadar güçlü performans göstermesinin temel nedenleri:

- Karmaşık non-lineer ilişkileri öğrenebilmesi,
- Çok sayıda karar ağacı kullanması,
- Gürültülü verilere karşı dayanıklı olması,
- Overfitting riskinin düşük olması,
- Büyük veri boyutlarında stabil çalışabilmesi

olarak açıklanabilir.

SMOTE uygulandıktan sonra model performansı yine oldukça yüksek seviyede kalmıştır:

- Accuracy: 0.9987
- Precision: 0.9960
- Recall: 1.0000
- F1-Score: 0.9980

Recall değerinin korunması, modelin tüm fraud işlemlerini yakalamaya devam ettiğini göstermektedir.

Precision değerindeki çok küçük düşüş, modelin bazı normal işlemleri fraud olarak işaretlemesinden kaynaklanmaktadır. Ancak model genel olarak son derece başarılı performans göstermeye devam etmiştir.

3. XGBoost Analizi

XGBoost algoritması, gradient boosting tabanlı gelişmiş bir ensemble öğrenme yöntemidir. Model, hataları iteratif şekilde azaltarak güçlü tahminler üretmektedir.

SMOTE uygulanmadan elde edilen test sonuçları:

- Accuracy: 0.9993
- Precision: 0.9980
- Recall: 1.0000
- F1-Score: 0.9990

şeklindedir.

Bu sonuçlar, modelin neredeyse tüm fraud işlemlerini eksiksiz şekilde yakaladığını ve çok düşük yanlış alarm oranına sahip olduğunu göstermektedir.

Modelin:

- Güçlü öğrenme kapasitesine sahip olması,
- Hataları iteratif şekilde azaltması,
- Karmaşık fraud örüntülerini başarılı şekilde öğrenebilmesi

yüksek performans elde edilmesini sağlamıştır.

SMOTE uygulandıktan sonra model performansı şu şekilde gerçekleşmiştir:

- Accuracy: 0.9973
- Precision: 0.9919
- Recall: 1.0000
- F1-Score: 0.9960

Recall değeri korunmasına rağmen Precision ve F1-Score değerlerinde küçük düşüşler meydana gelmiştir.

Bu durumun temel nedeni, XGBoost modelinin sentetik fraud örneklerine daha fazla uyum sağlaması ve bazı normal işlemleri fraud olarak sınıflandırmasıdır.

Boosting algoritmaları bazı durumlarda azınlık sınıfa aşırı duyarlı hale gelebilmektedir. Buna rağmen model genel olarak oldukça yüksek performans göstermeye devam etmiştir.

Genel Model Karşılaştırması

55000 boyutlu veri seti sonuçları incelendiğinde:

- Lojistik Regresyon modeli diğer modellere göre daha düşük Recall performansı göstermiştir.
- Random Forest ve XGBoost modelleri son derece yüksek başarı elde etmiştir.
- En başarılı model Random Forest olmuştur.

Bu sonuçların temel nedenleri:

1. Fraud örüntülerinin doğrusal olmaması
2. Ensemble tabanlı modellerin karmaşık ilişkileri daha başarılı öğrenebilmesi
3. Büyük veri boyutlarının modellerin genelleme kapasitesini artırması
4. Ağaç tabanlı yöntemlerin büyük veri setlerinde daha stabil çalışabilmesi

şeklinde açıklanabilir.

Özellikle fraud detection problemlerinde Recall metriği kritik öneme sahiptir. Çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelmektedir.

Bu çalışmada Random Forest modelinin Recall değerinin 1.000 seviyesine ulaşması, modelin dolandırıcılık işlemlerini eksiksiz şekilde yakalayabildiğini göstermektedir.

Ancak yalnızca Recall metriği yeterli değildir. Precision değerinin de yüksek olması gerekmektedir. Çünkü yanlış alarm oranının artması müşteri memnuniyetsizliğine yol açabilir.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 60000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
Logistic Reg.	Yok	Eğitim	0.9982	0.9658	0.8028	0.8768
		Test	0.9350	1.0000	0.8028	0.8906
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9993	0.9980	1.0000	0.9990
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9960	0.9880	1.0000	0.9939
Logistic Reg.	Var	Eğitim	0.9443	0.9746	0.9125	0.9425
		Test	0.9497	0.9299	0.9167	0.9232

1. 60000 Boyutlu Veri Seti Yapısı

60000 boyutlu senaryoda:

- Normal işlem sayısı = 60000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$60000 + 492 = \mathbf{60492}$$

şeklindedir.

Bu veri seti daha sonra eğitim ve test setlerine bölünmüştür.

Yaklaşık Dağılım:

Eğitim Verisi

- Toplam ≈ 48393 örnek
- Normal işlem ≈ 48000
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 12099 örnek
- Normal işlem ≈ 12000
- Fraud işlem ≈ 99

Kod içerisinde kullanılan **stratify=y** parametresi sayesinde eğitim ve test veri setlerinde sınıf oranı korunmuştur. Böylece veri seti gerçek dünya dağılımına uygun şekilde modellenmiştir.

Veri miktarının artmasıyla birlikte modellerin genelleme kabiliyeti daha stabil hale gelmiş ve özellikle ensemble tabanlı yöntemlerin performansında kararlı bir yapı gözlenmiştir.

2. 60000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 48000 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud verileri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE Sonrası Eğitim Dağılımı:

- Normal işlem ≈ 48000
- Fraud işlem ≈ 48000

Test veri seti ise değiştirilmemiştir:

- Normal işlem ≈ 12000
- Fraud işlem ≈ 99

Bu yaklaşım sayesinde modeller eğitim aşamasında azınlık sınıfı daha iyi öğrenmiş, test aşamasında ise gerçek veri dağılımı korunarak objektif değerlendirme yapılmıştır.

Özellikle büyük veri boyutlarında SMOTE yönteminin ensemble algoritmalarla birlikte daha güçlü öğrenme sağladığı gözlemlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 60000)

Bu çalışmada 60000 boyutlu veri seti kullanılarak Logistic Regression, Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar Accuracy, Precision, Recall ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının artmasıyla birlikte özellikle ağaç tabanlı ensemble modellerin performanslarının daha stabil hale geldiği gözlemlenmiştir.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal bir sınıflandırma algoritmasıdır. Bu nedenle karmaşık ve non-lineer fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan test sonuçları:

- Accuracy: 0.9350
- Precision: 1.0000
- Recall: 0.8028
- F1-Score: 0.8906

Modelin precision değerinin 1.000 olması, yanlış alarm üretmediğini göstermektedir. Ancak Recall değerinin 0.8028 olması, fraud işlemlerinin yaklaşık %20'sinin kaçırıldığını göstermektedir.

Bu durum, lojistik regresyonun doğrusal yapısından kaynaklanmaktadır. Fraud işlemlerinin karmaşık yapısı nedeniyle model yeterli öğrenme kapasitesine ulaşamamaktadır.

SMOTE sonrası:

- Recall: 0.8028 → 0.9167
- F1-Score: 0.8906 → 0.9232
- Precision: 1.0000 → 0.9299

SMOTE ile birlikte model fraud örneklerini daha iyi öğrenmiş, ancak precision düşerek daha fazla yanlış alarm üretmeye başlamıştır.

Genel olarak lojistik regresyon, hızlı ve yorumlanabilir olmasına rağmen karmaşık fraud problemlerinde yetersiz kalmaktadır.

2. Random Forest Analizi

Random Forest, çok sayıda karar ağacından oluşan güçlü bir ensemble yöntemidir.

SMOTE uygulanmadan test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

Model tüm fraud işlemlerini hatasız yakalamıştır.

Bu başarının temel nedenleri:

- Non-lineer ilişkileri öğrenebilmesi
- Ensemble yapısı
- Gürültüye dayanıklılık
- Büyük veri setlerinde stabil çalışma

SMOTE sonrası:

- Accuracy: 0.9993
- Precision: 0.9980
- Recall: 1.0000
- F1-Score: 0.9990

Recall değeri korunmuş, model fraud yakalamaya devam etmiştir. Precision'daki küçük düşüş bazı normal işlemlerin yanlış sınıflandırılmasından kaynaklanmaktadır.

Genel olarak Random Forest en stabil modellerden biri olmuştur.

3. XGBoost Analizi

XGBoost, gradient boosting tabanlı güçlü bir ensemble modelidir.

SMOTE uygulanmadan test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

Model tüm fraud işlemlerini eksiksiz yakalamıştır.

SMOTE sonrası:

- Accuracy: 0.9960
- Precision: 0.9880
- Recall: 1.0000
- F1-Score: 0.9939

Recall korunmuş ancak precision ve F1-score'da küçük düşüş yaşanmıştır. Bu durum modelin SMOTE sonrası daha agresif öğrenmesinden kaynaklanmaktadır.

XGBoost genel olarak yüksek doğruluk ve güçlü genelleme kabiliyeti göstermiştir.

Genel Model Karşılaştırması (60000 Veri Seti)

60000 boyutlu veri seti sonuçlarına göre:

- Logistic Regression en düşük performansı göstermiştir.
- Random Forest ve XGBoost çok yüksek performans göstermiştir.
- En stabil ve güçlü model Random Forest olmuştur.

Temel nedenler:

- Fraud verisinin non-lineer yapısı
- Ensemble modellerin güçlü öğrenme kapasitesi
- Büyük veri setlerinin genelleme gücünü artırması
- Ağaç tabanlı modellerin karmaşık ilişkileri yakalayabilmesi

Genel Değerlendirme

Fraud detection problemlerinde en kritik metrik Recall'dır çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelir.

Bu çalışmada Random Forest ve XGBoost modelleri Recall = 1.000 seviyesine ulaşarak tüm fraud işlemlerini başarıyla yakalamıştır.

Ancak yalnızca Recall yeterli değildir. Precision da yüksek olmalıdır çünkü yanlış alarm müşteri deneyimini olumsuz etkiler.

Bu nedenle 60000 veri seti için genel değerlendirmede:

- Recall + Precision dengesi
- F1-Score başarısı
- Genelleme kabiliyeti

birlikte ele alındığında en başarılı modellerin **Random Forest ve XGBoost** olduğu sonucuna ulaşılmıştır.

Eğitim ve Test Performansı Karşılaştırma Tablosu (Size: 96000)

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
Random Forest	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
XGBoost	Yok	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	1.0000	1.0000	1.0000	1.0000
Logistic Reg.	Yok	Eğitim	0.9988	0.9749	0.7886	0.8719

Model	SMOTE	Veri Seti	Doğruluk (Acc)	Kesinlik (Prec)	Duyarlılık (Recall)	F1-Skoru
		Test	0.9303	1.0000	0.7886	0.8818
Random Forest	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9987	0.9960	1.0000	0.9980
XGBoost	Var	Eğitim	1.0000	1.0000	1.0000	1.0000
		Test	0.9960	0.9880	1.0000	0.9939
Logistic Reg.	Var	Eğitim	0.9450	0.9742	0.9142	0.9433
		Test	0.9504	0.9300	0.9187	0.9243

1. 96000 Boyutlu Veri Seti Yapısı

96000 boyutlu senaryoda:

- Normal işlem sayısı = 96000
- Fraud işlem sayısı = 492

olarak kullanılmıştır.

Toplam veri sayısı:

$$96000 + 492 = \mathbf{96492}$$

şeklindedir.

Bu veri seti daha sonra eğitim ve test setlerine ayrılmıştır.

Eğitim Verisi

- Toplam ≈ 77193 örnek
- Normal işlem ≈ 76800
- Fraud işlem ≈ 393

Test Verisi

- Toplam ≈ 19299 örnek
- Normal işlem ≈ 19200
- Fraud işlem ≈ 99

Kod içerisinde kullanılan **stratify=y** parametresi sayesinde eğitim ve test veri setlerinde sınıf oranı korunmuştur. Böylece veri dağılımı gerçek dünya koşullarına uygun şekilde korunarak modellerin adil bir şekilde değerlendirilmesi sağlanmıştır.

Veri miktarının daha da artmasıyla birlikte modellerin genelleme kapasitesi güçlenmiş ve özellikle ensemble tabanlı yöntemlerde daha kararlı sonuçlar elde edilmiştir.

2. 96000 Boyutlu SMOTE Sonrası Veri Yapısı

SMOTE yalnızca eğitim verisi üzerinde uygulanmıştır.

Başlangıçta eğitim verisinde yaklaşık:

- 76800 normal işlem
- 393 fraud işlem

bulunmaktadır.

SMOTE uygulandıktan sonra azınlık sınıfı olan fraud işlemleri sentetik örneklerle artırılmış ve eğitim veri seti dengelenmiştir.

SMOTE sonrası eğitim dağılımı:

- Normal işlem ≈ 76800
- Fraud işlem ≈ 76800

Test veri seti ise değiştirilmemiştir:

- Normal işlem ≈ 19200
- Fraud işlem ≈ 99

Bu yaklaşım sayesinde modeller eğitim aşamasında azınlık sınıfı daha iyi öğrenmiş, test aşamasında ise gerçek dünya veri dağılımı korunarak objektif değerlendirme yapılmıştır.

Özellikle çok büyük veri setlerinde SMOTE yönteminin ensemble algoritmalarla birlikte daha dengeli ve güçlü öğrenme sağladığı gözlemlenmiştir.

Model Performans Karşılaştırması ve SMOTE Etkisinin Analizi (Veri Boyutu: 96000)

Bu çalışmada 96000 boyutlu veri seti kullanılarak Logistic Regression, Random Forest ve XGBoost algoritmalarının performansları karşılaştırılmıştır. Modeller hem SMOTE uygulanmadan hem de SMOTE uygulanarak eğitilmiş ve sonuçlar Accuracy, Precision, Recall ve F1-Score metrikleri üzerinden değerlendirilmiştir.

Veri miktarının oldukça yüksek seviyelere ulaşmasıyla birlikte özellikle ensemble tabanlı modellerin performanslarının son derece stabil hale geldiği gözlemlenmiştir.

1. Lojistik Regresyon (Logistic Regression) Analizi

Lojistik Regresyon modeli doğrusal bir sınıflandırma algoritmasıdır. Bu nedenle karmaşık ve non-lineer fraud örüntülerini öğrenme kapasitesi sınırlıdır.

SMOTE uygulanmadan test sonuçları:

- Accuracy: 0.9303
- Precision: 1.0000
- Recall: 0.7886
- F1-Score: 0.8818

Modelin precision değerinin 1.000 olması, yanlış alarm üretmediğini göstermektedir. Ancak Recall değerinin 0.7886 olması, fraud işlemlerinin yaklaşık %21'inin kaçırıldığını göstermektedir.

Bu durum lojistik regresyonun doğrusal yapısından kaynaklanmaktadır. Fraud işlemlerinin karmaşık yapısı model tarafından tam olarak öğrenilememektedir.

SMOTE sonrası:

- Recall: 0.7886 → 0.9187
- F1-Score: 0.8818 → 0.9243
- Precision: 1.0000 → 0.9300

SMOTE ile birlikte model fraud örneklerini daha iyi öğrenmiş, ancak precision düşerek daha fazla yanlış alarm üretmeye başlamıştır.

Genel olarak lojistik regresyon büyük veri setlerinde bile sınırlı performans göstermekte ve ensemble yöntemlerin gerisinde kalmaktadır.

2. Random Forest Analizi

Random Forest, çok sayıda karar ağacından oluşan güçlü bir ensemble modelidir.

SMOTE uygulanmadan test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

Model tüm fraud işlemlerini hatasız şekilde yakalamıştır.

Bu başarının nedenleri:

- Non-lineer ilişkileri öğrenebilmesi
- Ensemble yapısı
- Gürültüye dayanıklılık
- Büyük veri setlerinde stabil çalışma

SMOTE sonrası:

- Accuracy: 0.9987
- Precision: 0.9960
- Recall: 1.0000
- F1-Score: 0.9980

Recall değeri korunmuş, model fraud işlemleri yakalamaya devam etmiştir. Precision'daki küçük düşüş bazı normal işlemlerin yanlış sınıflandırılmasından kaynaklanmaktadır.

Random Forest genel olarak en stabil modellerden biri olmuştur.

3. XGBoost Analizi

XGBoost, gradient boosting tabanlı güçlü bir ensemble yöntemidir.

SMOTE uygulanmadan test sonuçları:

- Accuracy: 1.0000
- Precision: 1.0000
- Recall: 1.0000
- F1-Score: 1.0000

Model tüm fraud işlemlerini eksiksiz yakalamıştır.

SMOTE sonrası:

- Accuracy: 0.9960
- Precision: 0.9880
- Recall: 1.0000
- F1-Score: 0.9939

Recall korunmuş ancak precision ve F1-score'da küçük düşüşler olmuştur. Bu durum modelin SMOTE sonrası daha agresif öğrenmesinden kaynaklanmaktadır.

XGBoost genel olarak yüksek performans ve güçlü genelleme kabiliyeti göstermiştir.

Genel Model Karşılaştırması (96000 Veri Seti)

96000 boyutlu veri seti sonuçlarına göre:

- Logistic Regression en düşük performansı göstermiştir.
- Random Forest ve XGBoost çok yüksek performans göstermiştir.
- En stabil ve güçlü model Random Forest olmuştur.

Temel nedenler:

- Fraud verisinin non-lineer yapısı
- Ensemble modellerin güçlü öğrenme kapasitesi
- Büyük veri setlerinin genelleme gücünü artırması
- Ağaç tabanlı modellerin karmaşık ilişkileri yakalayabilmesi

Genel Değerlendirme

Fraud detection problemlerinde en kritik metrik Recall'dır çünkü kaçırılan her fraud işlem doğrudan finansal kayıp anlamına gelir.


Bu çalışmada Random Forest ve XGBoost modelleri Recall = 1.000 seviyesine ulaşarak tüm fraud işlemlerini başarıyla yakalamıştır.

Ancak yalnızca Recall yeterli değildir. Precision da yüksek olmalıdır çünkü yanlış alarm müşteri deneyimini olumsuz etkiler.

Bu nedenle 96000 veri seti için genel değerlendirmede:

- Recall + Precision dengesi
- F1-Score başarısı
- Genelleme kabiliyeti

birlikte ele alındığında en başarılı modellerin **Random Forest ve XGBoost** olduğu sonucuna ulaşılmıştır.



Farklı Veri Boyutlarında Modellerin Performans Metrikleri Değişim Analizi

Yukarıdaki grafik, veri seti boyutunun (normal işlem sayısının) 500'den 96.000'e kadar artırılmasıyla oluşan aşırı sınıf dengesizliği durumunda, Lojistik Regresyon, Random Forest ve XGBoost modellerinin test verisi üzerindeki Recall (Duyarlılık) ve Precision (Kesinlik) metriklerindeki değişimi göstermektedir. Grafik üzerinden şu temel analizler yapılabilir:

- Duyarlılık (Recall) Kararlılığı:** Kredi kartı dolandırıcılığı tespitinde en kritik metrik olan Recall değerinde, **Random Forest** ve **XGBoost** modelleri tüm veri boyutlarında %100'e yakın bir kararlılık sergileyerek dolandırıcılık vakalarını kaçırmadıklarını kanıtlamıştır. Buna karşın, **Lojistik Regresyon** modelinin Recall başarısı, veri boyutu ve dengesizlik arttıkça doğrusal bir düşüş sergileyerek %92 seviyelerinden %78 seviyelerine kadar gerilemiştir.
- Kesinlik (Precision) Gelişimi:** Veri miktarı arttıkça tüm modellerin Precision değerlerinde bir yükselme gözlemlenmiştir. Bu durum, modellerin daha fazla normal işlem örneği görerek "yanlış alarm" (False Positive) üretme oranlarını düşürdüğünü göstermektedir. Özellikle Random Forest ve XGBoost, büyük veri setlerinde hem Recall hem de Precision değerlerinde 1.000 (kusursuz) seviyesine ulaşmıştır.
- Algoritma Dayanıklılığı:** Grafik, doğrusal modellerin (Lojistik Regresyon) sınıf dengesizliğine karşı oldukça hassas olduğunu, ancak topluluk öğrenme tabanlı (Ensemble) modellerin (Random Forest ve XGBoost) karmaşık ve dengesiz veri

yapılarında çok daha sağlam ve güvenilir sonuçlar ürettiğini görsel olarak doğrulamaktadır.

Bu analiz sonucunda, projenin temel hedefi olan "yüksek doğruluklu dolandırıcılık tespiti" için en stabil ve başarılı performansın **Random Forest** algoritması tarafından sergilendiği tespit edilmiştir.

Kaynaklar

[1] M. Selimoğlu and A. Yılmaz, “Kredi kartı dolandırıcılık tespitinin makine öğrenmesi yöntemleri ile tahmin edilmesi,” *Beykent Üniversitesi Fen ve Mühendislik Bilimleri Dergisi*, vol. 13, no. 2, pp. 28–33, 2021, doi: 10.20854/bujse.873804.

[2] A. Sarker, A. Yasmin, M. A. Rahman, M. H. Rashid, and B. R. Roy, “Detection of credit card